Modelación probabilística de periodos de siembra del maíz en condiciones de cambio climático. Caso de estudio en Alemania.

Isaac Vázquez-Mendoza[a]*, Magali Arellano-Vazquez[a]

[a] INFOTEC, Centro de Investigación e Innovación en Tecnologías de la Información y Comunicación, Aguascalientes 20326, Mexico.

1. Introducción

Las flores, frutas, vegetales y hongos representan un pilar fundamental en la cadena alimentaria (Cassani and Gomez-Zavaglia, 2022). La industria agrícola, responsable de su producción continua, enfrenta desafíos crecientes debido a la incertidumbre respecto a las condiciones de cultivo, las cuales se han visto afectadas, en gran parte, por el cambio climático (Parajuli et al., 2019).

Las alteraciones que se derivan del cambio climático repercuten en diversos aspectos, entre ellos, el ciclo de producción agrícola, debido a variaciones inusuales e inesperadas en temperatura, precipitación y patrones de migración de polinizadores, entre otros factores. Los cuales, en conjunto, han modificado las zonas, temporadas y rendimiento de los cultivos (Bayable et al., 2021; Cuevas et al., 2021; Parajuli et al., 2019).

La estabilidad de los procesos productivos depende de cierta consistencia en las condiciones ambientales. Sin embargo, las variaciones a las que nos enfrentamos actualmente, derivadas principalmente por el cambio climático, repercuten en dicha consistencia, incrementando la inestabilidad en la seguridad alimentaria y el desabasto a la par de reducir la producción y exportación, impactando directamente la economía de las naciones (Farooq et al., 2022).

Cada cultivo prospera dentro de umbrales agroambientales específicos, que en muchos casos, han sido ya ampliamente descritos con anterioridad en la literatura científica; e.g., el aguacate (Moraes García et al., 2022; Rocha-Arroyo et al., 2011) o el agave (García-Mendoza, 2002). El maíz (*Zea mays*), un cultivo de origen mexicano (Orozco-Ramírez et al., 2016), representa un caso particular al ser considerado como uno de los cultivos más importantes a nivel mundial para el abastecimiento alimenticio directo e indirecto y sus usos industriales (Revilla et al., 2022).

El maíz ha sido empleado para consumo tanto de dieta primaria como de dieta secundaria; i.e., incorporado en conjunto con otros alimentos o para forrajeo (Revilla et al., 2022). Asimismo, este cultivo se emplea en diversas actividades del sector productivo y de manufactura (Ranum et al., 2014); e.g., cervezas, jarabes, harinas, medicamentos y biocombustibles (Rausch and Belyea, 2006; Sokan-Adeaga et al., 2024; Zhang et al., 2023).

A nivel mundial, el consumo de las distintas variedades de este cultivo aporta, en promedio, el 5.3 %, el 4.6 % y 1.6 % de la ingesta calórica, proteica y grasa, respectivamente, per capita diaria (Erenstein et al., 2022). Las variedades del maíz pueden clasificarse por su tamaño, dulzor, composición del endospermo, color o tasa de maduración (Ranum et al., 2014); no obstante, comparten su respuesta a las condiciones de cultivo (Baum et al., 2019; Sánchez et al., 2014; Parent and Tardieu, 2012).

Los calendarios agrícolas proporcionan información crítica sobre cuándo se llevan a cabo las etapas de desarrollo del cultivo que conforman su fenología (Franch et al., 2022). De esta manera, se organiza el manejo agrícola tanto de la secuencia fenológica completa como de etapas particulares; e.g., la siembra o la cosecha.

A través del alza en la frecuencia de eventos climáticos extremos (Mirón et al., 2023), el incremento de la temperatura promedio del planeta (Shivanna, 2022) y los desfases en la duración de las estaciones del año (Wang, 2014), el cambio climático ha alterado la distribución espacial de las zonas de cultivo (Su et al., 2023) y los calendarios agrícolas (Franch et al., 2022).

Lo anterior impone a la agricultura un reto para garantizar la calidad y la cantidad de productos para satisfacer las necesidades alimentarias en el futuro (Mirón et al., 2023). Por otro lado, se ha observado que, para el maíz, las fechas de siembra juegan un rol determinante en la cosecha resultante (Baum et al., 2019; Bernal-Morales et al., 2025; Long et al., 2017; Mason et al., 2018; Parker et al., 2016; Sacks and Kucharik, 2011).

De acuerdo con Sánchez et al. (2014), el periodo de la siembra a la emergencia de la plántula es una de las temporadas más susceptibles de este cultivo. Por tanto, este trabajo se centra en proponer una recalendarización del periodo de siembra que garantice una baja exposición al estrés ambiental durante el ciclo de desarrollo comprendido hasta la emergencia.

Anualmente se destinan aproximadamente 200 millones de hectáreas (M ha) para la plantación de maíz, de las cuales, aproximadamente el 9 % se ubica en Europa (Erenstein et al., 2022). No obstante, a consecuencia del cambio climático, las regiones con mayor altitud y aquellas al norte de la región noroeste de Europa, en particular Alemania, tendrán un incremento en las zonas con potencial de producción agrícola del maíz (Miedaner and Juroszek, 2021).

Esta transición implica retos en tanto a la renovación de la planeación, la gestión, el desarrollo y la correcta implementación de las técnicas agrícolas relativas al manejo y cuidado del cultivo (Parent et al., 2018; Donmez et al., 2023). La identificación de periodos de siembra, bajo la transición que supone el cambio climático, continúa siendo limitada, no por desinterés sino por la tendencia a considerarlas estáticas (Parker et al., 2016), la complejidad inherente a la incertidumbre climática (Waha et al., 2011) y por falta de especificidad en la información disponible correspondiente a las fechas de plantación (Portmann et al., 2010; Sacks et al., 2010).

En este sentido, este estudio pretende robustecer la planificación de las fechas de siembra del maíz mediante la implementación de herramientas analíticas y computacionales para la toma de esta decisión, ante la necesidad de adaptar la planificación agrícola a los cambios esperados en las condiciones ambientales futuras. El estudio se focaliza en el sureste de Alemania, una región que alberga aproximadamente el 54.42 % de las 9.5 M ha de superficie empleada anualmente para la producción de los principales cultivos (Duden et al., 2024).

La expansión proyectada de su área potencial de cultivo en regiones como Alemania, la estabilidad nutricional bajo escenarios de elevadas concentraciones atmosféricas de CO_2 (Myers et al., 2014) y su papel en la seguridad alimentaria global (Tanumihardjo et al., 2020), en conjunto, consolidan al maíz como un cultivo estratégico no solo por su relevancia productiva y económica ante el cambio climático.

En consecuencia, este trabajo busca cubrir la necesidad de actualizar la planificación agronómica del periodo comprendido de la siembra a la emergencia. Determinando, mediante el análisis de datos agroclimáticos históricos, aquellas temporadas favorables para el desarrollo, mitigando el efecto del cambio climático.

2. Materiales y métodos

Bases de datos

Para integrar las condiciones ambientales que caracterizan el periodo comprendido entre la siembra y la emergencia del maíz, en este trabajo se emplean las bases de datos ráster desarrolladas por el Servicio Meteorológico Alemán (DWD, por sus siglas en alemán). Estas bases de datos son generadas mediante técnicas y modelos de interpolación previamente establecidos y se encuentran sujetas a procesos continuos de mantenimiento y control de calidad por parte del DWD.

Al contar con cobertura nacional de Alemania, alta resolución espacial, consistencia metodológica, amplia disponibilidad de datos históricos y soporte institucional, estas bases de datos constituyen fuentes de información confiables para la incorporación de registros agroclimáticos y favorecen la reproducibilidad de

los resultados.

HYRAS

El repositorio Hydrometeorologische Rasterdatensätze (HYRAS), versión v6–1, alberga las bases de datos históricos referentes a la temperatura ambiente (DWD Climate Data Center (CDC), 2025a,b,c) y la humedad relativa DWD Climate Data Center (CDC) (2025d) a nivel nacional. Empleando los registros diarios, desde 1951 a la fecha, medidos a través de 1300 estaciones climáticas distribuidas en Alemania y sus siete países vecinos (Razafimaharo et al., 2020), se genera un archivo ráster por día, con una resolución espacial de 1×1 km, a partir de la metodología de interpolación propuesta por Krähenmann et al. (2016)

Las bases de datos en HYRAS han sido sometidas a una extensa validación. A distintas escalas temporales (día, mes, año y el periodo completo de observación), se han comparado las mediciones registradas en las estaciones con los valores interpolados correspondientes a la celda más cercana así como a lo largo de los distintos niveles de elevación del terreno (Razafimaharo et al., 2020). Asimismo, de acuerdo con Razafimaharo et al. (2020), las bases de datos de este repositorio han sido comparadas con bases de datos homólogas, como el Gridded European Climate Assessment y el conjunto de datos mensuales del DWD.

Estas evaluaciones han demostrado una alta fidelidad entre las bases de datos del repositorio HYRAS y las correspondientes observaciones *in situ*. Sin embargo, la precisión de la interpolación puede disminuir en regiones con topografía compleja, particularmente para la humedad relativa, mientras que para la temperatura conserva datos altamente comparables (Razafimaharo et al., 2020).

Del repositorio HYRAS, se emplean las bases de datos de temperatura media (DWD Climate Data Center (CDC), 2025b) y humedad relativa (DWD Climate Data Center (CDC), 2025d) a lo largo de este trabajo al ser variables ambientales que participan durante el periodo fenológico comprendido entre la siembra y la emergencia del maíz.

Además, las características como el formato ráster, la rigurosidad metodológica, el control de calidad en los datos y la resolución espacial, permiten una representación homogénea de las condiciones ambientales en el espacio y el tiempo que resulta adecuada para análisis agrícolas a escala regional al reducir las inconsistencias asociadas con los registros de estaciones individuales.

Ráster diarios de la temperatura del suelo a una profundidad de 5 cm

El modelo AMBETI es una herramienta multipropósito diseñada para simular las interacciones suelo-planta-atmósfera, incluyendo el transporte de vapor de agua y agua líquida a través del suelo, así como los flujos netos de radiación en las superficies de la planta y del suelo (Braden, 1995). Específicamente, la componente de termodinámica del suelo es utilizado por el DWD para estimar la temperatura diaria del suelo a una profundidad de 5 cm desde 1991, dando lugar a este conjunto de datos.

A partir de la interpolación de mediciones *in situ* provenientes de aproximadamente 280 estaciones distribuidas en Alemania, se generan archivos ráster ASCII diarios con resolución de 1×1 km. La temperatura del suelo se estima inicialmente en las estaciones meteorológicas mediante el modelo AMBETI y posteriormente se interpola mediante una regresión lineal múltiple regional basada en la longitud, latitud y elevación, seguida de una triangulación para generar datos espaciales continuos sobre Alemania (DWD Climate Data Center (CDC), 2025e).

De acuerdo con DWD Climate Data Center (CDC) (2025e), las interpolaciones resultantes son físicamente factibles dado que la temperatura del suelo está determinada principalmente por la temperatura atmosférica y la radiación solar incidente, como señalan Baumberger et al. (2024). En consecuencia, la temperatura del suelo tiende a presentar una baja variabilidad (DWD Climate Data Center (CDC), 2025e).

Lo anterior sustenta la validez metodológica de la interpolación en conjuntos de datos en formato de ráster (Schloeder et al., 2001). Por lo tanto, el procedimiento de interpolación proporciona estimaciones espaciales confiables en Alemania, siendo la principal fuente de incertidumbre durante el invierno la distribución espacial heterogénea de la cobertura de nieve (DWD Climate Data Center (CDC), 2025e).

Para el desarrollo de este trabajo, se seleccionó esta base de datos debido a que representa de manera cercana el ambiente térmico experimentado por las semillas de maíz durante el periodo comprendido entre la siembra y la emergencia. Asimismo, su disponibilidad diaria, cobertura nacional, resolución espacial y metodología de estimación basada en principios físicos robustece la representación de las condiciones ambientales que influyen en el periodo de siembra a emergencia de la secuencia fenológica.

Ráster diarios de la humedad del suelo para el maíz en Alemania

La base de datos de humedad del suelo para el cultivo de maíz fue generado mediante el modelo Agrarmeteorologische Berechnung der Aktuellen Verdunstung (AMBAV) 2.0, versión 1.5, un modelo agrohidrológico basado en principios físicos que simula la dinámica del agua en el suelo dentro del sistema suelo-planta (DWD Climate Data Center (CDC), 2024). Como describen Herbst et al. (2021), se modela el almacenamiento de agua en el suelo considerando el consumo hídrico del cultivo, obteniendo una caracterización específica de la dinámica de la humedad del suelo para cada cultivo.

Las mediciones *in situ*s de variables meteorológicas, incluyendo la temperatura del aire, humedad relativa, radiación de onda corta y onda larga, precipitación y velocidad del viento, obtenidas de las estaciones del DWD cada hora, se utilizan para la interpolación espacial y la posterior estimación de la disponibilidad de agua en el suelo (Herbst et al., 2021).

El balance hídrico del suelo se parametriza mediante perfiles específicos para cada cultivo, que incorporan factores como la demanda hídrica del cultivo, el desarrollo radicular y la dinámica de extracción de agua, permitiendo derivar el contenido de agua disponible para las plantas en cada cultivo (Herbst et al., 2021); en este caso, el maíz.

A partir de 1991, el conjunto de datos resultante proporciona archivos ráster diarios que cubren Alemania con una resolución espacial de 1×1 km, los cuales contienen estimaciones de humedad del suelo específicas para cada cultivo, expresadas como porcentaje de la Capacidad de Campo Disponible (AFC, por sus siglas en inglés) (DWD Climate Data Center (CDC), 2024), que indica la proporción de agua disponible para las plantas en el suelo (Deutscher Wetterdienst (DWD), 2024).

La base de datos contiene perfiles verticales del agua en el suelo mediante capas de 10 cm de espesor desde la superficie hasta una profundidad de 2 m, además de capas agregadas que representan la disponibilidad acumulada de agua dentro de los perfiles de suelo de 0-30, 0-60 y 0-90 cm (DWD Climate Data Center (CDC), 2024).

Para este trabajo, se seleccionó la capa de humedad del suelo de 0-10 cm, la zona del suelo donde se deposita la semilla de maíz, inicia la imbibición y ocurre el desarrollo radicular temprano. Considerando la cobertura territorial, resolución espacial, disponibilidad de datos y metodología de interpolación, esta base de datos proporciona una representación confiable de la disponibilidad de agua en el suelo durante las primeras etapas del cultivo, consolidando el conjunto de las condiciones ambientales que influyen en el periodo comprendido entre la siembra y la emergencia del maíz.

Datos ambientales

De las variables disponibles en los bases de datos del DWD descritos anteriormente, se seleccionó un subconjunto de acuerdo con sus interacciones durante el periodo comprendido entre la siembra y la emergencia del maíz, considerando los requerimientos meteorológicos, hídricos y térmicos. Aunque las extensiones temporales de los conjuntos de datos se remontan a fechas anteriores a 1996, en este estudio únicamente

se consideró el periodo común comprendido entre 1996 y 2025. Las variables extraídas de cada conjunto de datos, junto con sus respectivas características, se resumen en la Tabla 1.

Variable ambiental	**Unidad de medida**	**Base de datos**	**Frecuencia de registro**	**Periodo de estudio**
Temperatura ambiental media	°C	HYRAS	Diaria	1996–2025
Humedad relativa ambiental media	%			
Temperatura media en el suelo (5 cm profundidad)*	°C	Ráster diarios de la temperatura del suelo a una profundidad de 5 cm		
Humedad media en el suelo (0–10 cm profundidad)	% AFC	Ráster diarios de la humedad del suelo para el maíz en Alemania		

Tabla 1: Variables ambientales utilizadas en este trabajo, incluyendo sus unidades de medida, bases de datos de procedencia, frecuencia de registro y periodo de estudio. *Los valores originales deben dividirse entre diez para obtener la unidad correcta de °C (DWD Climate Data Center (CDC), 2025e).

Requerimientos ambientales

El periodo de la secuencia fenológica del maíz que comprende desde la siembra de la semilla hasta la emergencia de la plántula, cuando se desarrolla exitosamente, tiene una duración de 16.6 ± 3.1 días (Chmielewski et al., 2004). Durante esta etapa, el cultivo es altamente susceptible a las condiciones del entorno (Sánchez et al., 2014), motivo por el cual los requerimientos ambientales han sido descritos en la literatura previa.

Considerando los datos ráster disponibles descritos previamente (ver Tabla 1) y tras una revisión bibliográfica, se recopilaron los valores y rangos de condiciones ambientales sugeridos como favorables para el desarrollo de la semilla y la emergencia de la plántula. Estos valores se emplearon como referencia para establecer las condiciones ambientales evaluadas en el modelo y se resumen en la Tabla 2.

Variable ambiental	**Referencia**	**Valor sugerido**	**Intervalo usado en este trabajo**
Temperatura	Birch et al. (1998)	8 °C	11.10 ± 2.5116
	Coffman (1923)	10 °C	
	Grubben and Partohardjono (1997)	10 °C	
	Kiniry et al. (1995)	12.8 °C	
	Pan et al. (1999)	10 °C	
	Vâtcă et al. (2021)	15 °C	
	Waha et al. (2011)	14 °C	
	Warrington and Kanemasu (1983)	9 °C	
Humedad relativa	Martin and Thrailkill (1993)	80 – 90 %	65 – 85 %
	Peter et al. (2009)	60 – 70 %	
Temperatura en el suelo	Busschaert et al. (2026)	8 – 10 °C	8 – 10 °C
	Domokos et al. (2024)	10 °C	
	Vâtcă et al. (2021)	8 – 10 °C	
Humedad en el suelo	Mo et al. (2020)	84 – 90 %	80 – 90 %
	Peichl et al. (2018)	80 – 90 %	

Tabla 2: Condiciones ambientales sugeridas durante el periodo fenológico comprendido de la siembra a la emergencia del maíz reportadas en la literatura y los correspondientes intervalos de valores usados durante el desarrollo de este trabajo.

Modelo

Históricamente, muchas de las prácticas agrícolas se consolidaron mediante procesos empíricos de observación y ajuste progresivo en los cuales, a través de ensayo y error, se identificaban los periodos más favorables; por ejemplo, para la siembra (National Research Council, 1996). En el contexto actual, este tipo de decisiones debe replantearse dado que las condiciones en las que fueron tomadas se han alterado por la incertidumbre y la variabilidad asociadas al cambio climático.

Al estructurar la progresión del tiempo como un proceso cíclico se emula la periodicidad inherente a la naturaleza con mayor fidelidad (Chuine and Régnière, 2017; Gatto and Jammalamadaka, 2015; Gurney et al., 1992; Mardia and Jupp, 1999; Powell and Logan, 2005; Régnière and Powell, 2013). De esta manera, por convención, definamos

$$D_{366} \coloneqq D_1, \tag{1}$$
$$D_{367} \coloneqq D_2, \tag{2}$$
$$\vdots$$
$$D_j \coloneqq D_{j \text{ mód } 365}, \tag{3}$$

para toda $j \in \mathbb{N}$ tal que $j > 365$.

Con lo anterior, es posible dotar de una estructura cíclica a la progresión del año dado que al finalizar un año inmediatamente comienza el siguiente de manera que la observación del proceso de siembra puede observarse de manera continua en todo punto del año.

De esta manera, supongamos que una semilla de maíz será sembrada en campo abierto. Si tal semilla no es viable, entonces se concluye el proceso de siembra como fallido desde el inicio. En otro caso, si dicha semilla es viable y se siembra el día D_i, para alguna $i \in \{1, 2, 3, \ldots, 365\}$ el proceso puede concluir con la emergencia o con el fracaso al día D_j, para alguna $j \geq i$, tal que j mód $365 \in \{1, 2, 3, \ldots, 365\}$.

Sea $n^* \in \mathbb{N}$ el número de días necesarios para que una semilla viable de maíz logre la emergencia desde su siembra. Como se busca determinar los periodos en donde las condiciones agroambientales favorezcan un sano desarrollo de la semilla, reduciendo la exposición al estrés del entorno entonces se desea hallar al conjunto de días D_i tales que una semilla sembrada en dicha fecha emerja al día D_{i+n^*} con una probabilidad *suficientemente grande*.

Sea $X = \{X_t\}_{t \in \mathbb{N}}$ un proceso estocástico a tiempo discreto con espacio de estados $S = \{D_1, D_2, \ldots, D_{365}, F\}$, donde la variable aleatoria X_t representa el estado del proceso al t-ésimo día transcurrido desde la siembra. El estado F indica el fracaso del proceso de siembra atribuido a condiciones agroambientales adversas que detienen de manera irreversible el desarrollo de la semilla previo a la emergencia de la plántula.

Por otra parte, para cada $i \in \{1, 2, \ldots, 365\}$, el estado D_i denota el i-ésimo día del año calendario. Cuando el proceso X se encuentra en alguno de los estados D_i, se interpreta que, en dicho día, la semilla continúa su desarrollo de manera adecuada, es decir, el proceso aún no ha sido absorbido por el estado F.

De esta manera, dado dos estados $i, j \in S$, $i \neq j$ si $P_{i,j}$ denota la probabilidad de partir del estado i para transicionar al estado j, en un paso, entonces

$$P_{i,j} \coloneqq P(X_{t+1} = j \mid X_t = i) = \begin{cases} \lambda_k, \text{ si } i = D_k \text{ y } j = D_{k+1}, k \in \{1, 2, \ldots, 365\}. \\ 1 - \lambda_k, \text{ si } i = D_k, k \in \{1, 2, \ldots, 365\}, \text{ y } j = F. \\ 1, \text{ si } i = F \text{ y } j = F. \\ 0, \text{ en otro caso.} \end{cases} \tag{4}$$

Donde, para cada $k \in \{1, 2, \ldots, 365\}$,

$$\lambda_k = 1 - \frac{d(C_{H,k}\,, C^*)}{\max\limits_{l \in \{1,\ldots,365\}} \{d(C_{H,l}\,, C^*)\}}, \tag{5}$$

con $d(\cdot,\cdot)$ la distancia Euclidiana o la distancia Manhattan.

Además, $C_{H,k}$ denota el centroide de las condiciones agroambientales históricas registradas el k-ésimo día del año descritas en la Tabla 1. Asimismo, C^* denota el centroide de la región de condiciones agroambientales sugeridas durante un desarrollo del cultivo, las cuales se indican en la Tabla 2.

De esta manera, para toda $k \in \{1, 2, \ldots, 365\}$, se garantiza que $\lambda_k \in [0, 1]$ y, simultáneamente, tanto $C_{H,k}$ como C^* se interpretan como elementos en $\mathbb{R}^4$, donde cada componente corresponde a una variable agroambiental específica ver Fig. 1.

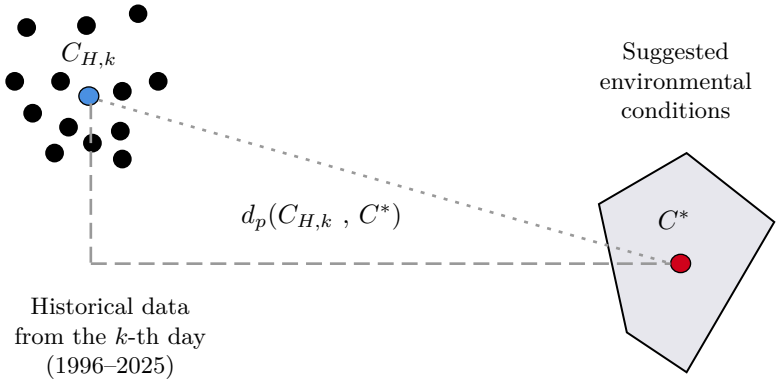

Figura 1: Distancia entre las condiciones agroclimáticas para el desarrollo óptimo del maíz y las condiciones agroclimáticas históricamente reportadas para el k-ésimo día del año, $k \in \{1, 2, \ldots, 365\}$. Los círculos en color negro representan los datos agroclimáticos reportados anualmente para el k-ésimo día del año mientras que el polígono sombreado en color gris representa la región de parámetros agroclimáticos, ideales para el desarrollo del maíz. Los círculos de color azul y rojo indican los centroides de los datos históricos ($C_{H,k}$) y la región óptima (C^*), respectivamente. Por último, en color gris se representa la distancia entre $C_{H,k}$ y C^*, calculada mediante la distancia Euclidiana, $p = 2$, y la distancia Manhattan, $p = 1$, representadas por una línea punteada y segmentos de línea discontinua, respectivamente.

Para ilustrar lo discutido en la Ecuación (4), se tiene la matriz estocástica $A \in \mathcal{M}_{366\times366}(\mathbb{R})$, ver Ecuación (6). Asimismo se construyó un diagrama de transición en donde se muestra tanto la estructura cíclica como proceso estocástico que subyacen en la modelación del problema, ver Fig. 2.

$$A = \begin{array}{c} \\ D_1 \\ D_2 \\ \vdots \\ D_{364} \\ D_{365} \\ F \end{array} \begin{array}{c} \begin{array}{ccccccccc} D_1 & D_2 & D_3 & D_4 & \cdots & D_{364} & D_{365} & F \end{array} \\ \begin{bmatrix} 0 & \lambda_1 & 0 & 0 & \cdots & 0 & 0 & 1-\lambda_1 \\ 0 & 0 & \lambda_2 & 0 & \cdots & 0 & 0 & 1-\lambda_2 \\ & & & & \ddots & & & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 0 & \lambda_{364} & 1-\lambda_{364} \\ \lambda_{365} & 0 & 0 & 0 & \cdots & 0 & 0 & 1-\lambda_{365} \\ 0 & 0 & 0 & 0 & \cdots & 0 & 0 & 1 \end{bmatrix} \end{array}. \tag{6}$$

Sea

$$\tau_F \coloneqq \inf_{t \in \mathbb{N}} \{X_t = F\} \tag{7}$$

el primer día en el que proceso de siembra falla. Así, propondremos al i-ésimo del año como candidato para

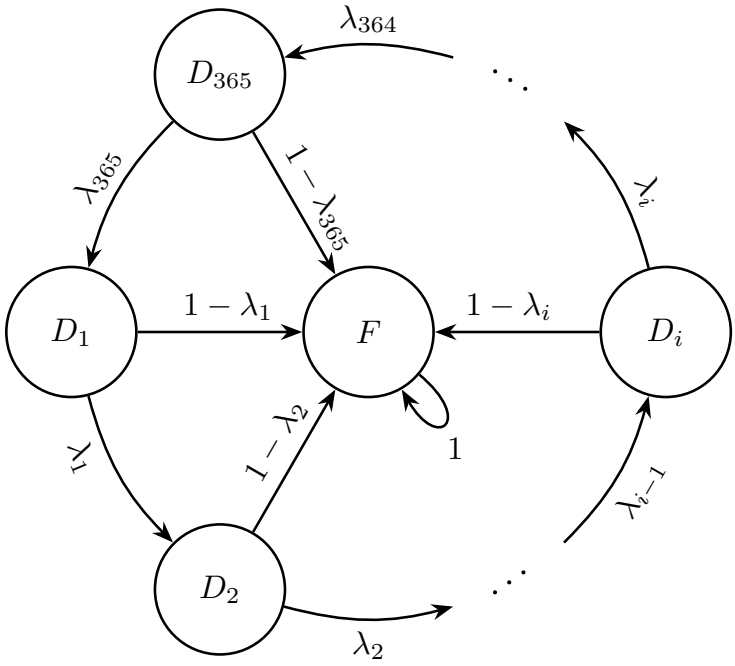

Figura 2: Diagrama de transición diaria de la factibilidad de siembra. El estado F indica el fracaso del proceso de siembra, mientras que los estados D_i, $i \in \{1, 2, \ldots, 365\}$, denotan el i-ésimo día del año calendario. Cuando el proceso X se encuentra en un estado D_i, se interpreta que, en dicho día, la semilla continúa su desarrollo de manera adecuada, es decir, que el proceso no ha sido absorbido por el estado F como consecuencia de las condiciones agroambientales del entorno. Para cada i, λ_i denota la probabilidad de transición de D_i a D_{i+1}, y $1 - \lambda_i$ la probabilidad de transición de D_i a F.

la siembra de maíz en Alemania si

$$P_i(\tau_F > n^*) \coloneqq P(\tau_F > n^* \mid X_0 = D_i) \geq \zeta^*, \tag{8}$$

para algún $\zeta^* \in [0, 1]$. Es decir, bajo el esquema de trabajo anterior, se sugiere al i-ésimo día siempre que la emergencia de la semilla ocurra antes del fracaso del proceso. Con este criterio general, se plantean cuatro enfoques para evaluar la relación temporal entre ambos eventos y, en consecuencia, determinar la aptitud diaria para la siembra.

Modelo: Criterio Markoviano de permanencia

Las cadenas de Markov permiten modelar procesos cuya dinámica depende exclusivamente del estado inmediatamente anterior, sin considerar la trayectoria histórica previa del proceso. Al interpretar la Figura 2 como un diagrama de transición asociado a una cadena de Markov, la probabilidad indicada en la Ecuación (8) se calcula de la manera siguiente.

$$P_i(\tau_F > n^*) = \prod_{t=0}^{n^*-1} \lambda_{(i+t) \text{ mód } 365}. \tag{9}$$

Modelo: Criterio de disponibilidad de tiempo

Al tener estados absorbentes, el análisis de las cadenas de Markov admite una alternativa a través de la teoría de cadenas de Markov absorbentes. Dado que, al partir del estado de fallo, la probabilidad de permanecer en tal estado es uno, la cadena de Markov propuesta es, en efecto, una cadena de Markov absorbente.

Empleando las herramientas discutidas por Grinstead and Snell (2003, Capítulo 11) y Kemeny and Snell (1976, Capítulo 3) se obtiene que, al menos, el $\left(1 - \frac{1}{\kappa^2}\right) 100\,\%$ de las realizaciones que parten del estado D_i, $i \in 1, 2, \ldots, 365$, presentan una duración comprendida en el intervalo

$$(\mu_i - \kappa\sigma_i \,, \mu_i + \kappa\sigma_i)$$

antes de ser absorbidas por el estado F.

De esta forma, para cada $i \in 1, 2, \ldots, 365$, se sugiere que la siembra se realice el i-ésimo día del año si

$$n^* < \mu_i - \kappa\sigma_i, \tag{10}$$

donde μ_i denota la i-ésima entrada del vector $\mathbf{N1}$, σ_i indica la raíz cuadrada de la i-ésima entrada del vector $(2\mathbf{N} - I_{365})\mu - \mu_{sq}$ y $\kappa \in \mathbb{R}$ el parámetro de la desigualdad de Chebyshev.

Asimismo, $\mathbf{N} \in \mathcal{M}_{365\times365}(\mathbb{R})$ es la matriz fundamental asociada a la cadena de Markov, $\mathbf{1} \in \mathbb{R}^{365}$ es el vector $\mathbf{1} = (1, 1, \ldots, 1)^T$, $I_{365} \in \mathcal{M}_{365\times365}(\mathbb{R})$ denota la matriz identidad y $\mu_{sq} \in \mathbb{R}^{365}$ se define por $\mu_{sq} = (\mu_1^2, \mu_2^2, \ldots, \mu_{365}^2)^T$.

Modelo: Criterio de alcanzabilidad fenológica eventual

Adicionalmente, la teoría de cadenas de Markov absorbentes permite analizar la alcanzabilidad de estados específicos a lo largo de las trayectorias; i.e., determinar la probabilidad de que, eventualmente, una trayectoria alcance un estado determinado.

Aludiendo al trabajo de Kemeny and Snell (1976, Capítulo 3) se tiene que al partir del estado D_i, $i \in \{1, 2, \ldots, 365\}$, la probabilidad de visitar eventualmente el estado $D_{(i+n^*) \text{ mód } 365}$ está dada por la entrada $h_{i,(i+n^*) \text{ mód } 365}$ de la matriz $H \in \mathcal{M}_{365}(\mathbb{R})$ definida por

$$H = (\mathbf{N} - I_{365})(N_{dg})^{-1},$$

donde $I_{365} \in \mathcal{M}_{365\times365}(\mathbb{R})$ denota la matriz identidad y $N_{dg} \in \mathcal{M}_{t\times t}(\mathbb{R})$ es la matriz diagonal con la misma diagonal que la matriz fundamental $\mathbf{N}$.

De esta manera, para cada $i \in \{1, 2, \ldots, 365\}$, se sugiere realizar la siembra en el i-ésimo día del año si

$$h_{i,(i+n^*) \text{ mód } 365} \geq \zeta^*, \tag{11}$$

para algún $\zeta^* \in [0, 1]$. Es decir, si la probabilidad de que el cultivo eventualmente complete la etapa fenológica hasta la emergencia es suficientemente alta.

Modelo: Criterio empírico de permanencia

Al considerar la Figura 2 como un gráfica dirigida cuyos pesos son probabilidades, podemos emplear una metodología similar a la discutida en el trabajo de de Anda-Jauregui and Hernandez-Lemus (2021). Así, al permitir que caminatas aleatorias recorran la gráfica es posible estimar el valor de $P_i(\tau_F > n^*)$ a través de estudiar sus trayectorias y longitudes.

Con este enfoque, las caminatas aleatorias se inicializan en cada uno de los vértices. En particular, para cada $i \in \{1, 2, \ldots, 365\}$, se inicializa una caminata aleatoria que parte del vértice D_i y cuya trayectoria llega, por lo menos, al vértice $D_{(i+n^*) \text{ mód } 365}$, o bien, llega al vértice F sin haber visitado el vértice $D_{(i+n^*) \text{ mód } 365}$. Por repetir el proceso anterior $r^* \in \mathbb{N}$ veces para cada vértice, se propone a

$$\widehat{P}_i(\tau_F > n^*) \coloneqq \frac{|W(D_i, D_{(i+n^*) \text{ mód } 365})|}{r^*}, \tag{12}$$

como estimador de $P_i(\tau_F > n^*)$, donde $W(D_i, D_{(i+n^*) \text{ mód } 365})$ denota el conjunto de caminatas aleatorias que comienzan en el vértice D_i y, por lo menos, visitan el vértice $D_{(i+n^*) \text{ mód } 365}$ y $|\cdot|$ indica el operador de cardinalidad en conjuntos.

Más aún, derivado del gran número de repeticiones es posible generar intervalos del $(1-\alpha)100\,\%$ de confianza para cada uno de los vértices D_i empleando los métodos de bootstrap y jacknife (Ramachandran and Tsokos, 2009, Capítulo 13).

Finalmente, tras la revisión bibliográfica realizada, se asignan valores numéricos a los parámetros empleados de manera abstracta en el modelo probabilístico propuesto. Los valores correspondientes se presentan en la Tabla 3.

Parámetro	**Descripción**	**Valor**	**Fuente**
n^*	Número de días requeridos para que una semilla viable alcance la emergencia desde la siembra.	16.6 ± 3.1	Chmielewski et al. (2004).
ζ^*	Umbral mínimo de probabilidad para considerar viable una fecha de siembra.	0.8	Food and Agriculture Organization of the United Nations (2011, p. 57).
r^*	Número de repeticiones de caminatas aleatorias para estimación empírica.	500	de Anda-Jauregui and Hernandez-Lemus (2021).
C^*	Centroide de la región de condiciones agroambientales óptimas para el desarrollo del cultivo.	$(11.10, 75, 9, 85)$	Ver Tabla 2.
$C_{H,k}$	Centroide de las condiciones agroambientales históricas observadas en el día k del año.	N/A.	Ver Tabla 1.
$d(\cdot,\cdot)$	Métrica de distancia en el espacio de variables agroambientales.	Euclidiana Manhattan	N/A.
α	Nivel de significancia para la construcción de intervalos de confianza.	0.05	N/A
κ	Parámetro en la desigualdad de Chebyshev.	4.47	da Silva et al. (2019).

Tabla 3: Parámetros empleados en la metodología probabilística para la estimación de fechas favorables de siembra.

3. Resultados

Con el objetivo de cubrir una región de interés agrícola, el análisis se centró en los estados federados de Baviera, Brandemburgo y Sajonia, los cuales, de manera conjunta, albergan 5.17 M ha de superficie destinada para la agricultura (Flores et al., 2025). Esta área representa aproximadamente el 54.42 % de las 9.5 M ha de superficie empleada anualmente para los principales cultivos que se producen en Alemania (Duden et al., 2024).

Para cada uno de los estados mencionados se replicó, de manera independiente, el criterio empírico de permanencia antes descrito para generar los correspondientes calendarios agrícolas regionalizados para la siembra de maíz en Alemania. Para ello, se consideraron exclusivamente los valores registrados diariamente dentro de las celdas contenidas en sus respectivas fronteras geográficas, ver Figura 3.

Para integrar los efectos del cambio climático se consideró un periodo de 30 años de duración, un tiempo estándar en el área (Hennemuth et al., 2013). Por tanto se contemplaron los datos históricos desde 1996 hasta 2025. Para cada variable considerada y para cada día del año, se calculó el promedio de los valores reportados en las celdas contenidas en el estado correspondiente.

De esta manera, se obtienen mediciones históricas representativas de las condiciones medias locales, ver Figura 1, las cuales son utilizadas para determinar las probabilidades de transición del modelo a través de la Ecuación (5).

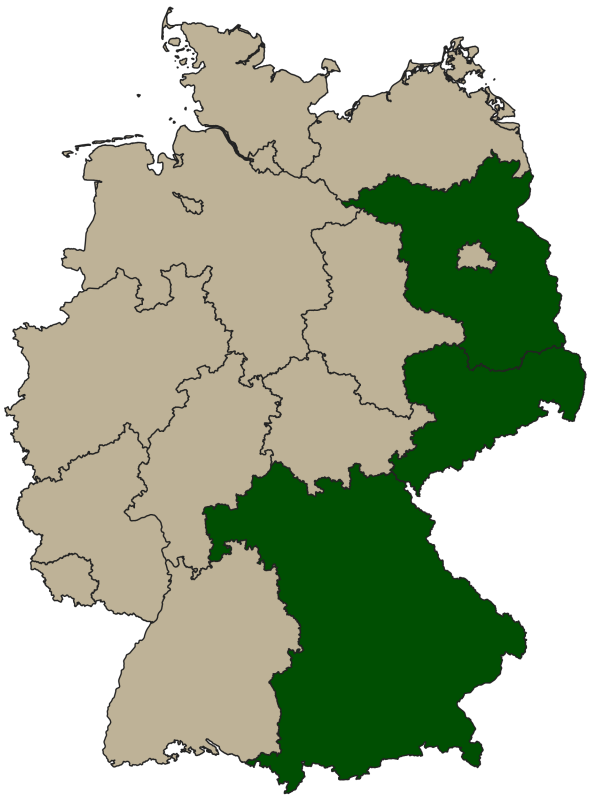

Figura 3: Distribución de las estaciones climáticas respecto a los estados federados de Alemania. Los polígonos delimitados por un contorno en color negro corresponden a los estados federados reportados por Bundesamt für Kartographie und Geodäsie Bundesamt für Kartographie und Geodäsie (2025). En color verde se muestran, de manera descendente, Brandemburgo, Sajonia y Baviera, respectivamente.

Al aplicar lo anterior, para cada estado considerado, se construyen los diagramas de transición asociados

a las cadenas de Markov, ver Figura 2. Al tomar las probabilidades de transición como pesos que modulan la aptitud para la siembra diaria, se tienen gráficas dirigida con pesos, ver Figuras 4, 5 y 6.

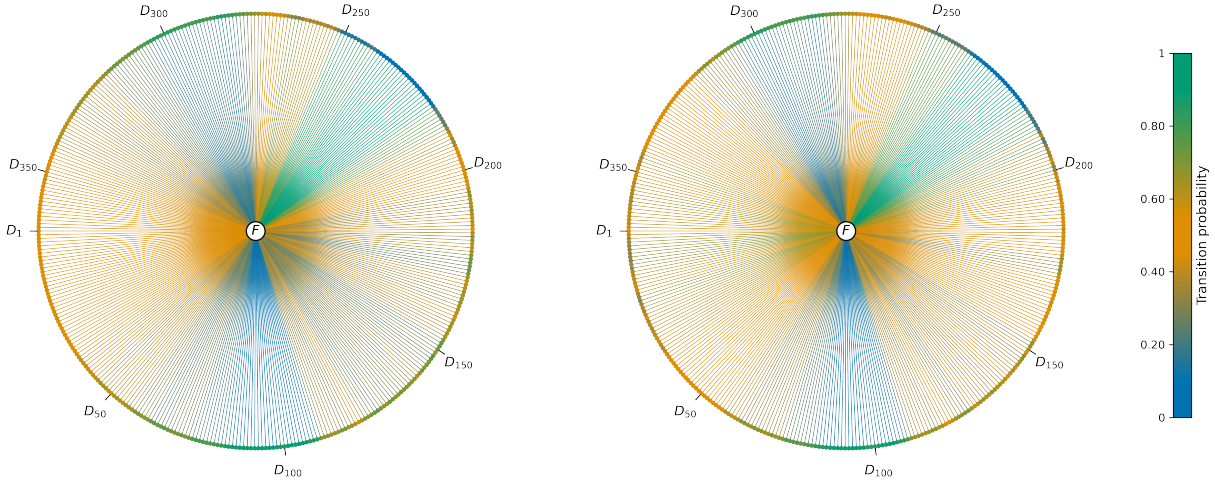

(a) (b)

Figura 4: Aptitud diaria para la siembra en Brandenburgo, expresada como la probabilidad de transición λ_k, $k \in \{1, 2, \ldots, 365\}$, calculada mediante las distancias Euclidiana y Manhattan. La figura 4a muestra los valores de λ_k calculados mediante la distancia Euclidiana, mientras que la figura 4b muestra los valores correspondientes calculados mediante la distancia Manhattan. La progresión del año se expresa en sentido contrario a las manecillas del reloj; en el exterior de la gráfica anular se indican los meses, mientras que en su interior se indican los días del año.

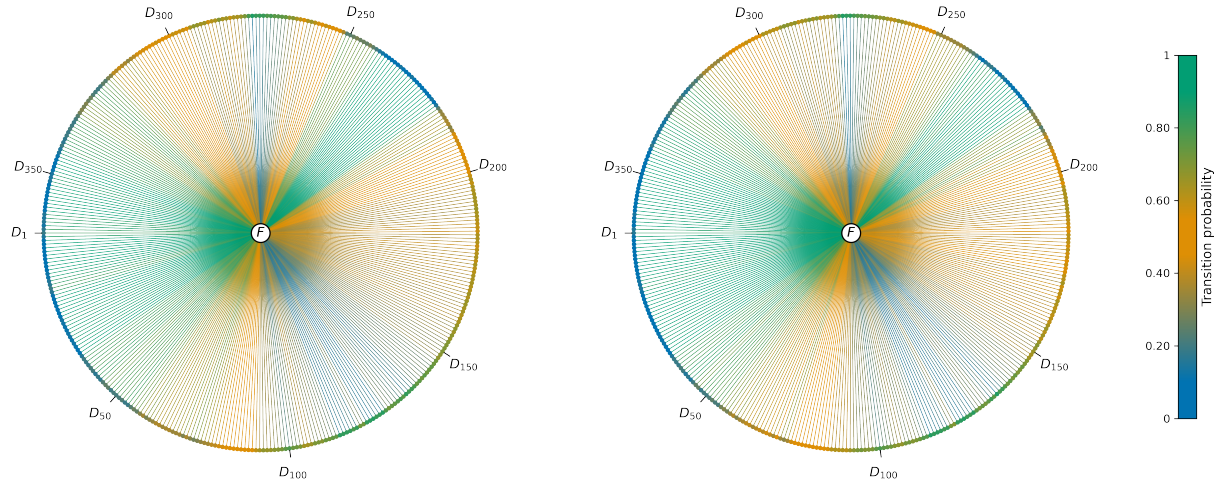

(a) (b)

Figura 5: Aptitud diaria para la siembra en Sajonia, expresada como la probabilidad de transición λ_k, $k \in \{1, 2, \ldots, 365\}$, calculada mediante las distancias Euclidiana y Manhattan. La figura 5a muestra los valores de λ_k calculados mediante la distancia Euclidiana, mientras que la figura 5b muestra los valores correspondientes calculados mediante la distancia Manhattan. La progresión del año se expresa en sentido contrario a las manecillas del reloj; en el exterior de la gráfica anular se indican los meses, mientras que en su interior se indican los días del año.

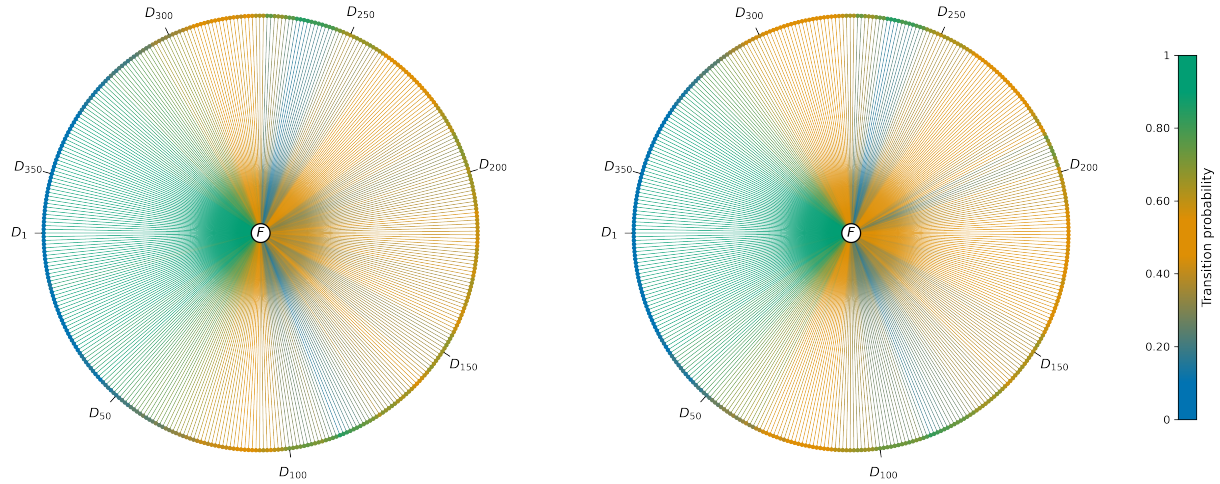

(a) (b)

Figura 6: Aptitud diaria para la siembra en Baviera, expresada como la probabilidad de transición λ_k, $k \in \{1, 2, \ldots, 365\}$, calculada mediante las distancias Euclidiana y Manhattan. La figura 6a muestra los valores de λ_k calculados mediante la distancia Euclidiana, mientras que la figura 6b muestra los valores correspondientes calculados mediante la distancia Manhattan. La progresión del año se expresa en sentido contrario a las manecillas del reloj; en el exterior de la gráfica anular se indican los meses, mientras que en su interior se indican los días del año.

Al aplicar el criterio empírico de permanencia descrito en la Sección 2 a las gráficas dirigidas correspondientes a cada estado, se obtuvieron calendarios de siembra de maíz para cada una de las distancias consideradas. A partir de los parámetros establecidos previamente, se identificaron los periodos regionales de siembra en cada región, los cuales se presentan en las Figuras 7, 8 y 9.

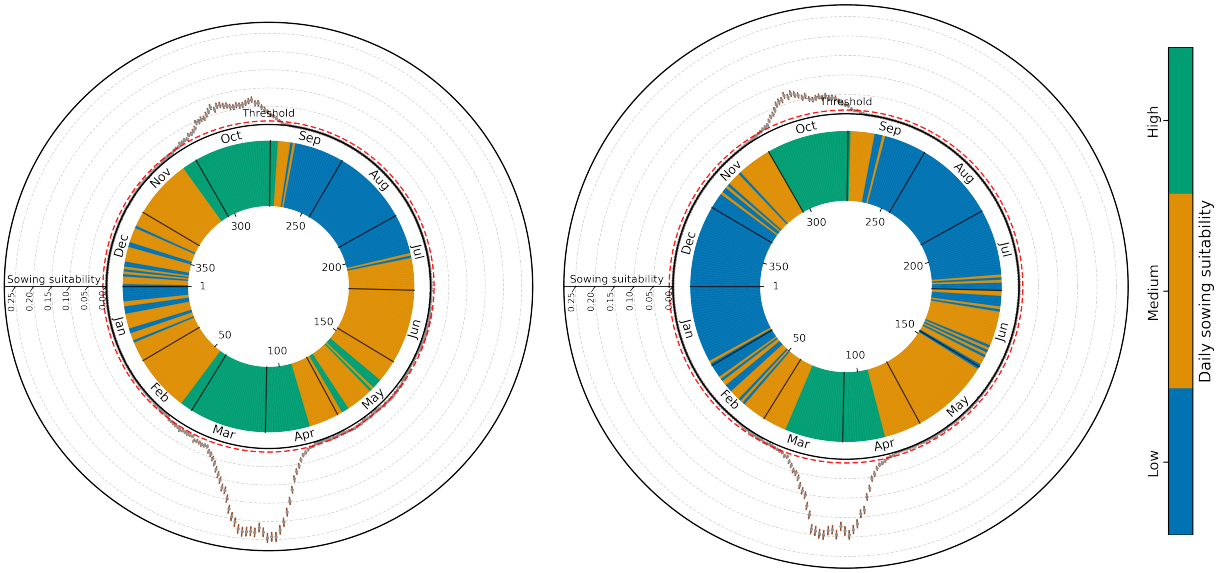

(a) (b)

Figura 7: Periodos de siembra identificados para Brandenburgo. Las figuras 7a y 7b muestran los periodos resultantes para la distancia Euclidiana y Manhattan, respectivamente. Los intervalos del 95 % de confianza para la probabilidad de aptitud calculados por bootstrap y jackknife se muestran en color café y gris, respetivamente. Los días con aptitud baja se muestran en azul, aquellos con aptitud media en amarillo y los de aptitud alta en verde.

Para cada una de las distancias consideradas, los periodos de siembra identificados se presentan en la Tabla 4. Las predicciones obtenidas mediante una única aplicación directa del criterio empírico de permanencia se identifican como Raw prediction. Por su parte, CI prediction corresponde al conjunto de días del año cuyos intervalos de confianza, estimados mediante bootstrap o jackknife a partir de 5000 réplicas por día, contienen el umbral de aptitud 0.7^{13} o se sitúan por encima de este. Finalmente, como referencia temporal, los resultados se presentan por separado para cada semestre del año.

Para robustecer nuestro trabajo se realizaron las siguientes comparaciones, ver Figura 10, 11, 12 y 13. Por una parte, con base en los trabajos de Parker et al. (2016) y Flores et al. (2025), se consideraron los periodos de siembra de maíz registrados *in situ* en Alemania, diferenciados según criterios geográficos de altitud, latitud y longitud, ver Tabla 10. Por otra parte, a partir del trabajo de (Parent et al., 2018, Fig. S12A), se consideraron los periodos de siembra históricos registrados para Europa durante 1975–2010, así como los periodos simulados para 2050 bajo los escenarios de trayectoria de concentración representativa (RCP, por sus siglas en inglés) 4.5 y 8.5, que proyectan concentraciones atmosféricas de CO_2 de 487 y 541 ppm, respectivamente.

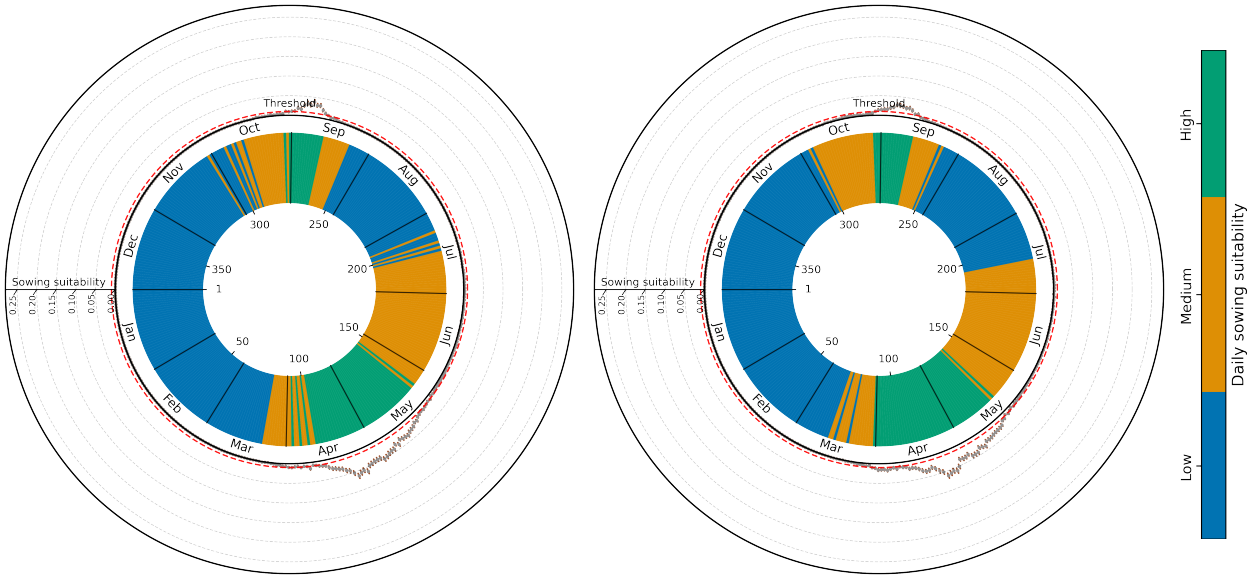

(a) (b)

Figura 8: Calendario de los periodos de siembra identificados para Sajonia mediante las distancias Euclidiana y Manhattan. Las figuras 8a y 8b muestran los periodos resultantes para cada distancia, respectivamente.

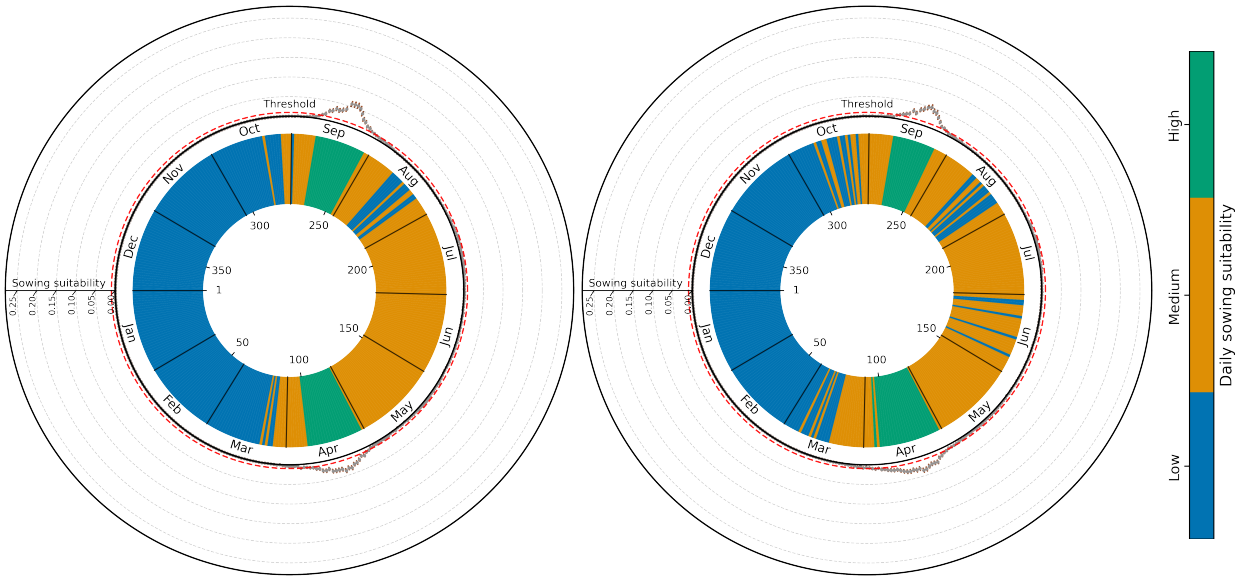

(a) (b)

Figura 9: Calendario de los periodos de siembra identificados para Baviera mediante las distancias Euclidiana y Manhattan. Las figuras 9a y 9b muestran los periodos resultantes para cada distancia, respectivamente.

Brandenburg				
Semester	**Sowing windows**			
	Euclidean		**Manhattan**	
	Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	55–108, 123–125, 137, 139–142	55–108, 115, 117, 121–127, 130–131, 135–147	69–106	64–65, 67–107
2	271–310	271–310, 312, 314	273–304	271–305

Saxony				
Semester	**Sowing windows**			
	Euclidean		**Manhattan**	
	Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	93, 96, 99, 102–143, 145	90, 92–145, 147	90–137, 139	90–140, 142
2	262–274, 276	260, 262–276	262–276	261–276

Bavaria				
Semester	**Sowing windows**			
	Euclidean		**Manhattan**	
	Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	99–119	96–119	95, 97–119	91, 93–122
2	246–264	245–265	249–264	248–265

Tabla 4: Periodos de siembra regionales obtenidos. Días del año identificados como adecuados para la siembra de maíz en Brandemburgo, Sajonia y Baviera mediante las distancias Euclidiana y Manhattan, respectivamente. Se presentan las predicciones obtenidas mediante la aplicación directa del criterio empírico de permanencia (Raw prediction), así como aquellas correspondientes a los días cuyos intervalos de confianza, estimados mediante bootstrap o jackknife, contienen el umbral de aptitud o se sitúan por encima de este (CI prediction). Los resultados se agrupan según el semestre del año.

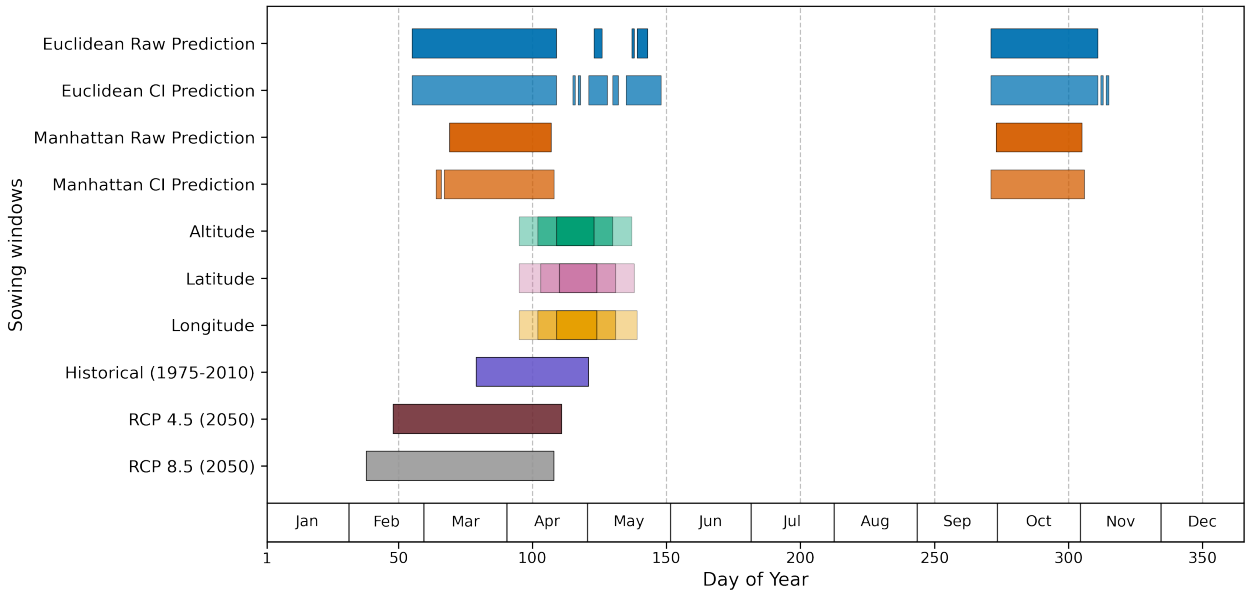

Figura 10: Comparaciones para Brandemburgo. Los periodos de siembra de maíz determinados empleando la distancia Euclideana se muestran en color azul mientras que los determinados empleando la distancia Manhattan se muestran en color anaranjado. Los periodos correspondientes a la Raw prediction se muestran opacos mientras que aquellos correspondientes a la CI prediction se muestran con transparencia. Los periodos de siembra de maíz en Alemania que se desprenden de los trabajos de (Parker et al., 2016) y (Flores et al., 2025), ver Tabla 10, se muestran en color verde, rosa y amarillo para la altitud, latitud y longitud, respectivamente. Los distintos niveles de transparencia ilustran las fechas comprendidas en el intervalo de semiancho una a tres desviaciones estándar respecto a la media de la muestra. Finalmente, los periodos de siembra de maíz en Europa correspondientes al periodo histórico (1975–2010) y a las proyecciones bajo los escenarios RCP 4.5 y RCP 8.5 se muestran en lila, vino y gris, respectivamente, los cuales se desprenden de (Parent et al., 2018, Fig. S12A).

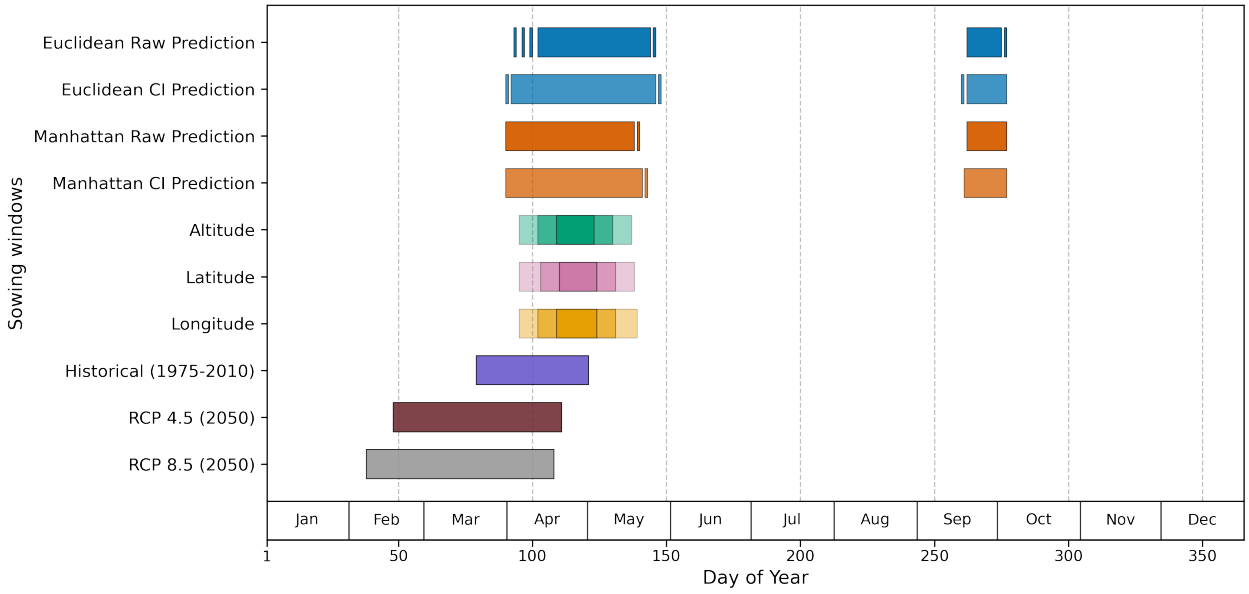

Figura 11: Comparaciones para el norte de Sajonia.Los periodos de siembra de maíz determinados empleando la distancia Euclideana se muestran en color azul mientras que los determinados empleando la distancia Manhattan se muestran en color anaranjado. Los periodos correspondientes a la Raw prediction se muestran opacos mientras que aquellos correspondientes a la CI prediction se muestran con transparencia. Los periodos de siembra de maíz en Alemania que se desprenden de los trabajos de (Parker et al., 2016) y (Flores et al., 2025), ver Tabla 10, se muestran en color verde, rosa y amarillo para la altitud, latitud y longitud, respectivamente. Los distintos niveles de transparencia ilustran las fechas comprendidas en el intervalo de semiancho $\nu \in \{1, 2, 3\}$ desviaciones estándar respecto a la media de la muestra. Finalmente, los periodos de siembra de maíz en Europa correspondientes al periodo histórico (1975–2010) y a las proyecciones bajo los escenarios RCP 4.5 y RCP 8.5 se muestran en lila, vino y gris, respectivamente, los cuales se desprenden de (Parent et al., 2018, Fig. S12A).

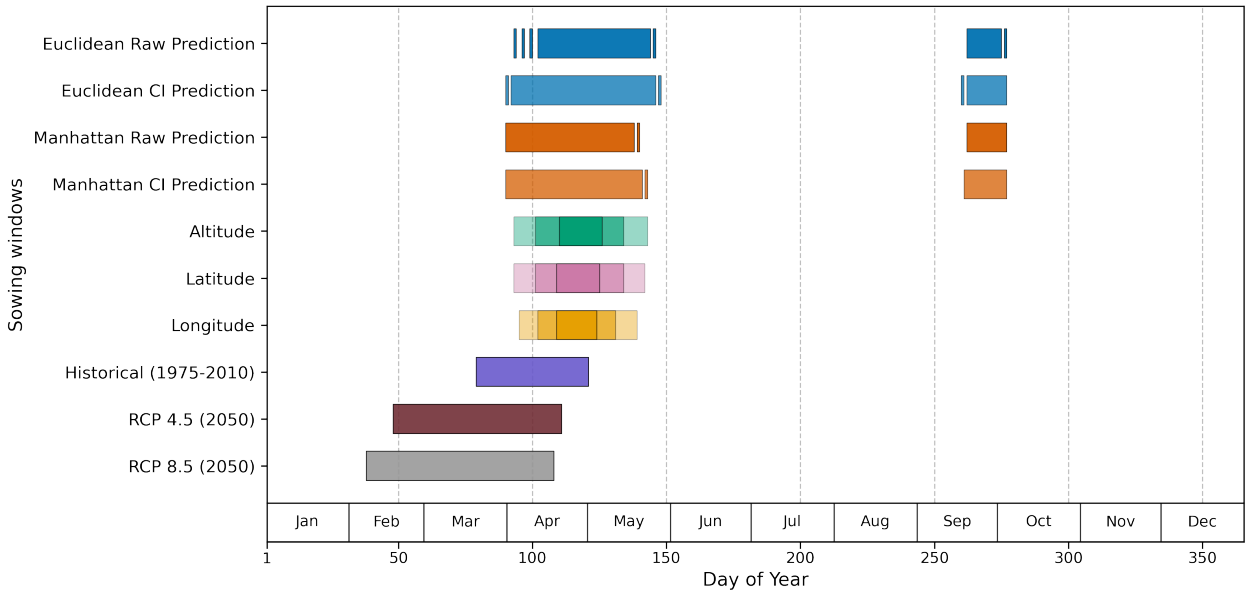

Figura 12: Comparaciones para el sur de Sajonia. Los periodos de siembra de maíz determinados empleando la distancia Euclideana se muestran en color azul mientras que los determinados empleando la distancia Manhattan se muestran en color anaranjado. Los periodos correspondientes a la Raw prediction se muestran opacos mientras que aquellos correspondientes a la CI prediction se muestran con transparencia. Los periodos de siembra de maíz en Alemania que se desprenden de los trabajos de (Parker et al., 2016) y (Flores et al., 2025), ver Tabla 10, se muestran en color verde, rosa y amarillo para la altitud, latitud y longitud, respectivamente. Los distintos niveles de transparencia ilustran las fechas comprendidas en el intervalo de semiancho $\nu \in \{1, 2, 3\}$ desviaciones estándar respecto a la media de la muestra. Finalmente, los periodos de siembra de maíz en Europa correspondientes al periodo histórico (1975–2010) y a las proyecciones bajo los escenarios RCP 4.5 y RCP 8.5 se muestran en lila, vino y gris, respectivamente, los cuales se desprenden de (Parent et al., 2018, Fig. S12A).

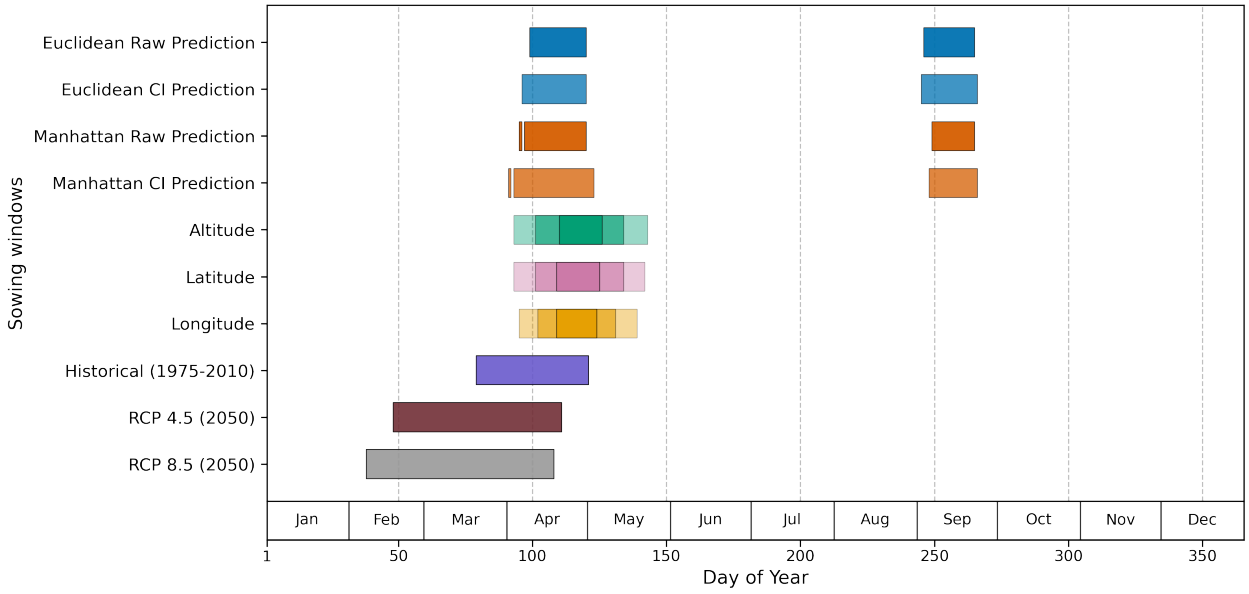

Figura 13: Comparaciones para Baviera. Los periodos de siembra de maíz determinados empleando la distancia Euclideana se muestran en color azul mientras que los determinados empleando la distancia Manhattan se muestran en color anaranjado. Los periodos correspondientes a la Raw prediction se muestran opacos mientras que aquellos correspondientes a la CI prediction se muestran con transparencia. Los periodos de siembra de maíz en Alemania que se desprenden de los trabajos de (Parker et al., 2016) y (Flores et al., 2025), ver Tabla 10, se muestran en color verde, rosa y amarillo para la altitud, latitud y longitud, respectivamente. Los distintos niveles de transparencia ilustran las fechas comprendidas en el intervalo de semiancho $\nu \in \{1, 2, 3\}$ desviaciones estándar respecto a la media de la muestra. Finalmente, los periodos de siembra de maíz en Europa correspondientes al periodo histórico (1975–2010) y a las proyecciones bajo los escenarios RCP 4.5 y RCP 8.5 se muestran en lila, vino y gris, respectivamente, los cuales se desprenden de (Parent et al., 2018, Fig. S12A).

Altitude					
ν	**Sowing window** $115.6 \pm 7.12\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 122	0.0131	0.0568	0.0000	0.000
2	101 – 129	0.1375	0.1888	0.0983	0.1076
3	94 – 136	0.2068	0.3010	0.1911	0.1944

Latitude					
ν	**Sowing window** $116.2 \pm 7.08\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	109 – 123	0.0131	0.0568	0.0000	0.0000
2	102 – 130	0.1234	0.1888	0.0806	0.0909
3	94 – 137	0.2183	0.3118	0.1884	0.1917

Longitude					
ν	**Sowing window** $116.2 \pm 7.3\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 123	0.0263	0.0681	0.0000	0.0000
2	101 – 130	0.1358	0.2000	0.0967	0.1060
3	94 – 138	0.2159	0.3225	0.1857	0.1891

Tabla 5: Comparaciones para Brandemburgo según el criterio geográfico. Índice de Jaccard calculado entre el periodo de siembra de maíz identificado por el modelo, acotado al primer semestre del año, y los conjuntos de fechas de siembra definidos por intervalos de semiancho ν desviaciones estándar respecto a la media muestral, con $\nu \in \{1, 2, 3\}$, correspondientes a los datos presentados en la Tabla 10.

Formalmente, las comparaciones se cuantificaron a través del índice de Jaccard, el cual mide la similitud entre un par de conjuntos finitos dados Bag et al. (2019). De esta manera, si $\hat{W}$ denota uno de los periodos siembra obtenido con nuestra metodología y W denota alguno de los periodos previamente reportados en la literatura, la similitud entre $\hat{W}$ y W, medida con el índice de Jaccard se denota y define por

$$J(\hat{W}, W) \coloneqq \frac{|\hat{W} \cap W|}{|\hat{W} \cup W|}, \tag{13}$$

donde $|\cdot|$ indica el operador de cardinalidad de un conjunto.

En Alemania, el maíz es un cultivo de primavera Laidig et al. (2025). Por tanto, consideramos exclusivamente la parte de los periodos de siembra determinados acotados al primer semestre del año, a la que denotaremos por P_1, para calcular el índice de Jaccard. Para cada una de las regiones, las comparaciones de periodos de siembra en Alemania respecto a los criterios geográficos de altitud, latitud y longitud se muestran en la Tablas 5, 6, 7 y 8, respectivamente.

Similarmente, para cada una de las regiones, las comparaciones de periodos de siembra de maíz en Europa respecto el escenario histórico, RCP 4.5 y RCP 8.5, a través del cálculo de índice de Jaccard, se muestran en la Tabla 9.

Dado que el cultivo de maíz en Alemania se desarrolla en la primavera, las comparaciones anteriores se realizaron entre los periodos de siembra identificados por el modelo que pertenecen al primer semestre del año (P_1) y los periodos reportados en la literatura. Para profundizar en las diferencias agroclimáticas entre los periodos identificados que pertenecen al primer semestre (P_1) y aquellos identificados que pertenecen al segundo semestre (P_2), se presenta a continuación un análisis comparativo de las condiciones ambientales

Altitude					
ν	**Sowing window** $115.6 \pm 7.12\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 122	0.3260	0.2678	0.3061	0.2884
2	101 – 129	0.5957	0.5178	0.5918	0.5576
3	94 – 136	0.7115	0.7678	0.8775	0.8269

Latitude					
ν	**Sowing window** $116.2 \pm 7.08\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	109 – 123	0.3260	0.2678	0.3061	0.2884
2	102 – 130	0.6304	0.5178	0.5918	0.5576
3	94 – 137	0.7307	0.7857	0.8979	0.8461

Longitude					
ν	**Sowing window** $116.2 \pm 7.3\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 123	0.3478	0.2857	0.3265	0.3076
2	101 – 130	0.6170	0.5357	0.6122	0.5769
3	94 – 138	0.7500	0.8035	0.8800	0.8653

Tabla 6: Comparaciones para el norte de Sajonia según el criterio geográfico. Índice de Jaccard calculado entre el periodo de siembra de maíz identificado por el modelo, acotado al primer semestre del año, y los conjuntos de fechas de siembra definidos por intervalos de semiancho ν desviaciones estándar respecto a la media muestral, con $\nu \in \{1, 2, 3\}$, correspondientes a los datos presentados en la Tabla 10.

Altitude					
ν	**Sowing window** $117.4 \pm 8.29\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	109 – 125	0.3695	0.3035	0.3469	0.3269
2	100 – 133	0.6666	0.6071	0.6938	0.6538
3	92 – 142	0.8301	0.9107	0.8867	0.9433

Latitude					
ν	**Sowing window** $116.7 \pm 8.23\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 124	0.3695	0.3035	0.3469	0.3269
2	100 – 133	0.6666	0.6071	0.6938	0.6538
3	92 – 141	0.8113	0.8928	0.9038	0.9245

Longitude					
ν	**Sowing window** $116.2 \pm 7.3\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 123	0.3478	0.2857	0.3265	0.3076
2	101 – 130	0.6170	0.5357	0.6122	0.5769
3	94 – 138	0.7500	0.8035	0.8800	0.8653

Tabla 7: Comparaciones para el sur de Sajonia según el criterio geográfico. Índice de Jaccard calculado entre el periodo de siembra de maíz identificado por el modelo, acotado al primer semestre del año, y los conjuntos de fechas de siembra definidos por intervalos de semiancho ν desviaciones estándar respecto a la media muestral, con $\nu \in \{1, 2, 3\}$, correspondientes a los datos presentados en la Tabla 10.

Altitude					
ν	**Sowing window** $117.4 \pm 8.29\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	109 – 125	0.4074	0.3666	0.3666	0.4117
2	100 – 133	0.5714	0.5263	0.5263	0.5476
3	92 – 142	0.4117	0.4705	0.4705	0.5769

Latitude					
ν	**Sowing window** $116.7 \pm 8.23\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 124	0.4615	0.4137	0.4137	0.4545
2	100 – 133	0.5714	0.5263	0.5263	0.5476
3	92 – 141	0.4200	0.4800	0.4800	0.5882

Longitude					
ν	**Sowing window** $116.2 \pm 7.3\nu$	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
1	108 – 123	0.4800	0.4285	0.4285	0.4687
2	101 – 130	0.5937	0.5428	0.5428	0.5641
3	94 – 138	0.4666	0.5333	0.5333	0.6170

Tabla 8: Comparaciones para Baviera según el criterio geográfico. Índice de Jaccard calculado entre el periodo de siembra de maíz identificado por el modelo, acotado al primer semestre del año, y los conjuntos de fechas de siembra definidos por intervalos de semiancho ν desviaciones estándar respecto a la media muestral, con $\nu \in \{1, 2, 3\}$, correspondientes a los datos presentados en la Tabla 10.

Brandenburg					
Climate scenario	**Sowing window**	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
Historical (1975–2010)	79–120	0.4054	0.3636	0.538462	0.5178
RCP 4.5 (2050)	48–110	0.7605	0.6206	0.603175	0.6825
RCP 8.5 (2050)	38–107	0.6708	0.5578	0.542857	0.61428

Saxony					
Climate scenario	**Sowing window**	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
Historical (1975–2010)	79–120	0.3333	0.4411	0.5166	0.4920
RCP 4.5 (2050)	48–110	0.1237	0.2020	0.2307	0.2234
RCP 8.5 (2050)	38–107	0.0841	0.1559	0.1782	0.1730

Bavaria					
Climate scenario	**Sowing window**	**Jaccard index**			
		Euclidean		**Manhattan**	
		Raw prediction	**CI prediction**	**Raw prediction**	**CI prediction**
Historical (1975–2010)	79–120	0.5000	0.5714	0.5714	0.6590
RCP 4.5 (2050)	48–110	0.1666	0.2083	0.2083	0.2533
RCP 8.5 (2050)	38–107	0.1097	0.1463	0.1463	0.1882

Tabla 9: Comparaciones por escenario climático. Índice de Jaccard calculado entre el periodo de siembra de maíz identificado por el modelo, acotado al primer semestre del año, y los conjuntos de fechas de siembra reportados para Europa en el escenario climático histórico (1975–2010) y los escenarios RCP 4.5 y RCP 8.5 proyectados al 2050, correspondientes a los datos presentados en (Parent et al., 2018, Fig. S12A).

asociadas a ambos conjuntos de fechas.

Por robustez metodológica, se aplicaron pruebas U de Mann-Whitney, con correción de Bonferroni, para analizar diferencias estadísticas en cada una de las cuatro variables en las que se basa el modelo: temperatura media del aire, humedad relativa media del aire, humedad media del suelo en la capa de 0–10 cm y temperatura media del suelo a 5 cm de profundidad.

Para Brandemburgo, considerando las predicciones etiquedas como Raw prediction obtenidas mediante la distancia Euclidiana, los conjuntos de días identificados para el primer y segundo semestre del año fueron, respectivamente, $P_1 = \{55, \ldots, 108, 123, \ldots, 125, 137, 139, \ldots, 142\}$ y $P_2 = \{271, \ldots, 310\}$, ver Tabla 4. En cuanto a la temperatura media del aire, se identificaron diferencias estadísticamente significativas entre ambos conjuntos de días para los datos de 1996 ($p < 0.001$), 2000 ($p < 0.001$), 2001 ($p < 0.001$), 2004 ($p < 0.05$), 2005 ($p < 0.01$), 2006 ($p < 0.001$), 2008 ($p < 0.001$), 2013 ($p < 0.001$) 2014 ($p < 0.001$), 2017 ($p < 0.05$), 2019 ($p < 0.05$), 2020 ($p < 0.001$), 2021 ($p < 0.001$), 2022 ($p < 0.001$), 2023 ($p < 0.05$) y 2025 ($p < 0.05$), ver Figura 14a.

Similarmente, respecto a la humedad relativa media del aire se identificaron diferencias estadísticamente significativas entre los periodos P_1 y P_2 para los datos de 1996 ($p < 0.001$), 1997 ($p < 0.05$), 1998 ($p < 0.01$), 2001 ($p < 0.05$), 2002 ($p < 0.05$), 2003 ($p < 0.01$), 2004 ($p < 0.001$), 2005 ($p < 0.001$), 2007 ($p < 0.001$), 2008 ($p < 0.001$), 2009 ($p < 0.001$), 2010 ($p < 0.01$), 2011 ($p < 0.001$), 2012 ($p < 0.001$), 2014 ($p < 0.001$), 2015 ($p < 0.001$), 2016 ($p < 0.001$), 2017 ($p < 0.001$), 2019 ($p < 0.001$), 2020 ($p < 0.001$), 2021 ($p < 0.01$), 2022 ($p < 0.001$), 2024 ($p < 0.001$) y 2025 ($p < 0.001$), ver Figura 16a.

Asimismo, respecto a la humedad media del suelo en la capa de 0–10 cm se identificaron diferencias estadísticamente significativas entre estos dos periodos en los datos correspondientes a 1997 1999 ($p < 0.001$), 2000 ($p < 0.001$), 2004 ($p < 0.001$), 2005 ($p < 0.05$), 2006 ($p < 0.001$), 2008 ($p < 0.001$), 2016 ($p < 0.05$), 2018 ($p < 0.001$), 2020 ($p < 0.05$) y 2021 ($p < 0.001$), ver Figura 18a.

Adicionalmente, respecto a la temperatura media del suelo a 5 cm de profundidad se identificaron diferencias estadísticamente significativas entre los periodos P_1 y P_2 en los datos correspondientes a 1996 ($p < 0.001$), 2000 ($p < 0.001$), 2001 ($p < 0.001$), 2005 ($p < 0.05$), 2006 ($p < 0.001$), 2008 ($p < 0.01$), 2013 ($p < 0.001$), 2014 ($p < 0.001$), 2017 ($p < 0.01$), 2019 ($p < 0.01$), 2020 ($p < 0.01$), 2021 ($p < 0.001$), 2022 ($p < 0.001$), 2023 ($p < 0.001$), ver Figura 20a.

Finalmente, para extender el análisis se emplearon pruebas U de Mann-Whitney, con corrección de Bonferroni, para comparar los datos agroambientales históricos correspondientes al periodo 1996–2025, agrupados según su pertenencia a los periodos de siembra P_1 y P_2, respectivamente. Tras implementar las pruebas antes mencionadas se identificaron diferencias estadísticamente significativas en la temperatura media del aire ($P_1 : 6.6552 \pm 5.0007$ °C; $P_2 : 9.7478 \pm 3.5387$ °C; $p < 0.001$), ver Figura 14c;la humedad relativa media del aire ($P_1 : 74.0827 \pm 11.1837$ %; $P_2 : 83.9478 \pm 6.9655$ %; $p < 0.001$), ver Figura 16c; la humedad media del suelo en la capa de 0–10 cm ($P_1 : 88.3911 \pm 20.6598$ %; $P_2 : 79.9957 \pm 25.9060$ %; $p < 0.001$), ver Figura 18c; y la temperatura media del suelo a 5 cm de profundidad ($P_1 : 7.7983 \pm 5.1169$ °C; $P_2 : 10.3372 \pm 3.2708$ °C; $p < 0.001$), ver Figura 20c.

Por otra parte, considerando las predicciones etiquetadas como CI prediction obtenidas mediante la distancia Euclidiana, los conjuntos de días identificados para la siembra de maíz durante el primer y el segundo semestre del año fueron, respectivamente, $P_1 = \{55, \ldots, 108, 115, 117, 121, \ldots, 127, 130, 131, 135, \ldots, 147\}$ y $P_2 = \{271, \ldots, 310, 312, 314\}$, ver Tabla 4.

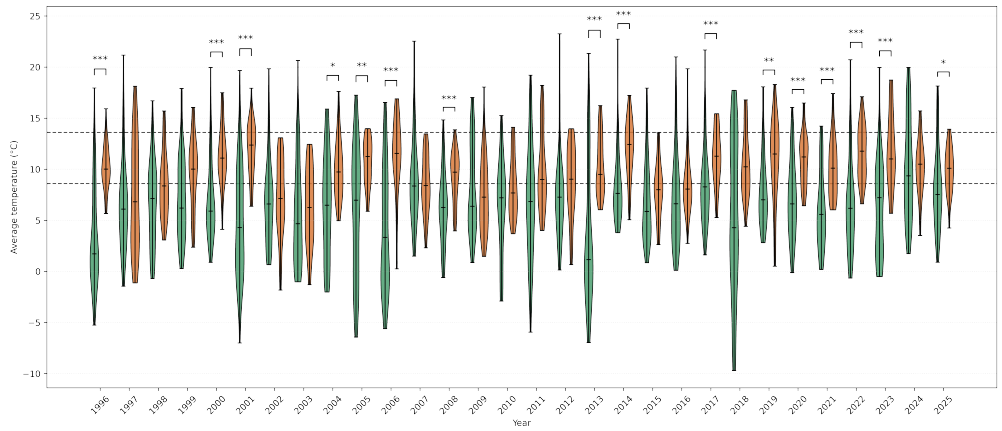

(a)

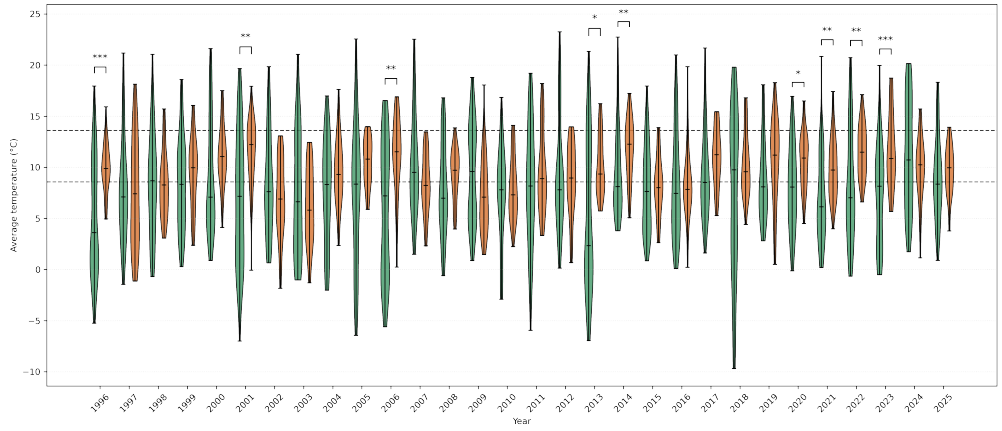

(b)

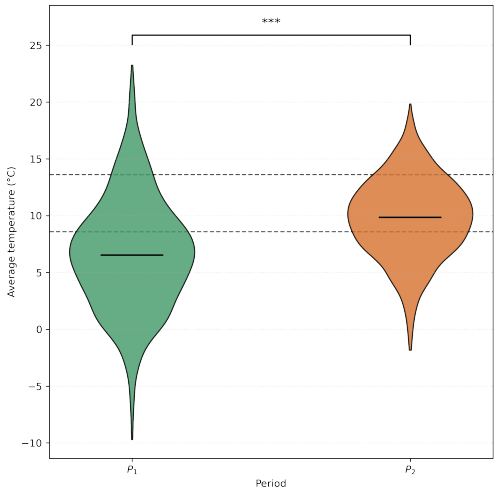

(c)

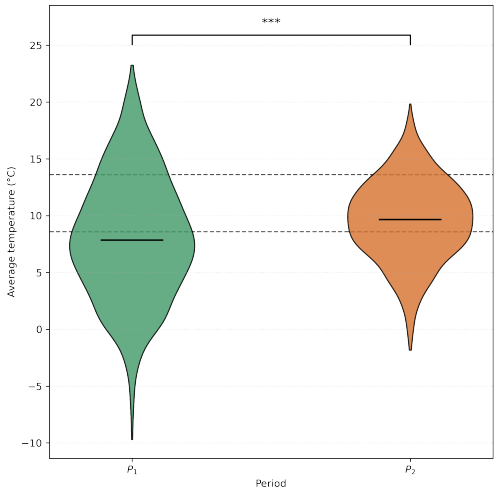

(d)

Figura 14: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

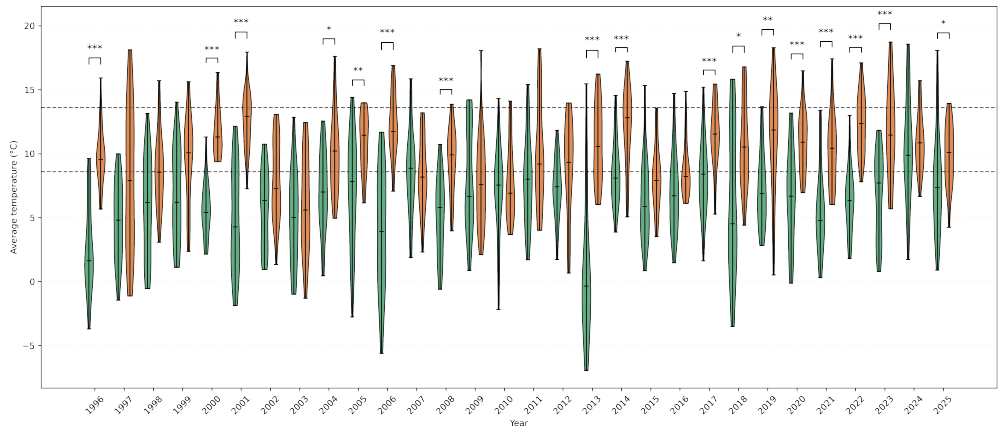

(a)

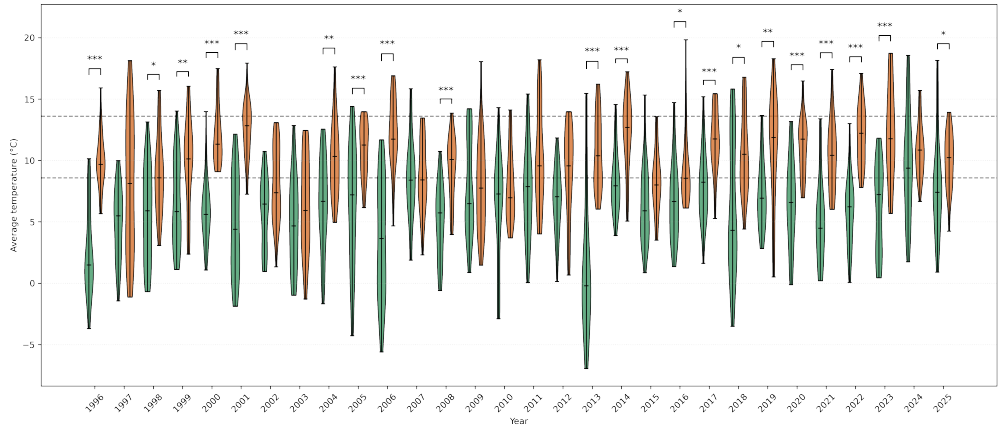

(b)

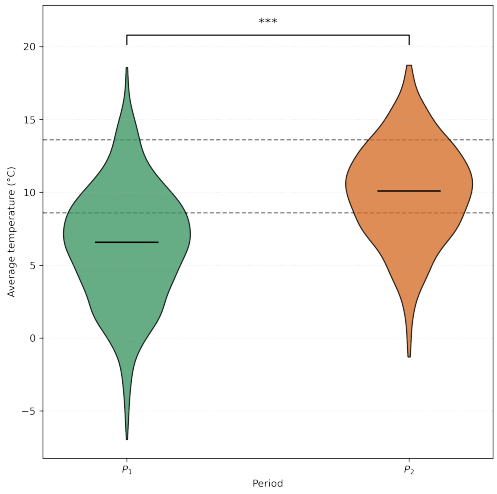

(c)

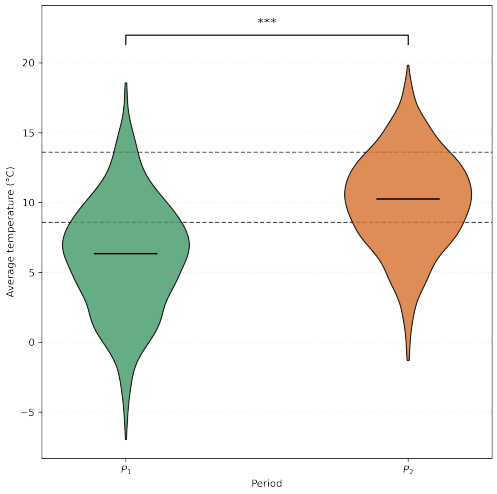

(d)

Figura 15: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

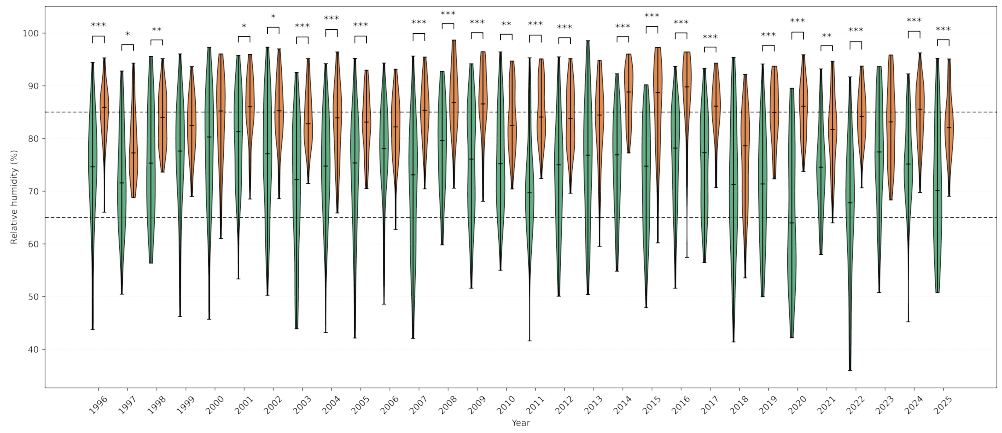

(a)

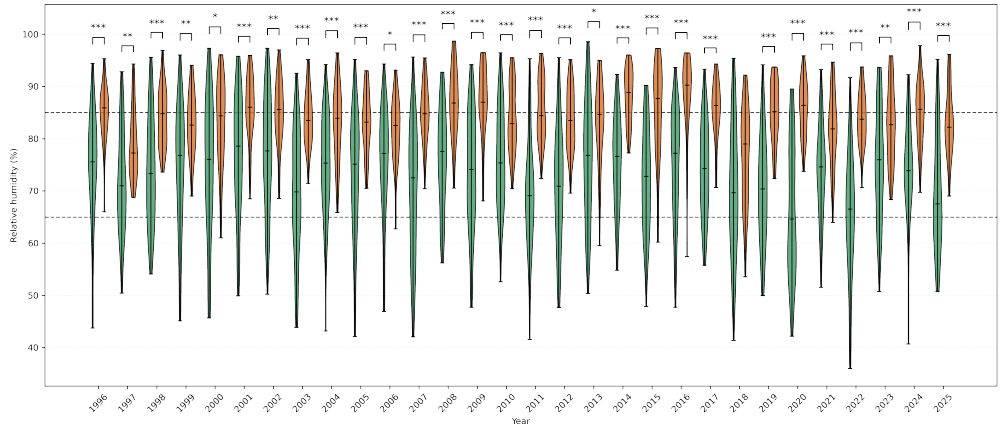

(b)

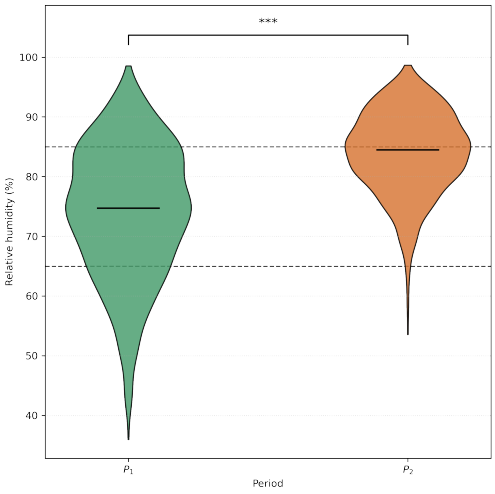

(c)

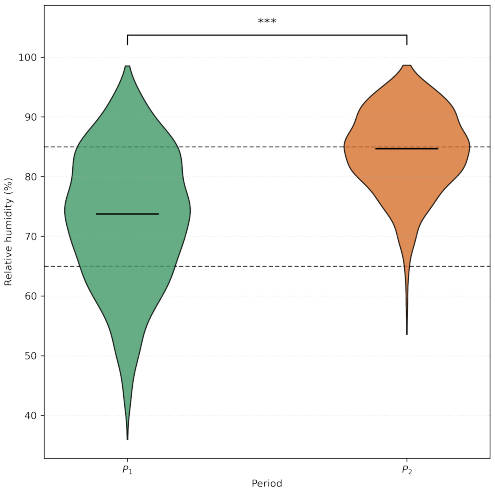

(d)

Figura 16: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

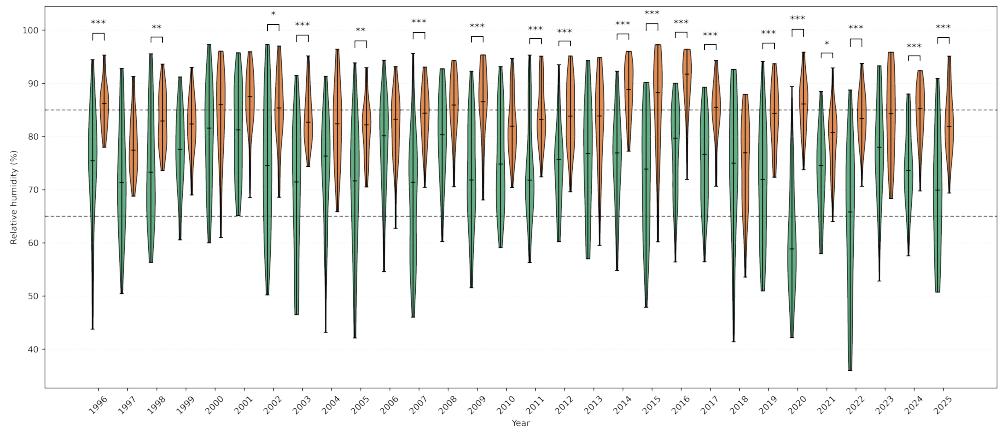

(a)

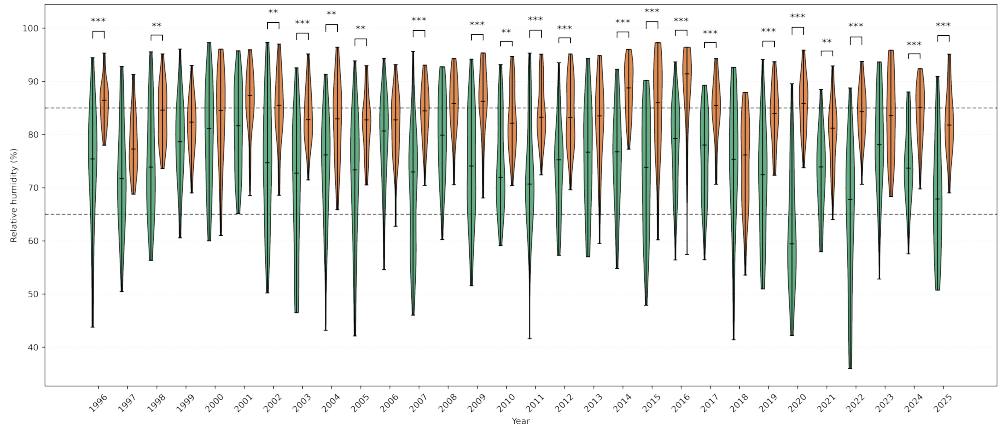

(b)

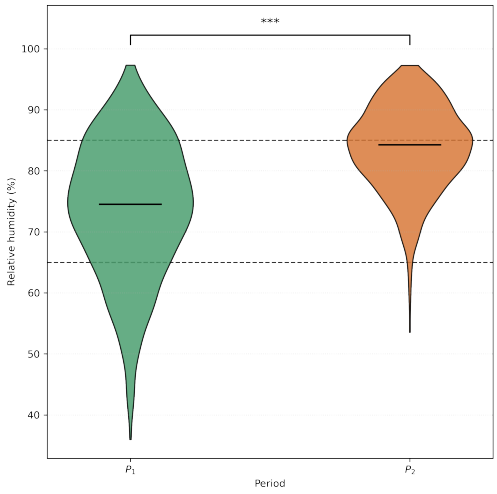

(c)

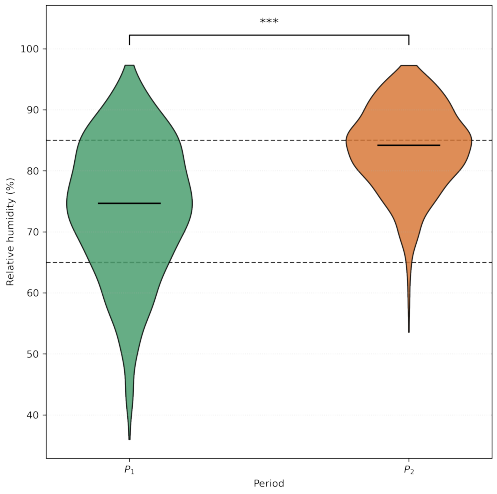

(d)

Figura 17: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

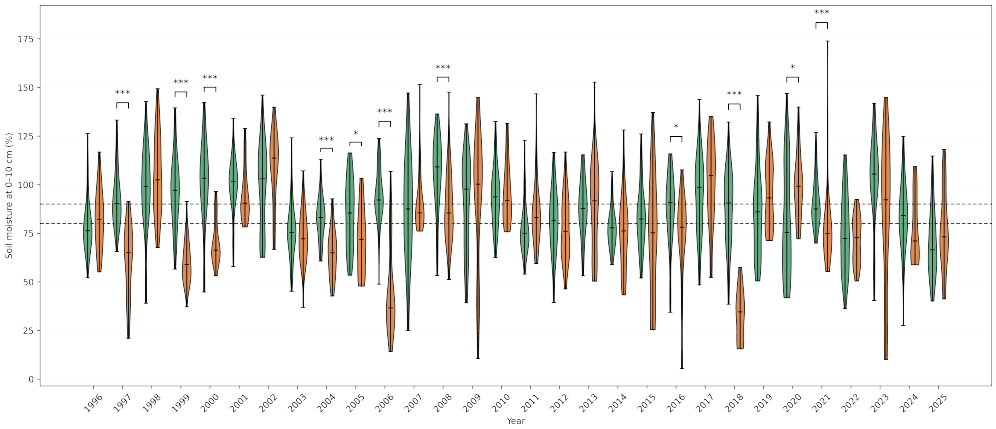

(a)

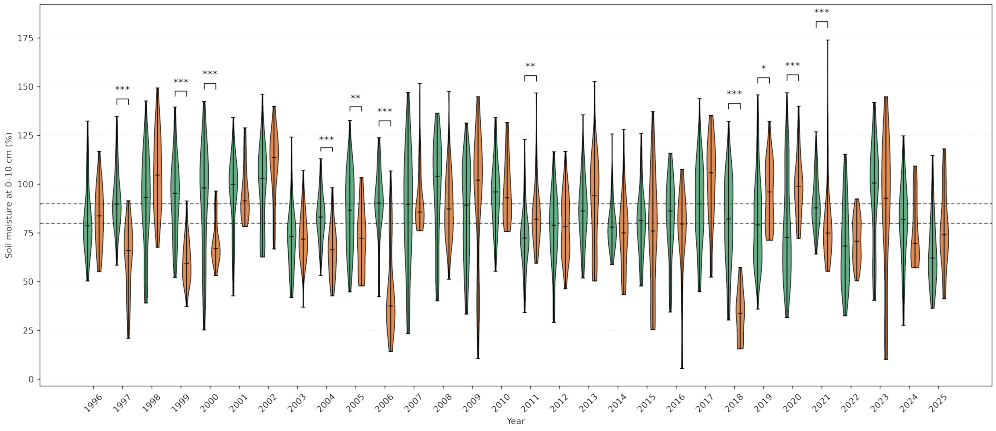

(b)

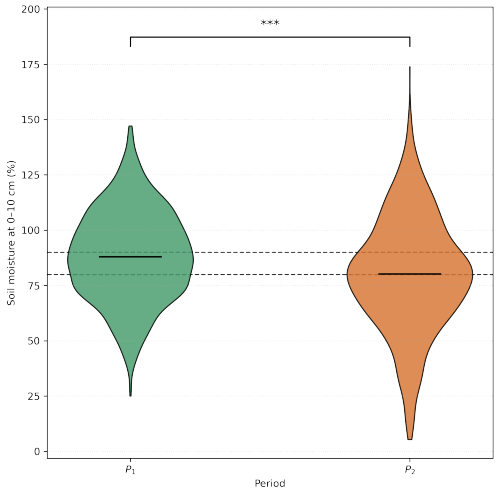

(c)

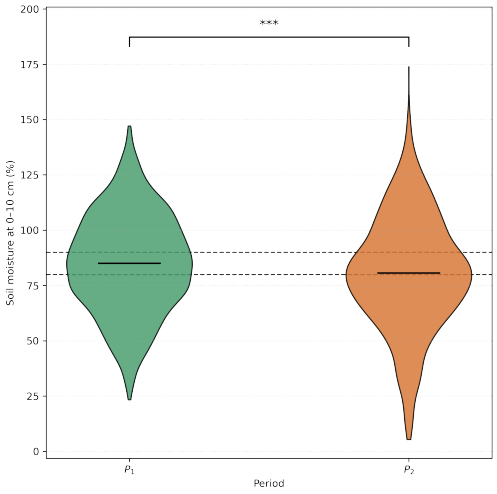

(d)

Figura 18: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

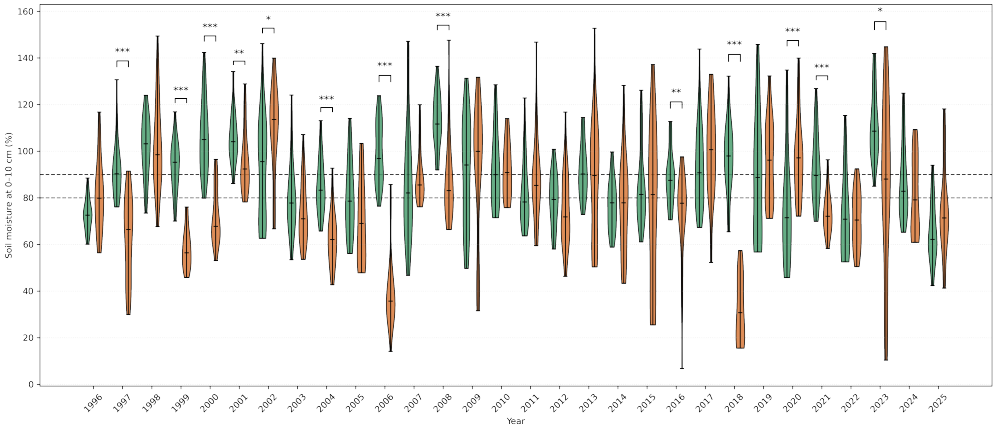

(a)

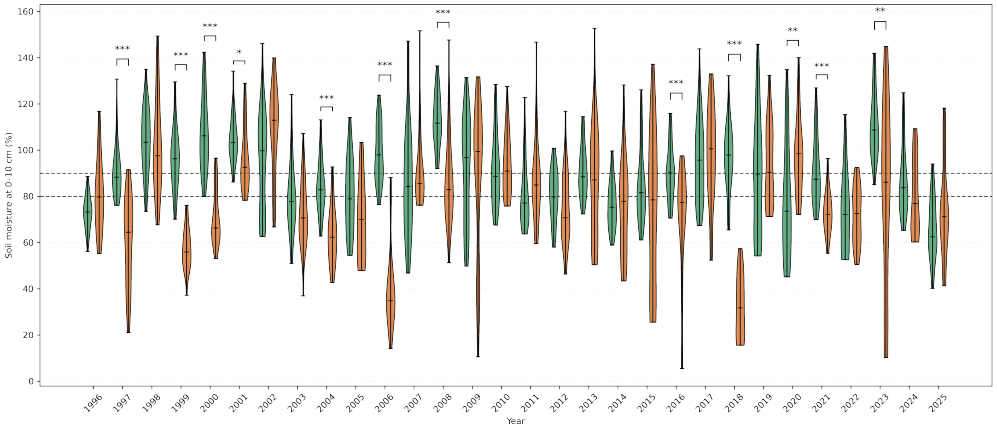

(b)

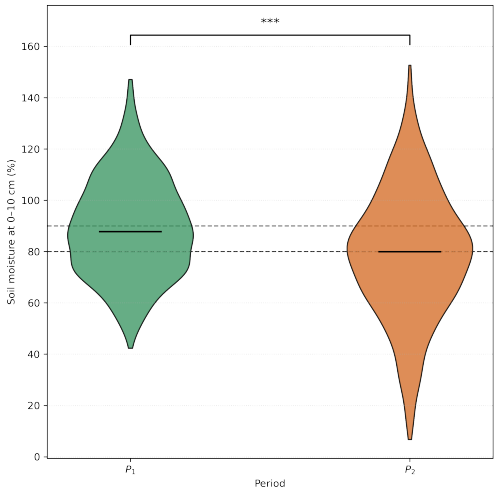

(c)

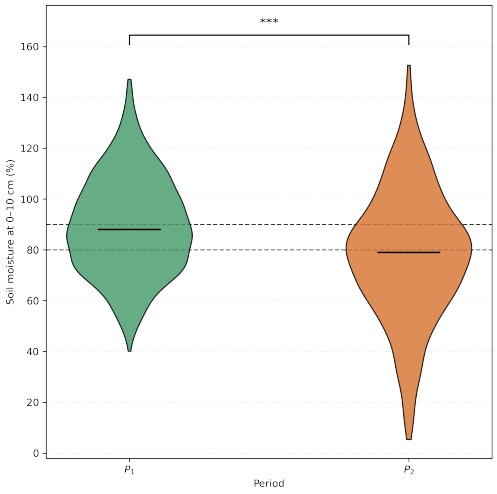

(d)

Figura 19: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

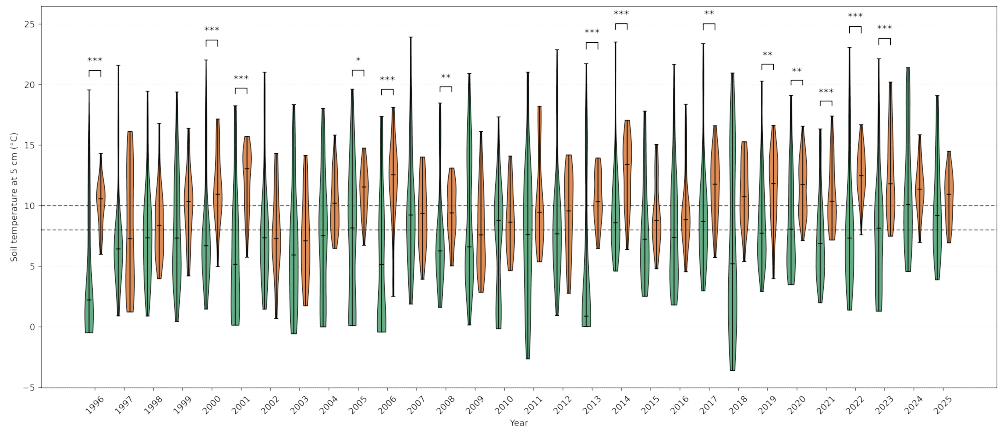

(a)

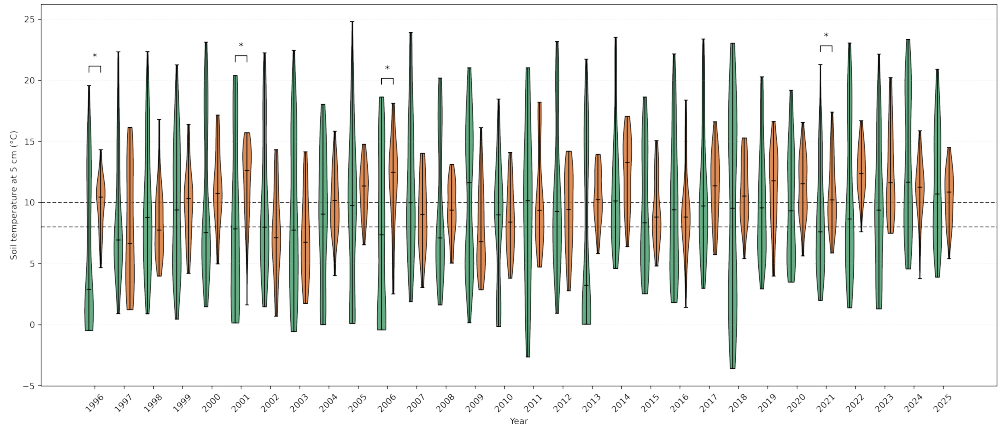

(b)

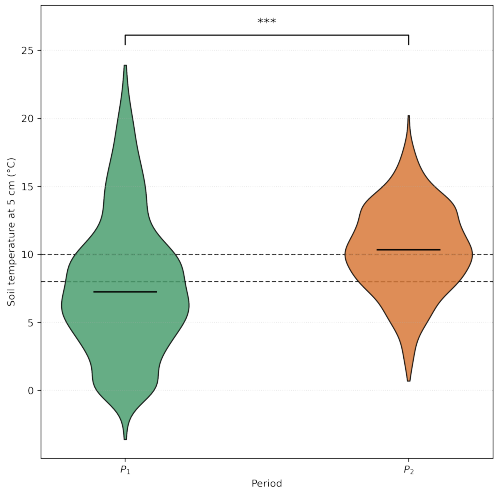

(c)

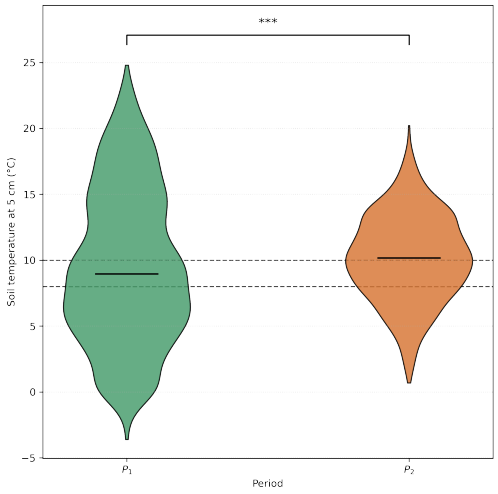

(d)

Figura 20: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

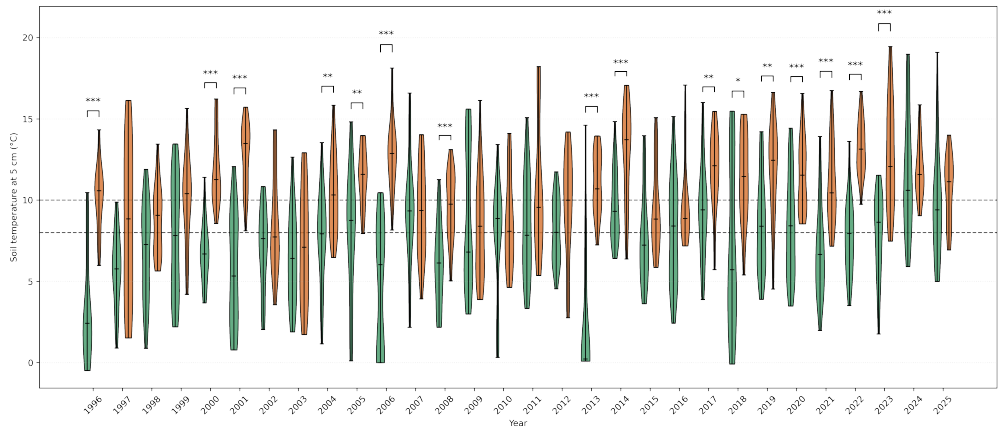

(a)

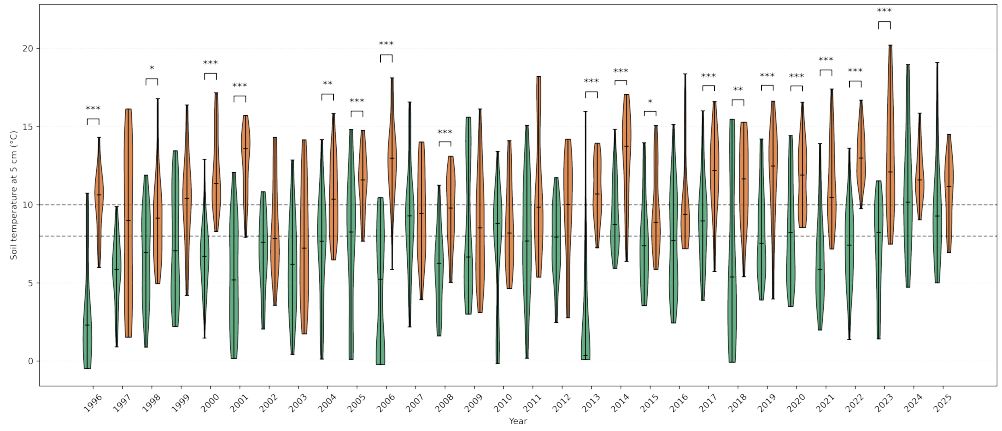

(b)

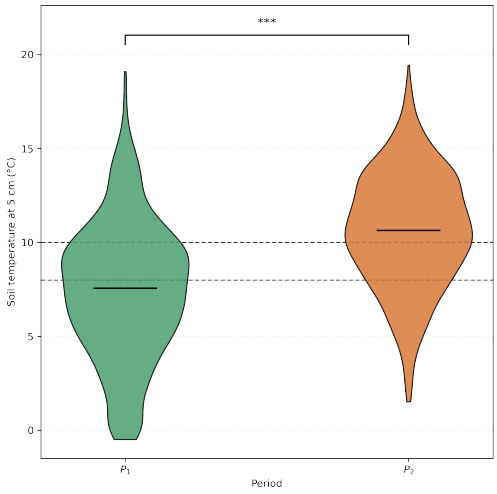

(c)

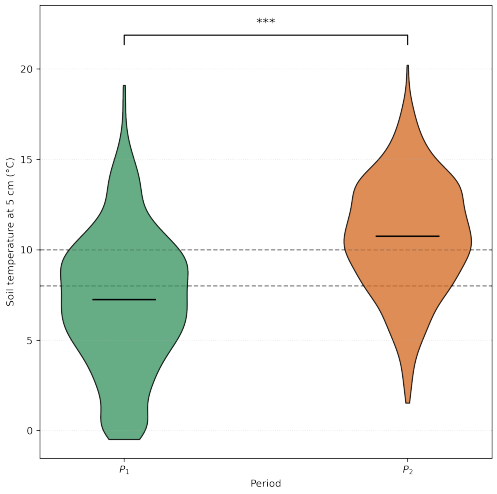

(d)

Figura 21: Temperatura media del aire para Brandenburgo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

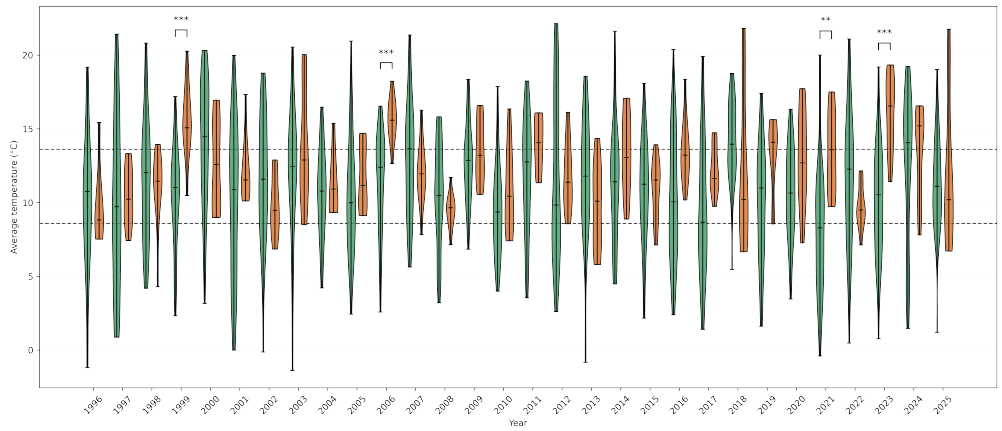

(a)

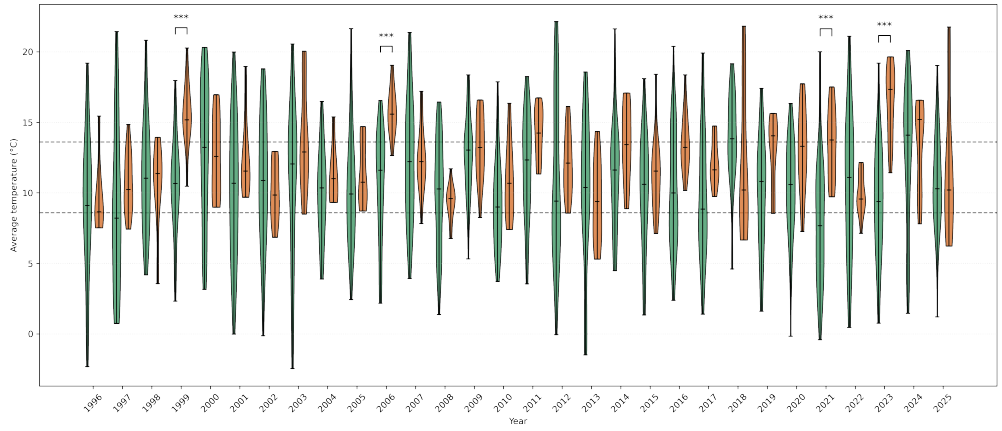

(b)

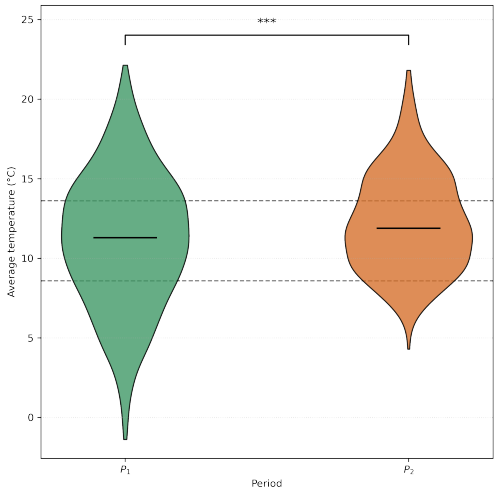

(c)

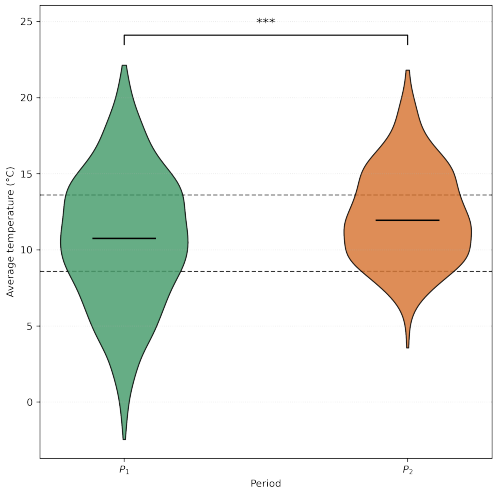

(d)

Figura 22: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

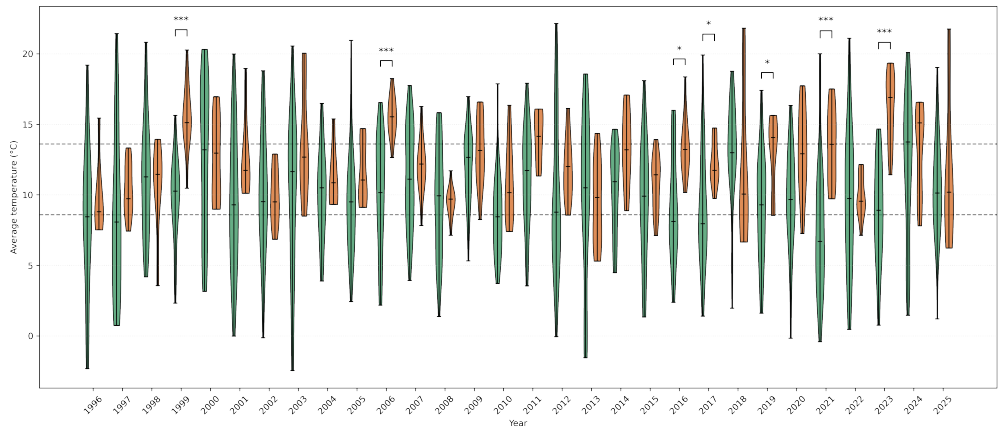

(a)

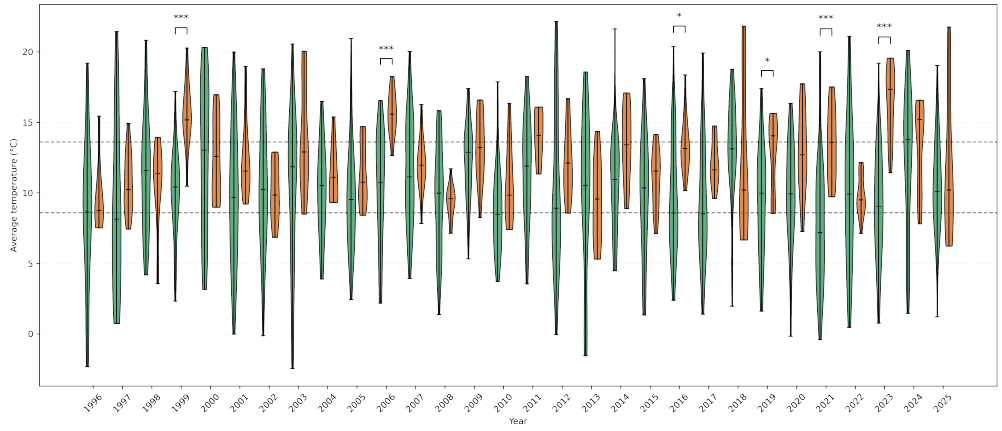

(b)

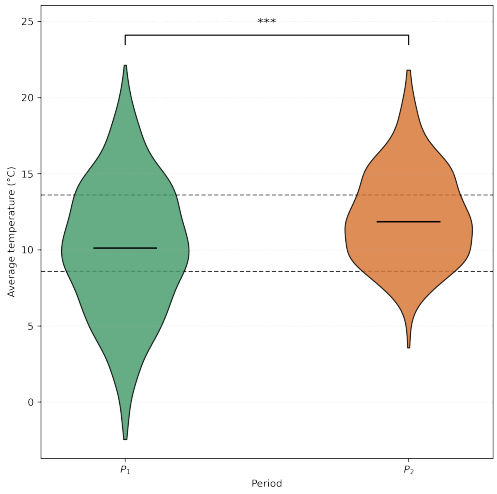

(c)

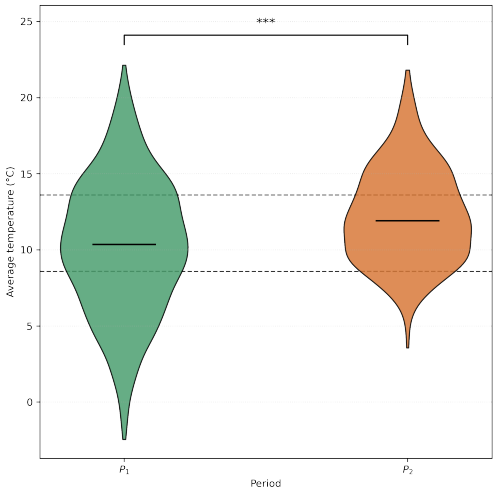

(d)

Figura 23: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

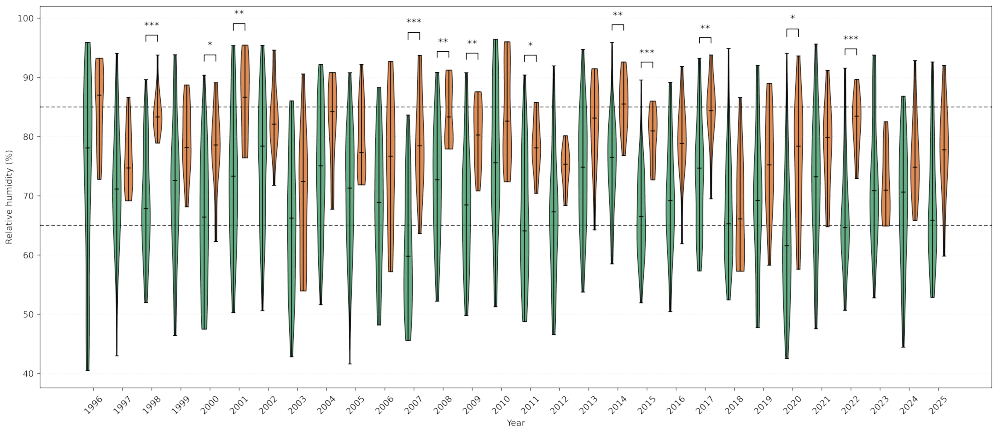

(a)

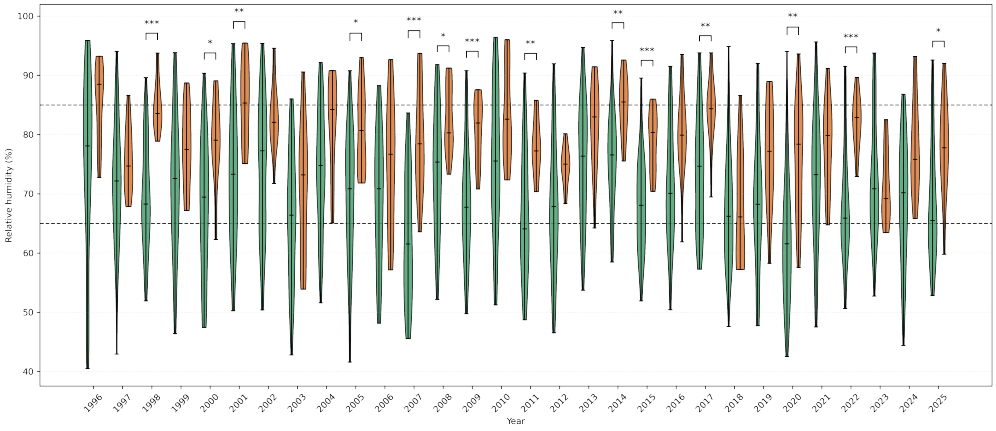

(b)

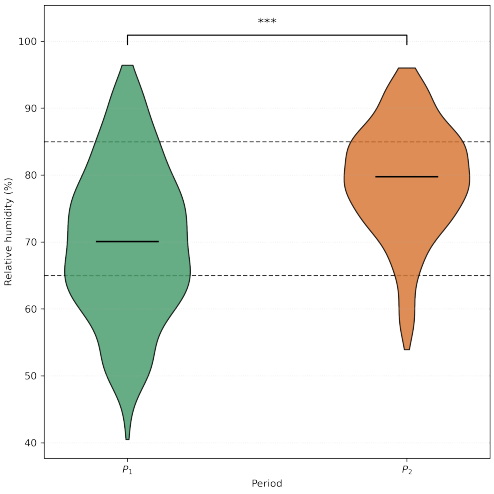

(c)

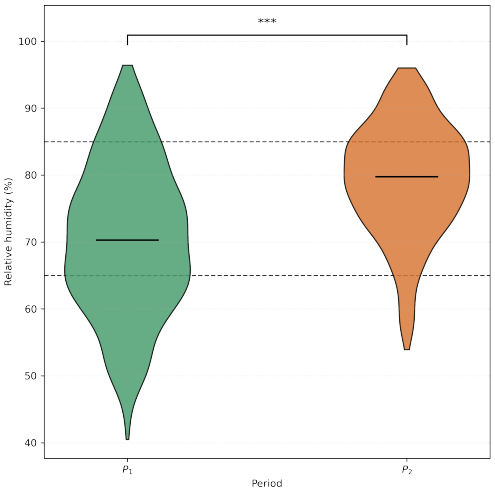

(d)

Figura 24: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

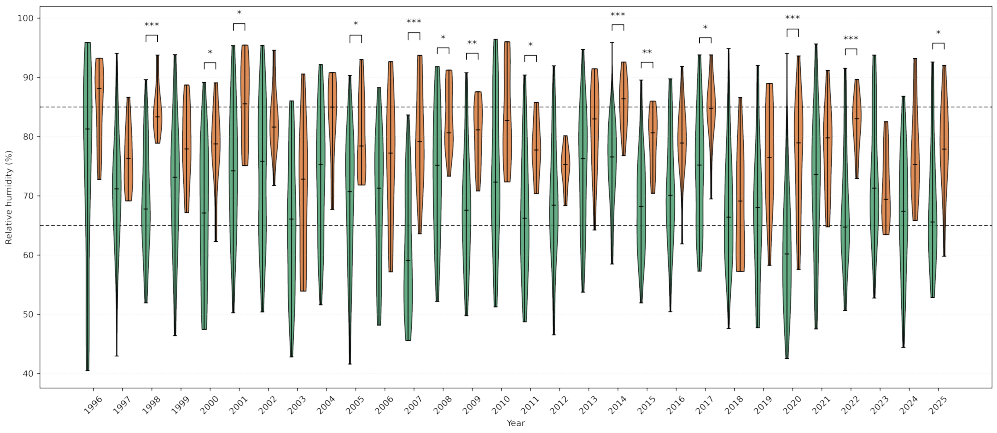

(a)

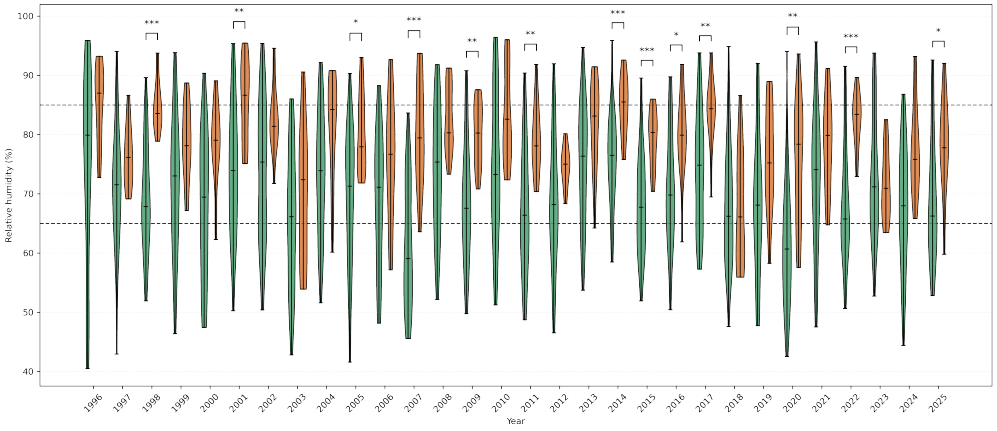

(b)

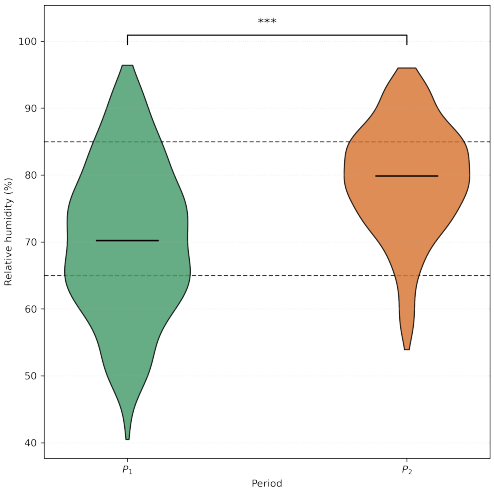

(c)

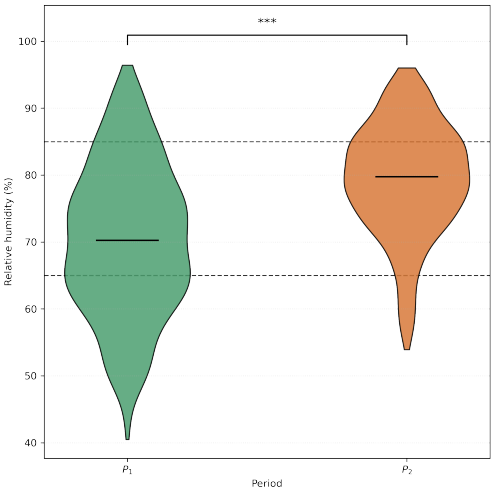

(d)

Figura 25: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

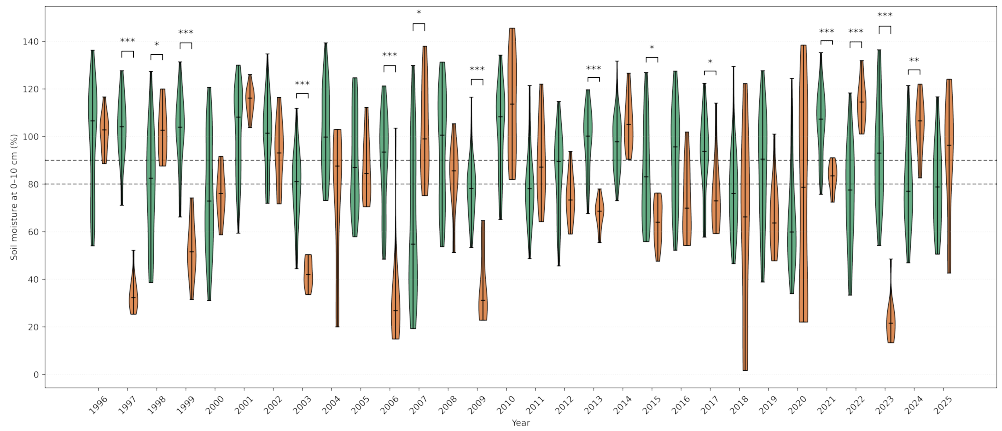

(a)

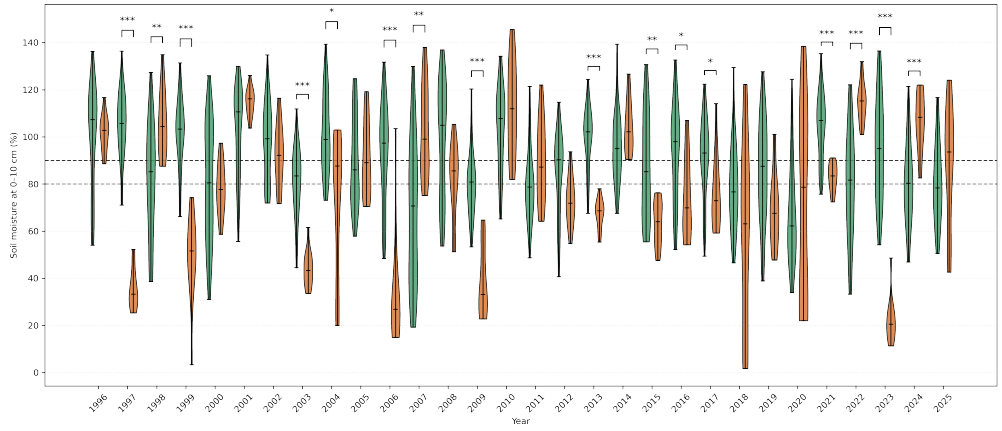

(b)

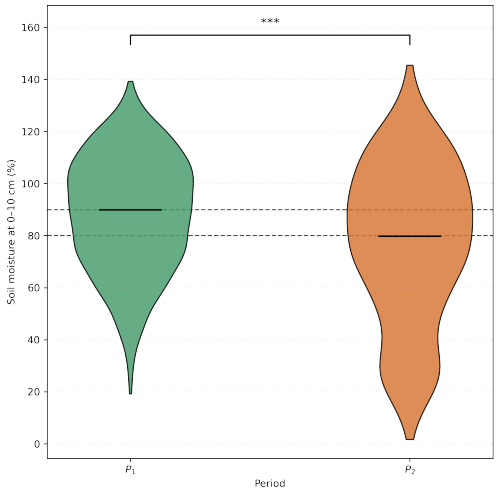

(c)

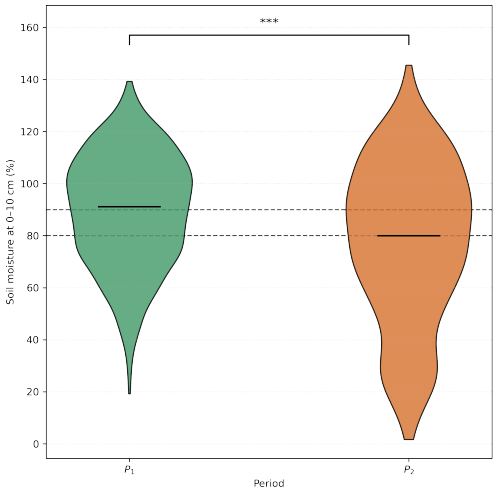

(d)

Figura 26: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

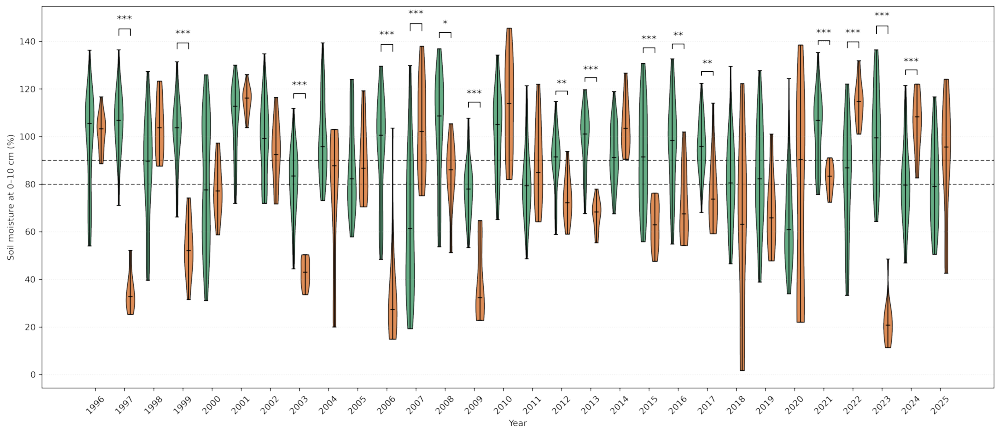

(a)

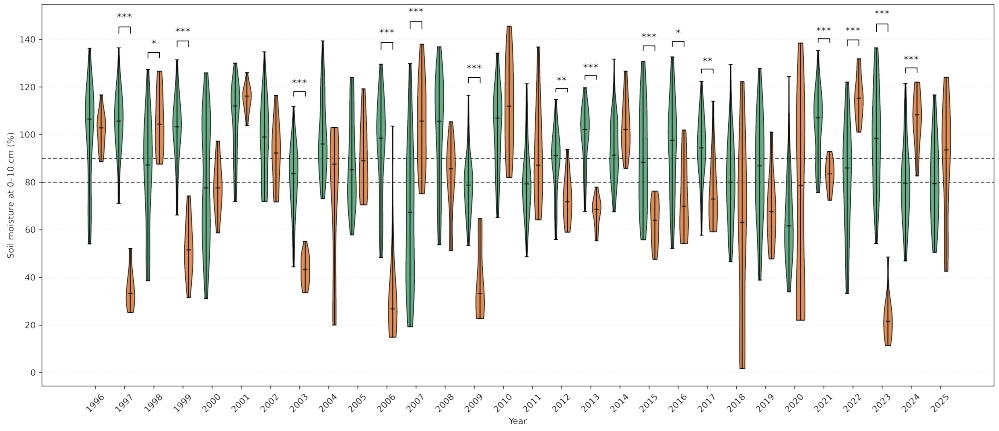

(b)

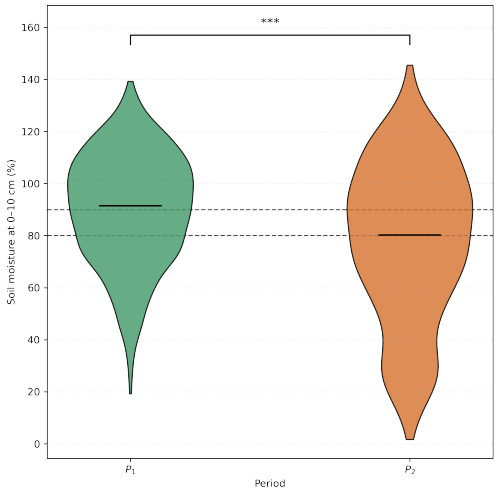

(c)

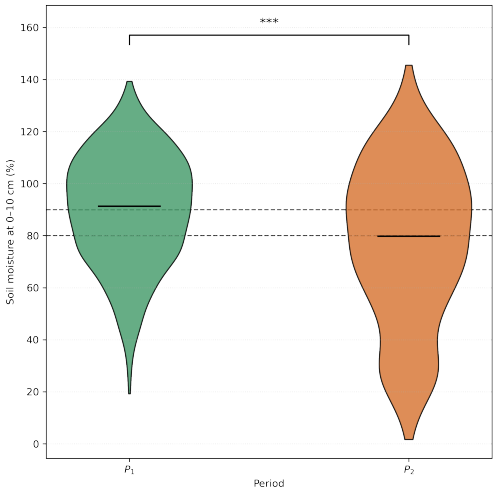

(d)

Figura 27: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

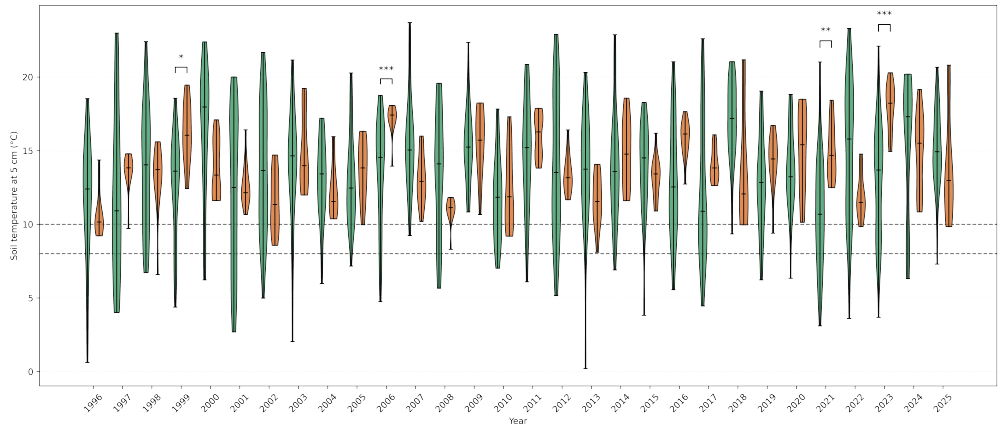

(a)

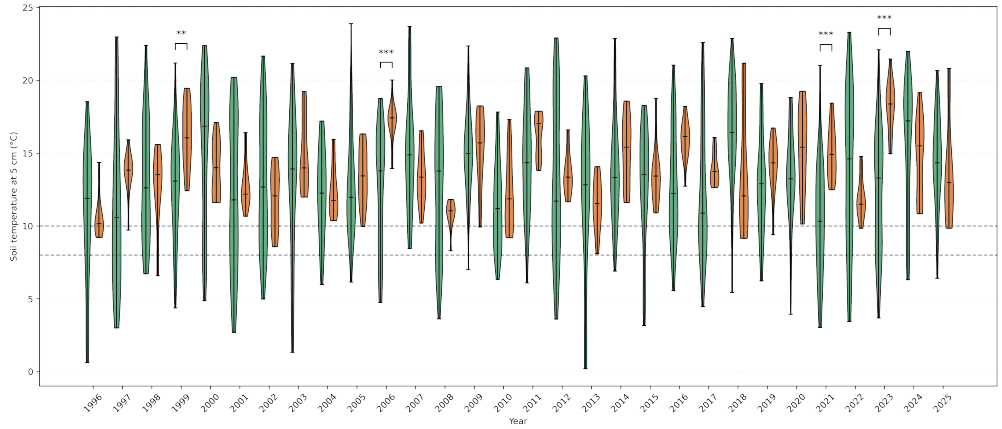

(b)

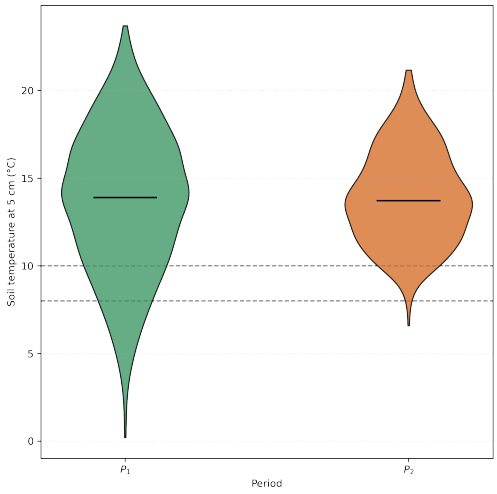

(c)

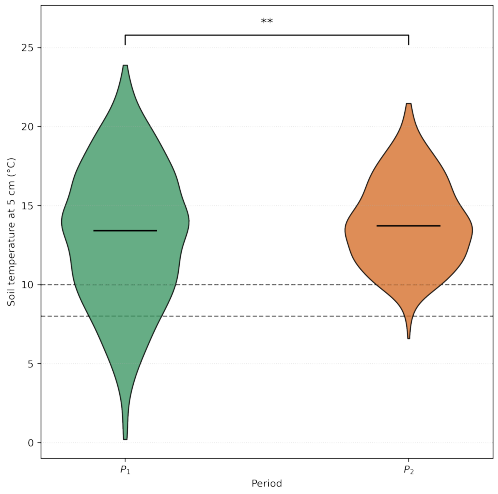

(d)

Figura 28: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

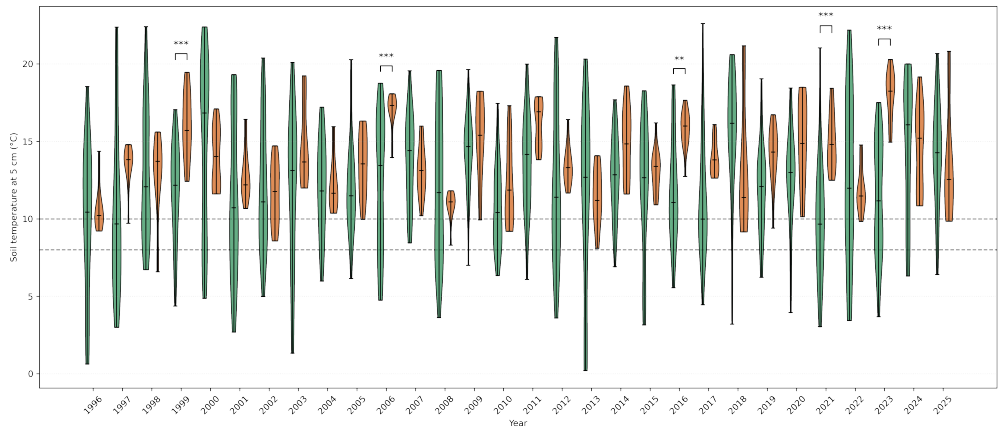

(a)

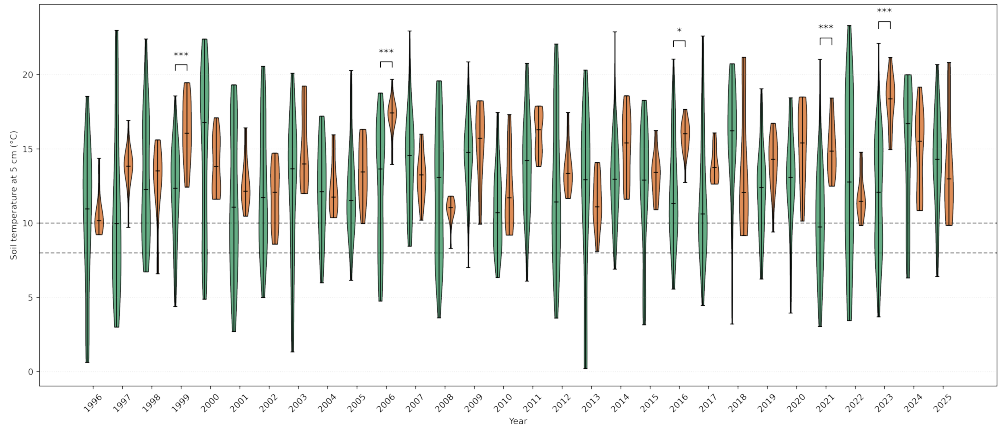

(b)

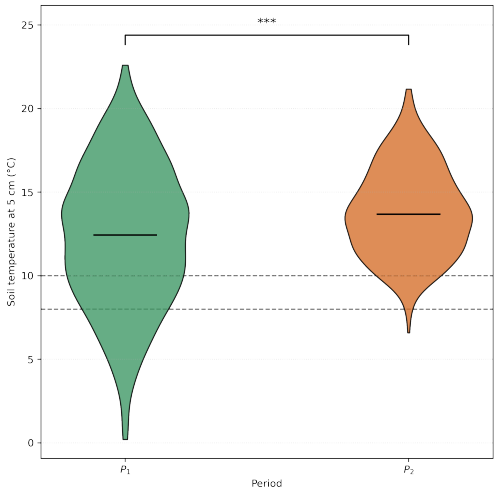

(c)

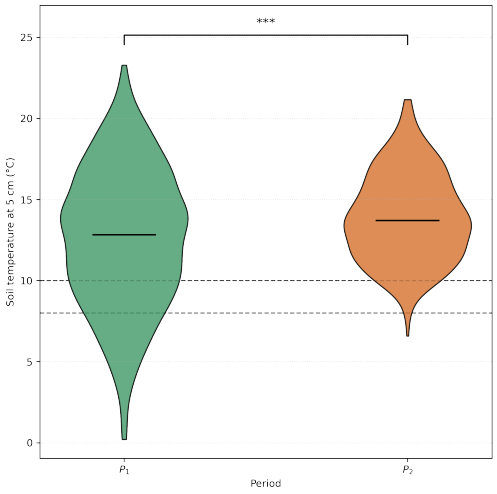

(d)

Figura 29: Temperatura media del aire para Saxonyo obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

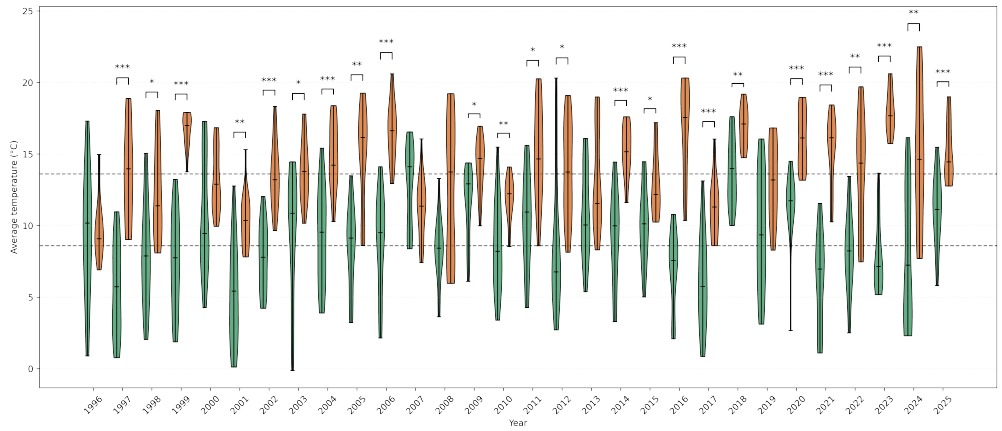

(a)

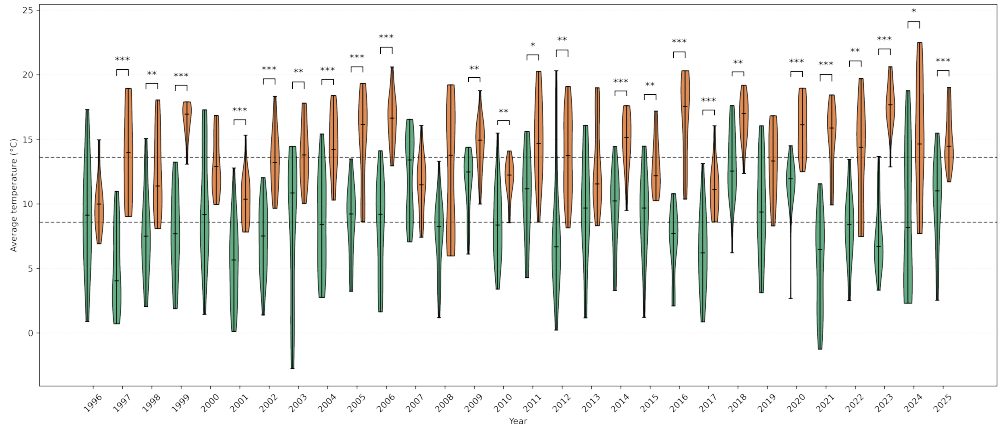

(b)

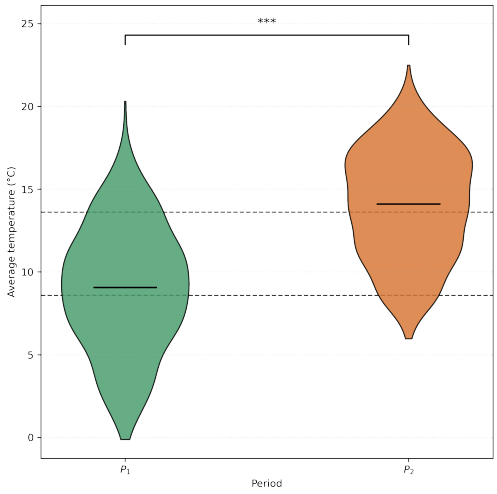

(c)

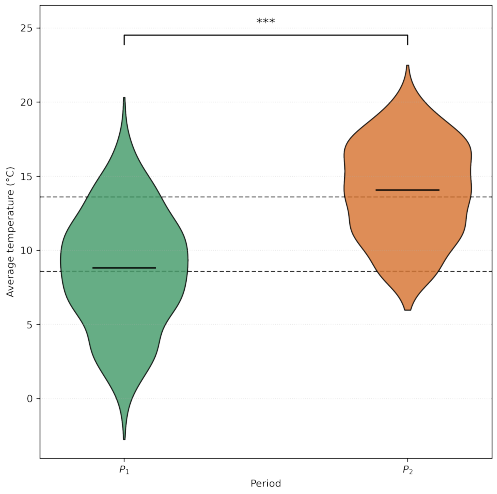

(d)

Figura 30: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

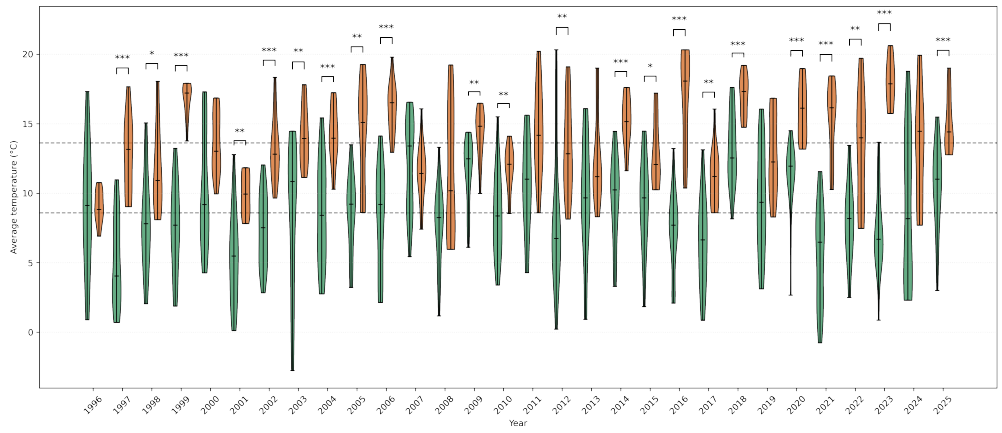

(a)

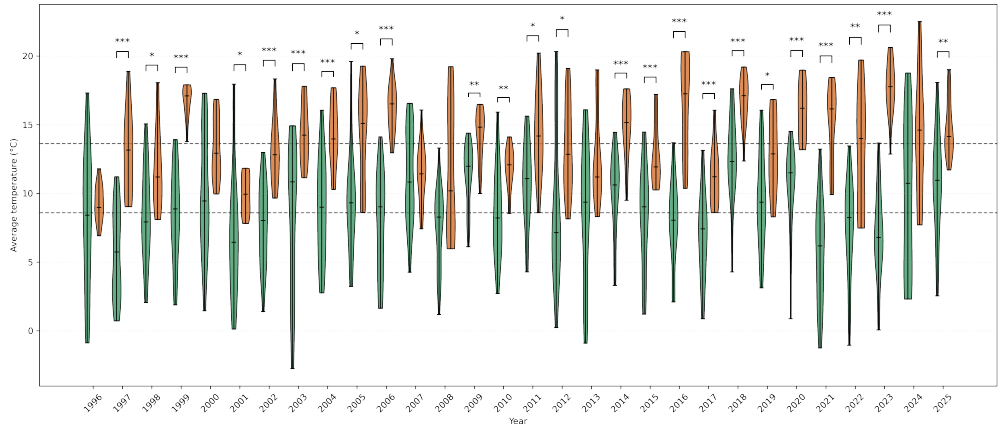

(b)

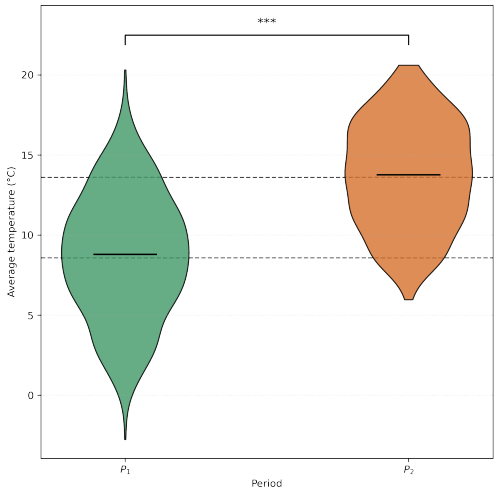

(c)

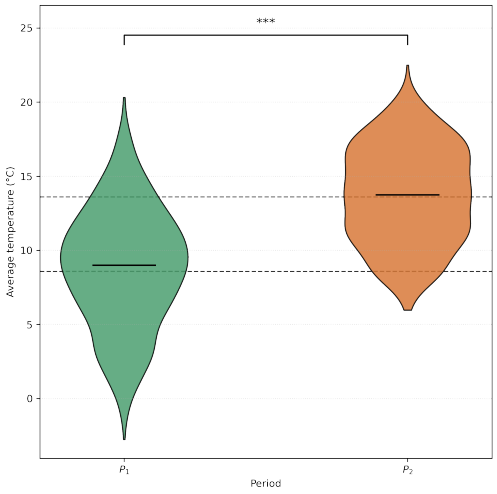

(d)

Figura 31: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

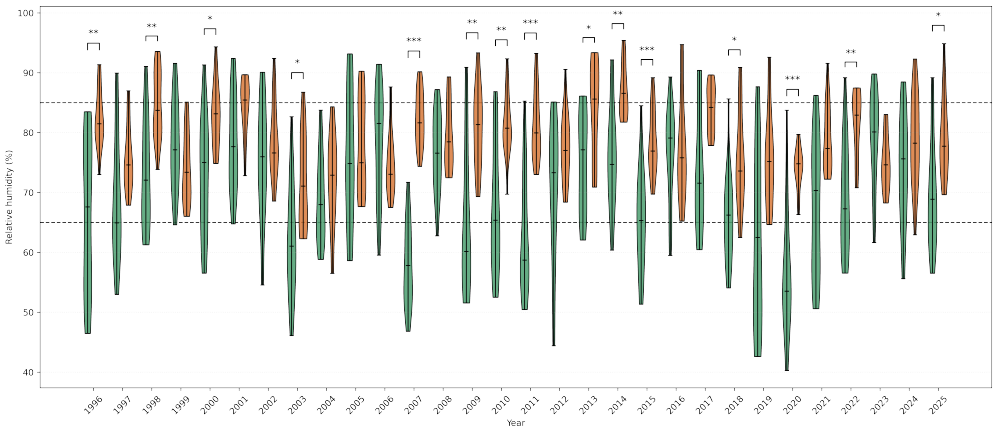

(a)

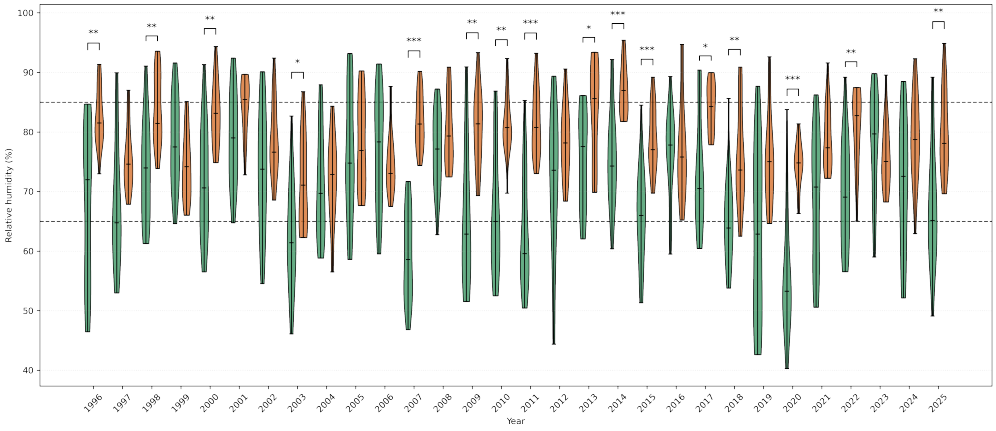

(b)

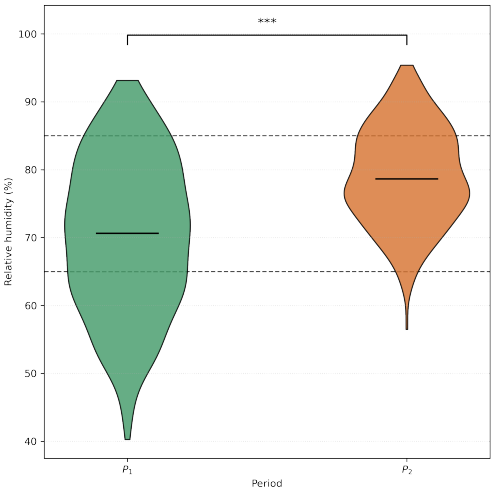

(c)

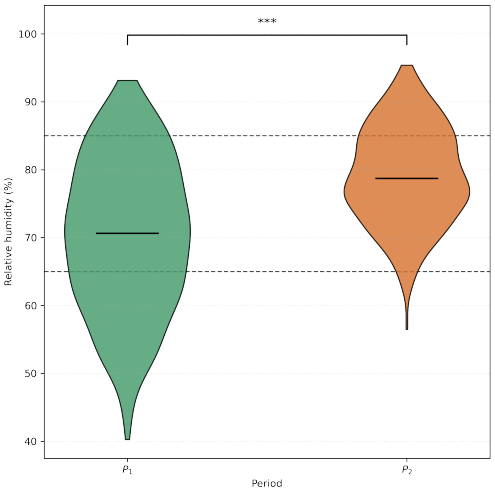

(d)

Figura 32: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

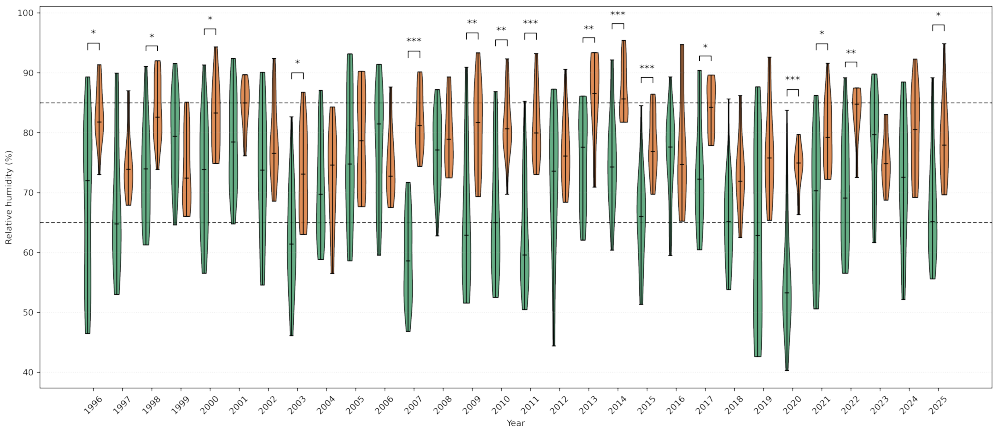

(a)

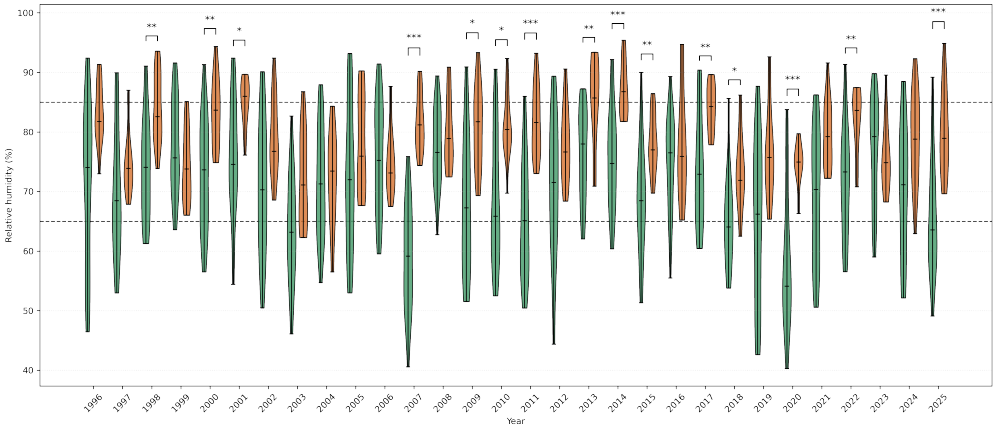

(b)

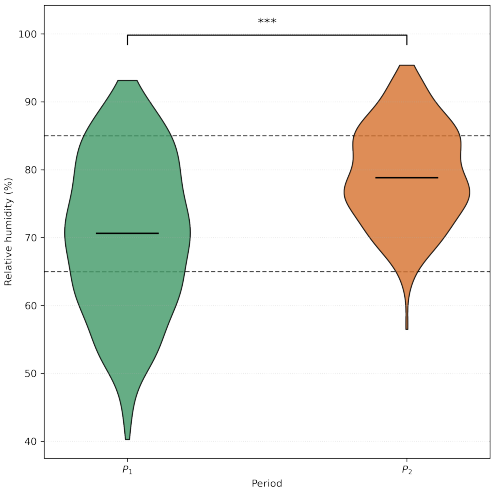

(c)

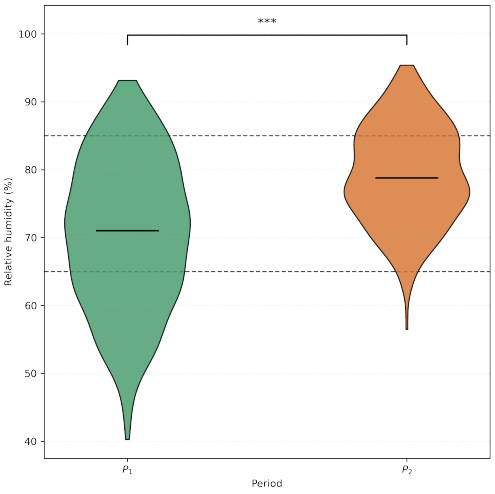

(d)

Figura 33: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

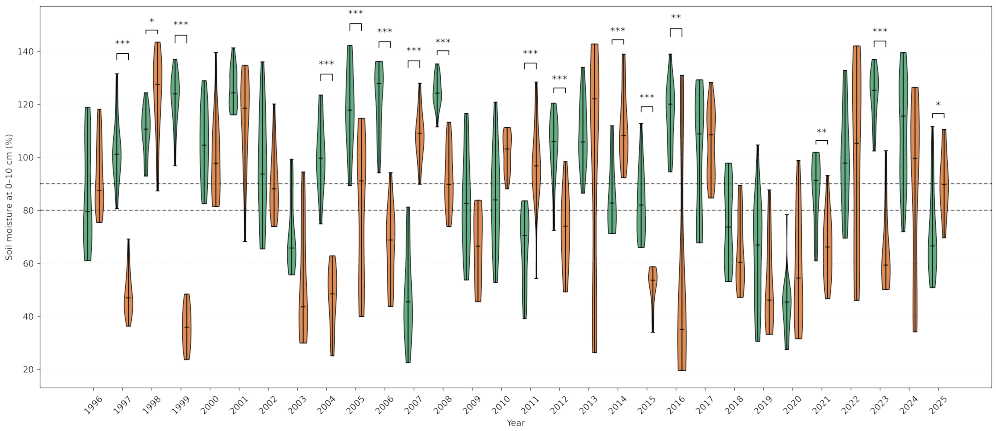

(a)

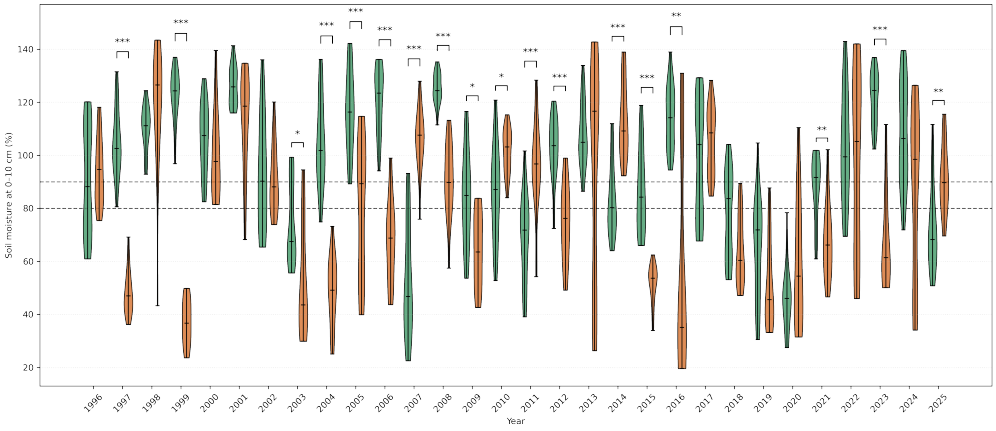

(b)

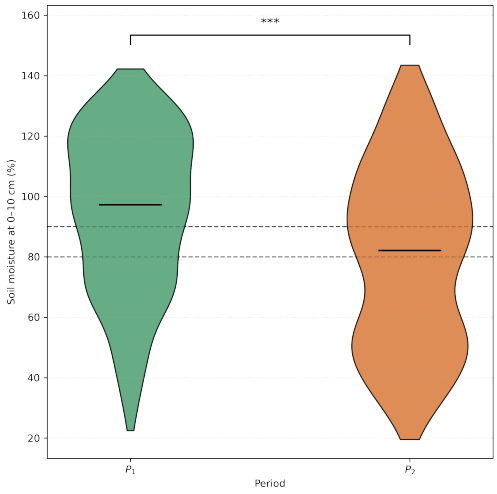

(c)

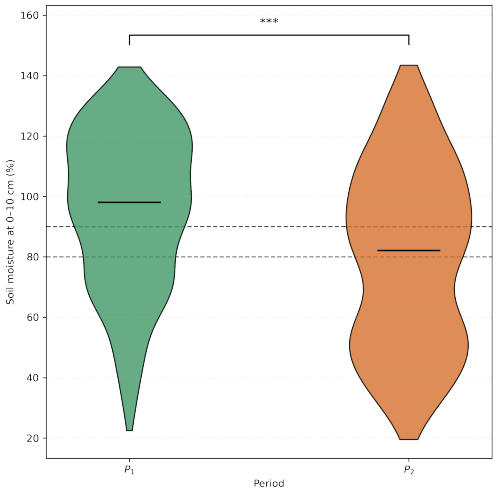

(d)

Figura 34: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

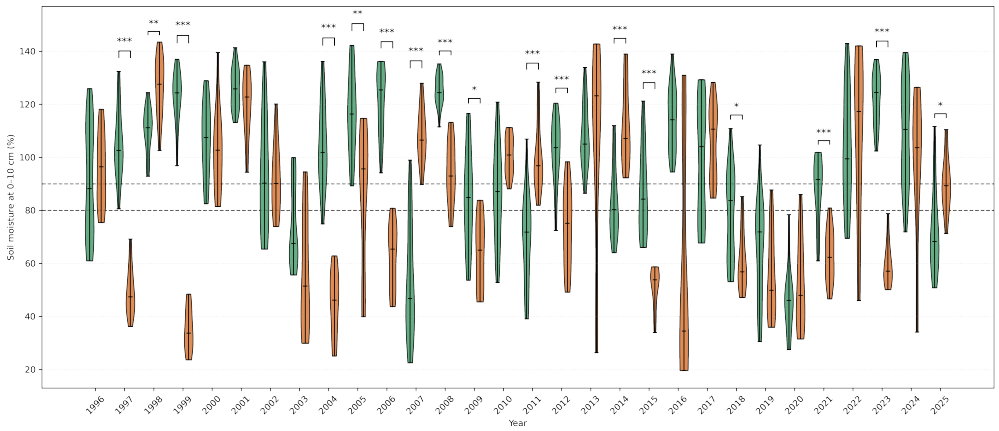

(a)

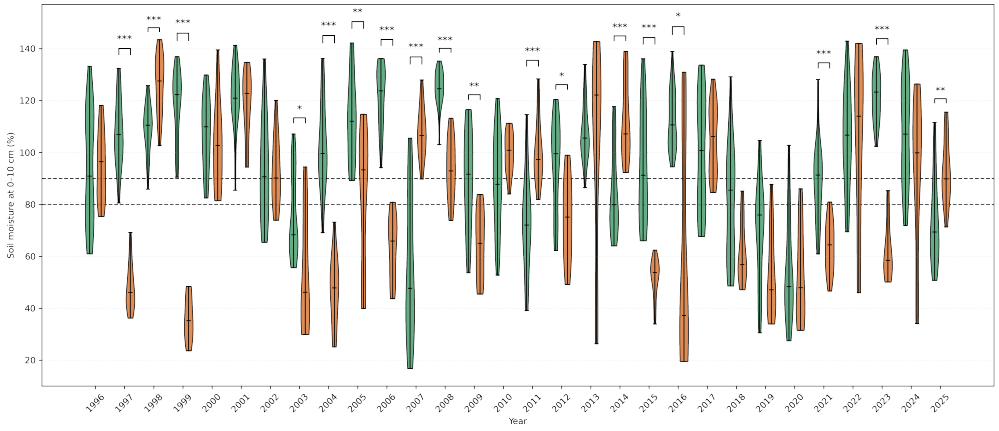

(b)

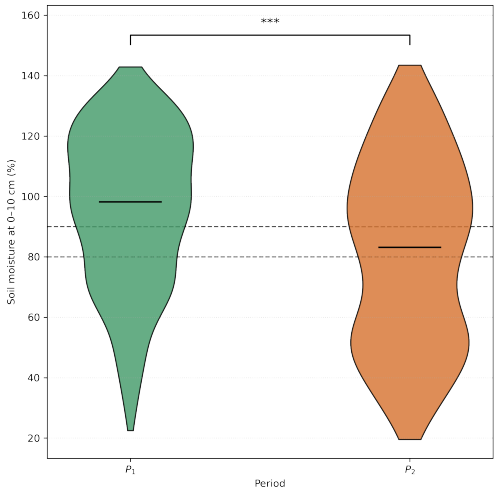

(c)

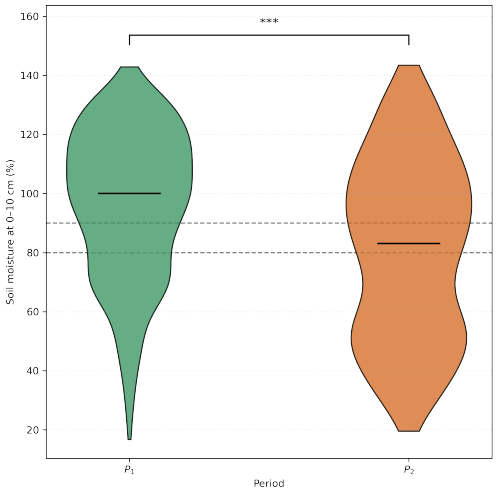

(d)

Figura 35: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

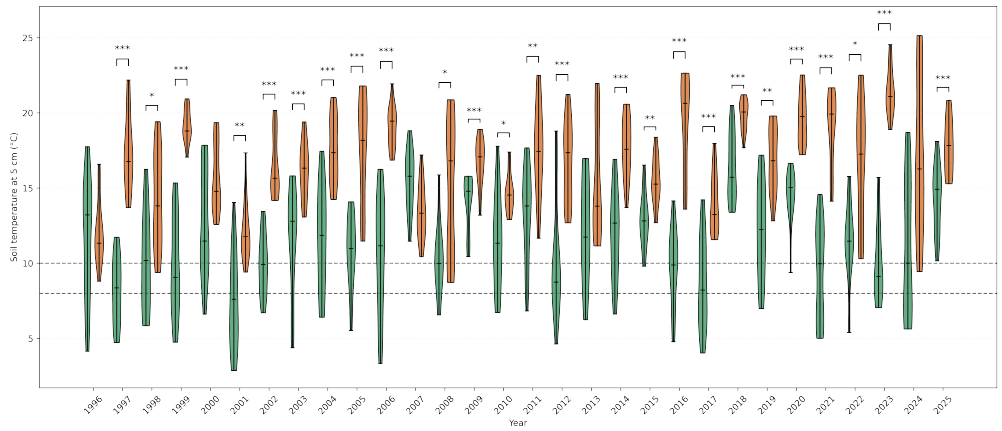

(a)

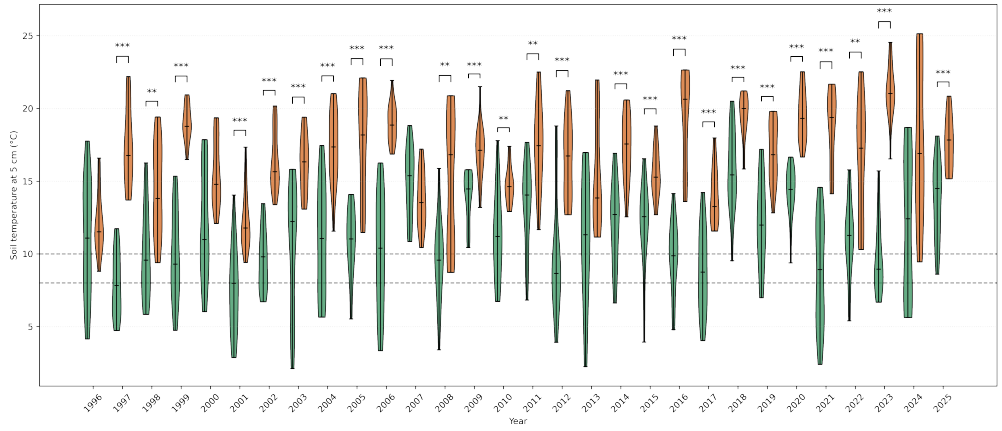

(b)

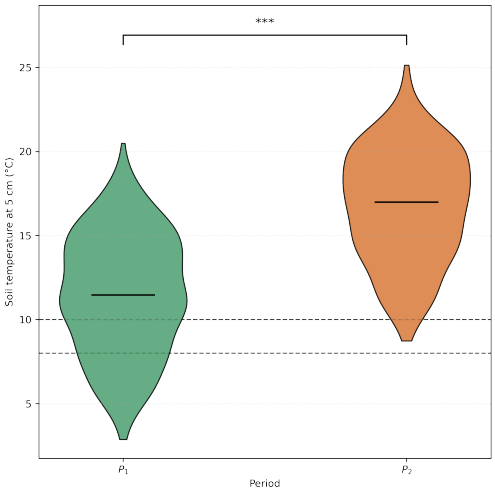

(c)

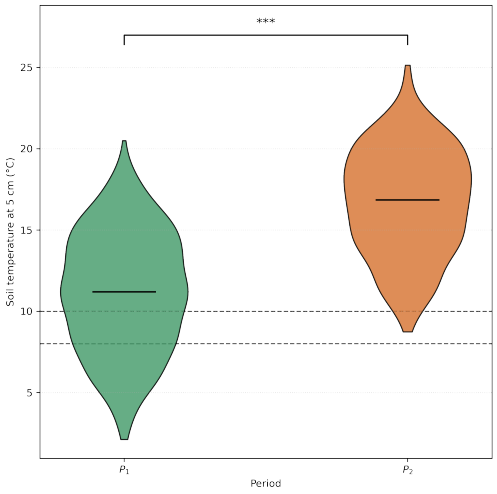

(d)

Figura 36: Temperatura media del aire para Bavariao obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

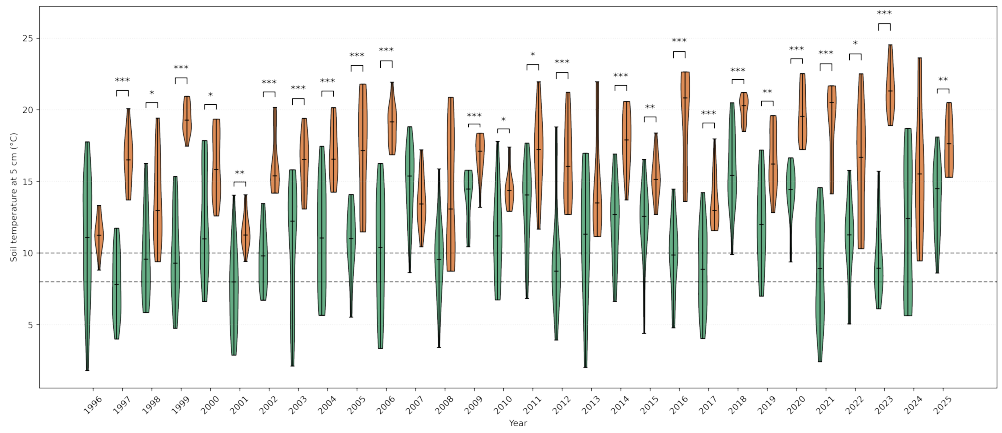

(a)

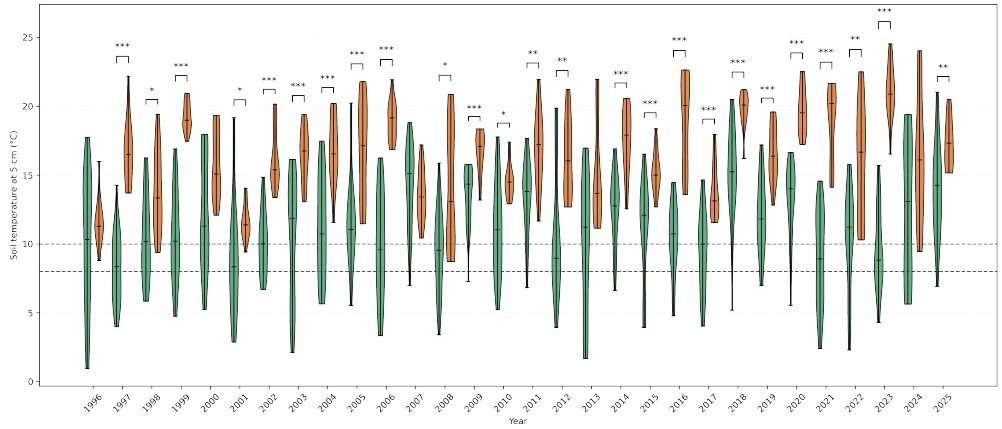

(b)

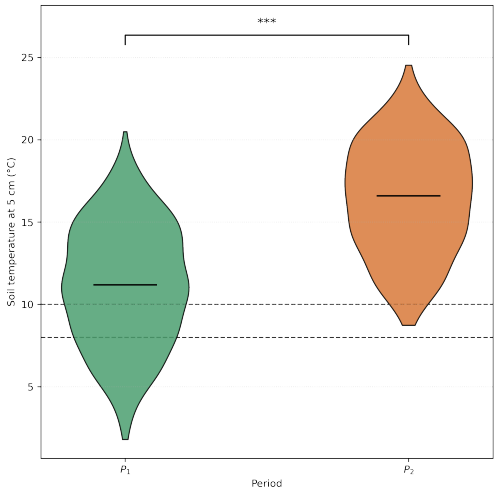

(c)

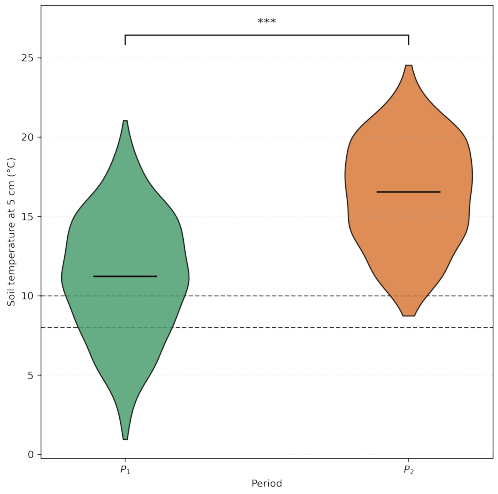

(d)

Figura 37: Temperatura media del aire para Bavaria obtenida mediante la distancia Euclidiana. Las dos primeras representaciones muestran los resultados para los datos sin agregar y sus respectivos intervalos de confianza, mientras que las dos representaciones inferiores muestran los resultados agregados para los mismos casos.

4. Cronograma de actividades

Durante el semestre en curso se contempla emplear los datos correspondientes a las fechas de siembra de maíz en Alemania, reportados por Parker et al. (2016, Tabla 1), a partir de los criterios topográficos y geográficos descritos por Flores et al. (2025), ver Tabla 10. Los cuales, tras identificar una métrica apropiada, sirvan para realizar una comparación complementaria con resultados previamente publicados.

Región	Características	Fecha de siembra
Brandemburgo Norte de Sajonia	Altitud menor que 250 m.s.n.m.	115.6 ± 7.12
	Latitud mayor o igual que 51° N.	116.2 ± 7.08
	Longitud mayor o igual que 8.5° E.	116.2 ± 7.3
Sur de Sajonia Baviera	Altitud mayor o igual que 250 m.s.n.m.	117.4 ± 8.29
	Latitud menor que 51° N.	116.7 ± 8.23
	Longitud mayor o igual que 8.5° E.	116.2 ± 7.3

Tabla 10: Fechas promedio de siembra de maíz y sus correspondientes desviaciones estándar reportadas por Parker et al. (2016), asociadas a las características geográficas y topográficas descritas por Flores et al. (2025) para Brandemburgo, Sajonia y Baviera.

Adicionalmente, se llevará a cabo la construcción de los intervalos de confianza correspondientes mediante los métodos de bootstrap y jackknife, así como la integración de restantes en la redacción del trabajo en formato de artículo. Finalmente, se contempla la presentación de los avances y resultados en el Congreso Internacional de Ecología Estadística (ISEC, por sus siglas en inglés), que se llevará a cabo del 10 al 15 de enero de 2027 en Mérida, México. Ver comprobante de aceptación aquí.

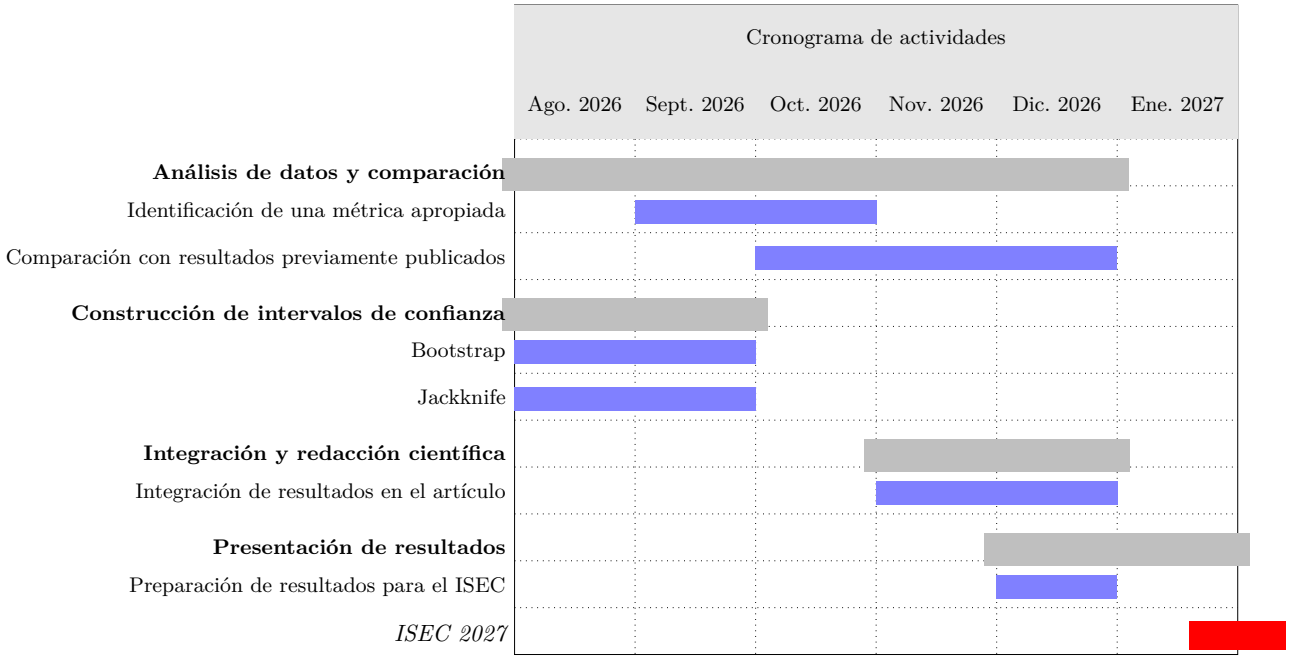

Figura 38: Cronograma de actividades correspondientes al semestre agosto–diciembre de 2026.

5. Revistas

El proyecto en desarrollo presenta tanto una metodología matemática nueva en el área de predicción fenológica como resultados con potencial impacto en el campo agrícola, dado que se trata de un calendario agrícola basado en un modelo de autoría propia. Por tanto, para la publicación del trabajo como un artículo de investigación en una revista científica se han considerado aquellas revistas cuyos alcances, objetivos y publicaciones previas sean compatibles con el balance entre un desarrollo metodológico teórico y un análisis bajo condiciones reales.

Con lo anterior y con base en la literatura consultada hasta el momento, en la siguiente tabla se presentan las revistas indexadas propuestas para someter nuestro trabajo en el mediano plazo.

Revista	**Factor de impacto**	**Referencias consultadas**
Computers and Electronics in Agriculture Editorial: Elsevier B.V.	10.3	Elnesr et al. (2013)
Sustainable Computing: Informatics and Systems Editorial: Elsevier B.V.	6.2	Gümüşçü et al. (2020)
Journal of Agronomy and Crop Science Editorial: Wiley.	3.2	Parker et al. (2016)

Tabla 11: Revistas idexadas en el Journal Citation Reports (JCR) consideradas para la publicación del artículo, factor de impacto y las referencias relacionadas con el proyecto consultadas en ellas.

Derivado del avance obtenido y considerando las actividades pendientes de programación, redacción y revisión, se propone diciembre de 2027 como fecha tentativa para el envío del manuscrito a una de las revistas antes mencionadas, correspondiendo con el final del quinto semestre del doctorado.

Referencias

S. Bag, S.K. Kumar, and M.K. Tiwari. An efficient recommendation generation using relevant jaccard similarity. *Information Sciences*, 483:53–64, May 2019. ISSN 0020-0255. doi: 10.1016/j.ins.2019.01.023. URL http://dx.doi.org/10.1016/j.ins.2019.01.023.

M.E. Baum, S.V. Archontoulis, and M.A. Licht. Planting date, hybrid maturity, and weather effects on maize yield and crop stage. *Agronomy Journal*, 111(1):303–313, 2019. doi: https://doi.org/10.2134/agronj2018.04.0297. URL https://acsess.onlinelibrary.wiley.com/doi/abs/10.2134/agronj2018.04.0297.

M. Baumberger, B. Haas, S. Sivakumar, M. Ludwig, N. Meyer, and H. Meyer. High-resolution soil temperature and soil moisture patterns in space, depth and time: An interpretable machine learning modelling approach. *Geoderma*, 451:117049, 2024. ISSN 0016-7061. doi: https://doi.org/10.1016/j.geoderma.2024.117049.

G. Bayable, G. Amare, G. Alemu, and T. Gashaw. Spatiotemporal variability and trends of rainfall and its association with pacific ocean sea surface temperature in west harerge zone, eastern ethiopia. *Environmental Systems Research*, 10:1–21, 2021.

R. Bernal-Morales, J.P. Juárez-Sánchez, B. Ramírez-Valverde, I. Ocampo-Fletes, and M.A. Velasco-Hernández. Impact of climate change on maize (zea mays l.) planting dates in the eastern region of puebla, mexico. *Agrociencia*, page 1–16, August 2025. ISSN 1405-3195. doi: 10.47163/agrociencia.v59i6.3311. URL http://dx.doi.org/10.47163/agrociencia.v59i6.3311.

C.J. Birch, G.L. Hammer, and K.G. Rickert. Temperature and photoperiod sensitivity of development in five cultivars of maize (zea mays l.) from emergence to tassel initiation. *Field Crops Research*, 55(1-2):93–107, 1 1998. ISSN 0378-4290. doi: 10.1016/s0378-4290(97)00062-2.

H. Braden. The model ambeti: A detailed description of a soil-plant-atmosphere model. *Berichte des Deutschen Wetterdienstes*, 195:VI–117, 1995. Accessed August 04, 2026, at https://opendatao.dwd.de/climate_environment/CDC/derived_germany/soil/multi_annual/mean_91-10/AMBETI.pdf.

Bundesamt für Kartographie und Geodäsie. Nuts-gebiete 1:250 000 (nuts250) – open data download, jul 2025. URL https://daten.gdz.bkg.bund.de/produkte/vg/nuts250_1231/aktuell/nuts250_12-31.utm32s.gpkg.zip. Accesado vía https://daten.gdz.bkg.bund.de/produkte/vg/nuts250_1231/aktuell/nuts250_12-31.utm32s.gpkg.zip en abril 16, 2026.

L. Busschaert, V. Deketelaere, W. Thiery, D. Raes, and G.J.M. De Lannoy. Future projections of european maize yields using aquacrop with an adaptive growing season. *European Journal of Agronomy*, 173:127920, February 2026. ISSN 1161-0301. doi: 10.1016/j.eja.2025.127920. URL http://dx.doi.org/10.1016/j.eja.2025.127920.

L. Cassani and A. Gomez-Zavaglia. Sustainable food systems in fruits and vegetables food supply chains. *Frontiers in Nutrition*, 9, February 2022. ISSN 2296-861X. doi: 10.3389/fnut.2022.829061. URL http://dx.doi.org/10.3389/fnut.2022.829061.

F.M. Chmielewski, A. Müller, and E. Bruns. Climate changes and trends in phenology of fruit trees and field crops in germany, 1961–2000. *Agricultural and Forest Meteorology*, 121(1):69–78, 2004. ISSN 0168-1923. doi: https://doi.org/10.1016/S0168-1923(03)00161-8. URL https://www.sciencedirect.com/science/article/pii/S0168192303001618.

I. Chuine and J. Régnière. Process-based models of phenology for plants and animals. *Annual Review of Ecology, Evolution, and Systematics*, 48(Volume 48, 2017):159–182, 2017. ISSN 1545-2069. doi: https://doi.org/10.1146/annurev-ecolsys-110316-022706. URL https://www.annualreviews.org/content/journals/10.1146/annurev-ecolsys-110316-022706.

F.A. Coffman. The minimum temperature of germination of seeds. *Agronomy Journal*, 15(7):257–270, 7 1923. ISSN 1435-0645. doi: 10.2134/agronj1923.00021962001500070001x.

E. Cuevas, J. Blancas, J. Caballero, I. A Hinojosa-Díaz, and A. Martínez-Ballesté. Agricultural management and local knowledge: key factors for the conservation of socio-ecosystems in the face of the pollinator world crisis. *Botanical Sciences*, 99(2):305–320, 2021.

C.M. da Silva, F.C. Araújo Ribeiro, J.W. Vieira, and C.A. da Silva Filho. Bootstrap interval with application in environmental monitoring. *International Journal of Environmental Studies*, 77(2):335–348, June 2019. ISSN 1029-0400. doi: 10.1080/00207233.2019.1630108. URL http://dx.doi.org/10.1080/00207233.2019.1630108.

G. de Anda-Jauregui and E. Hernandez-Lemus. Identification of potential adverse drug reactions using random walk on network models. In *2021 Mexican International Conference on Computer Science (ENC)*, page 1–6. IEEE, August 2021. doi: 10.1109/enc53357.2021.9534826. URL http://dx.doi.org/10.1109/ENC53357.2021.9534826.

Deutscher Wetterdienst (DWD). Erläuterungen zur nutzbaren Feldkapazität (% nFK), 2024. Accessed August 5, 2026, at https://www.dwd.de/DE/fachnutzer/landwirtschaft/dokumentationen/allgemein/basis_einheiten_nfk_doku.html.

Z. Domokos, A. Șimon, F. Chețan, O.A. Ceclan, E. Filip, R.E. Călugăr, S.D. Vâtcă, and M.M. Duda. The influence of sowing date on the primary yield components of maize. *Agronomy*, 14(9):2120, 9 2024. ISSN 2073-4395. doi: 10.3390/agronomy14092120.

C. Donmez, M. Schmidt, A. Cilek, M. Grosse, C. Paul, W. Hierold, and K. Helming. Climate change impacts on long-term field experiments in germany. *Agricultural Systems*, 205:103578, 2023. ISSN 0308-521X. doi: https://doi.org/10.1016/j.agsy.2022.103578. URL https://www.sciencedirect.com/science/article/pii/S0308521X22002141.

C. Duden, C. Nacke, and F. Offermann. German yield and area data for 11 crops from 1979 to 2021 at a harmonized spatial resolution of 397 districts. *Scientific Data*, 11(1), January 2024. ISSN 2052-4463. doi: 10.1038/s41597-024-02951-8. URL http://dx.doi.org/10.1038/s41597-024-02951-8.

DWD Climate Data Center (CDC). Daily grids of mean soil moisture under maize for germany, version v1.0, 2024. Accessed August 5, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/soil_moisture/maize/.

DWD Climate Data Center (CDC). Raster data set of maximum temperature in ° C for Germany - HYRAS-DE-TASMAX v6-1, Version v6-1, 2025a. Accessed July 31, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/hyras_de/air_temperature_max/.

DWD Climate Data Center (CDC). Raster data set of mean temperature in ° C for Germany - HYRAS-DE-TAS v6-1, Version v6-1, 2025b. Accessed July 31, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/hyras_de/air_temperature_mean/.

DWD Climate Data Center (CDC). Raster data set of minimum temperature in ° C for Germany - HYRAS-DE-TASMIN v6-1, Version v6-1, 2025c. Accessed July 31, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/hyras_de/air_temperature_min/.

DWD Climate Data Center (CDC). Raster data set of mean relative humidity in % for Germany - HYRAS-DE-HURS v6-1, Version v6-1, 2025d. Accessed July 31, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/hyras_de/humidity/.

DWD Climate Data Center (CDC). Daily grids of soil temperature at 5 cm depth, 2025e. Accessed July 29, 2026, at https://opendata.dwd.de/climate_environment/CDC/grids_germany/daily/soil_temperature_5cm/DESCRIPTION_gridsgermany_daily_soil_temperature_5cm_en.pdf.

M.N. Elnesr, A.A. Alazba, and A.A. Alsadon. An arithmetic method to determine the most suitable planting dates for vegetables. *Computers and Electronics in Agriculture*, 90:131–143, 2013. ISSN 0168-1699. doi: https://doi.org/10.1016/j.compag.2012.09.010. URL https://www.sciencedirect.com/science/article/pii/S0168169912002323.

O. Erenstein, M. Jaleta, K. Sonder, K. Mottaleb, and B.M. Prasanna. Global maize production, consumption and trade: trends and r& d implications. *Food Security*, 14(5):1295–1319, May 2022. ISSN 1876-4525. doi: 10.1007/s12571-022-01288-7. URL http://dx.doi.org/10.1007/s12571-022-01288-7.

M.S. Farooq, M. Uzair, A. Raza, M. Habib, Y. Xu, M. Yousuf, S.H. Yang, and M. Ramzan Khan. Uncovering the research gaps to alleviate the negative impacts of climate change on food security: a review. *Frontiers in plant science*, 13:927535, 2022.

L. Flores, C. Nendel, B. Bookhagen, J.A. Oviedo Reyes, T. Smith, and G. Ghazaryan. The potential of sentinel-1 time series for large-scale assessment of maize and wheat phenology across germany. *GIScience & Remote Sensing*, 62(1), July 2025. ISSN 1943-7226. doi: 10.1080/15481603.2025.2531593. URL http://dx.doi.org/10.1080/15481603.2025.2531593.

Food and Agriculture Organization of the United Nations. *Seeds in emergencies: A technical handbook*. FAO Plant Production and Protection Papers. Food and Agriculture Organization of the United Nations (FAO), Rome, Italy, March 2011.

B. Franch, J. Cintas, I. Becker-Reshef, M.J. Sanchez-Torres, J. Roger, S. Skakun, J.A. Sobrino, K. Van Tricht, J. Degerickx, S. Gilliams, B. Koetz, Z. Szantoi, and A. Whitcraft. Global crop calendars of maize and wheat in the framework of the worldcereal project. *GIScience & Remote Sensing*, 59(1):885–913, 2022.

A. García-Mendoza. Distribution of agave (agavaceae) in mexico. 74:177–187, 2002. ISSN 1938-288X 0007-9367.

R. Gatto and S.R. Jammalamadaka. Directional statistics: Introduction, March 2015. URL http://dx.doi.org/10.1002/9781118445112.stat00201.pub2.

C.M. Grinstead and J.L. Snell. *Introduction to Probability*. American Mathematical Society, Providence, RI, 2nd edition, 2003.

G.J.H. Grubben and S. Partohardjono. Plant resources of south east asia. *Botanical Journal of the Linnean Society*, 123(3):261, 1997.

W.S.C. Gurney, P.H. Crowley, and R.M. Nisbet. Locking life-cycles onto seasons: Circle-map models of population dynamics and local adaptation. *Journal of Mathematical Biology*, 30(3):251–279, January 1992. ISSN 1432-1416. doi: 10.1007/bf00176151. URL http://dx.doi.org/10.1007/BF00176151.

A. Gümüşçü, M.E. Tenekeci, and A.V. Bilgili. Estimation of wheat planting date using machine learning algorithms based on available climate data. *Sustainable Computing: Informatics and Systems*, 28:100308, 2020. ISSN 2210-5379. doi: https://doi.org/10.1016/j.suscom.2019.01.010. URL https://www.sciencedirect.com/science/article/pii/S2210537918302452.

B. Hennemuth, S. Bender, K. Bülow, N. Dreier, E. Keup-Thiel, O. Krüger, C. Mudersbach, C. Radermacher, and R. Schoetter. Statistical methods for the analysis of simulated and observed climate data: applied in projects and institutions dealing with climate change impact and adaptation. Climate Service Center Germany, 2013.

M. Herbst, E. Falge, and C. Frühauf. Regionale klimamodellierung – perspektive landwirtschaft. *promet 104*, page Beitrag 8, 2021. doi: 10.5676/DWD_PUB/PROMET_104_08.

J.G. Kemeny and J.L. Snell. *Finite Markov chains*. Undergraduate Texts in Mathematics. Springer, New York, NY, 1 edition, July 1976.

J.R. Kiniry, J.R. Williams, D.J. Major, R.C. Izaurralde, P.W. Gassman, M. Morrison, R. Bergentine, and R.P. Zentner. Epic model parameters for cereal, oilseed, and forage crops in the northern great plains region. *Canadian Journal of Plant Science*, 75(3):679–688, 7 1995. ISSN 1918-1833. doi: 10.4141/cjps95-114.

S. Krähenmann, A. Walter, S. Brienen, F. Imbery, and A. Matzarakis. High-resolution grids of hourly meteorological variables for germany. *Theoretical and Applied Climatology*, 131(3-4):899–926, 12 2016. ISSN 1434-4483. doi: 10.1007/s00704-016-2003-7.

F. Laidig, T. Feike, H. Brandes, and H-P. Piepho. Breeding progress of grain and forage maize in long-term variety trials compared to on-farm yield development. *Theoretical and Applied Genetics*, 138(12), November 2025. ISSN 1432-2242. doi: 10.1007/s00122-025-05085-6. URL http://dx.doi.org/10.1007/s00122-025-05085-6.

N.V. Long, Y. Assefa, R. Schwalbert, and I.A. Ciampitti. Maize yield and planting date relationship: A synthesis-analysis for us high-yielding contest-winner and field research data. *Frontiers in Plant Science*, 8, December 2017. ISSN 1664-462X. doi: 10.3389/fpls.2017.02106. URL http://dx.doi.org/10.3389/fpls.2017.02106.

K.V. Mardia and P.E. Jupp. *Directional Statistics*. Wiley, January 1999. ISBN 9780470316979. doi: 10.1002/9780470316979. URL http://dx.doi.org/10.1002/9780470316979.

D.L. Martin and D.J. Thrailkill. Moisture and humidity requirements for germination of surface seeded corn. *Applied Engineering in Agriculture*, 9(1):43–48, 1993. ISSN 1943-7838. doi: 10.13031/2013.25963.

S. Mason, T. Galusha, and Z. Kmail. Planting date influence on yield of drought-tolerant maize with different maturity classifications. *Agronomy Journal*, 110(1):293–299, 2018. doi: https://doi.org/10.2134/agronj2017.06.0326. URL https://acsess.onlinelibrary.wiley.com/doi/abs/10.2134/agronj2017.06.0326.

T. Miedaner and P. Juroszek. Global warming and increasing maize cultivation demand comprehensive efforts in disease and insect resistance breeding in north-western europe. *Plant Pathology*, 70(5):1032–1046, 2021. doi: https://doi.org/10.1111/ppa.13365. URL https://bsppjournals.onlinelibrary.wiley.com/doi/abs/10.1111/ppa.13365.

I.J. Mirón, C. Linares, and J. Díaz. The influence of climate change on food production and food safety. *Environmental Research*, 216:114674, 2023. ISSN 0013-9351. doi: https://doi.org/10.1016/j.envres.2022.114674. URL https://www.sciencedirect.com/science/article/pii/S0013935122020011.

Y. Mo, G. Li, D. Wang, F.R. Lamm, J. Wang, Y. Zhang, M. Cai, and S. Gong. Planting and preemergence irrigation procedures to enhance germination of subsurface drip irrigated corn. *Agricultural Water Management*, 242:106412, December 2020. ISSN 0378-3774. doi: 10.1016/j.agwat.2020.106412.

A.F. Moraes García, L. Micheletti Broglio, M. Santoro Brossi, N. Teixeira dos Santos, T. Avilés Cantuarias, and S. da Silva Rodrigues. Horticultural performance of 'hass' avocado grafted onto seedling and clonal rootstocks under tropical wet-dry climate conditions. *Scientia Horticulturae*, 302:111155, August 2022. ISSN 0304-4238. doi: 10.1016/j.scienta.2022.111155. URL http://dx.doi.org/10.1016/j.scienta.2022.111155.

S.S. Myers, A. Zanobetti, I. Kloog, P. Huybers, A.D.B. Leakey, A.J. Bloom, E. Carlisle, L.H. Dietterich, G. Fitzgerald, T. Hasegawa, N.M. Holbrook, R.L. Nelson, M.J. Ottman, V. Raboy, H. Sakai, K.A. Sartor, J. Schwartz, S. Seneweera, M. Tausz, and Y. Usui. Increasing co2 threatens human nutrition. *Nature*, 510(7503):139–142, May 2014. ISSN 1476-4687. doi: 10.1038/nature13179. URL http://dx.doi.org/10.1038/nature13179.

National Research Council. *Lessons from the Past Provide Direction for the Future*, pages 1–22. National Academies Press, Washington, DC, 1996. doi: 10.17226/5135. URL https://nap.nationalacademies.org/read/5135/chapter/3.

Q. Orozco-Ramírez, H. Perales, and R.J. Hijmans. Geographical distribution and diversity of maize (zea mays l. subsp. mays) races in mexico. *Genetic Resources and Crop Evolution*, 64(5):855–865, April 2016. ISSN 1573-5109. doi: 10.1007/s10722-016-0405-0. URL http://dx.doi.org/10.1007/s10722-016-0405-0.

B. Pan, Y.M. Bai, S. Leibovitch, and D.L. Smith. Plant-growth-promoting rhizobacteria and kinetin as ways to promote corn growth and yield in a short-growing-season area. *European Journal of Agronomy*, 11(3-4):179–186, 11 1999. ISSN 1161-0301. doi: 10.1016/s1161-0301(99)00029-5.

R. Parajuli, G. Thoma, and M.D. Matlock. Environmental sustainability of fruit and vegetable production supply chains in the face of climate change: A review. *Science of The Total Environment*, 650:2863–2879, 2019. ISSN 0048-9697. doi: https://doi.org/10.1016/j.scitotenv.2018.10.019. URL https://www.sciencedirect.com/science/article/pii/S0048969718338920.

B. Parent and F. Tardieu. Temperature responses of developmental processes have not been affected by breeding in different ecological areas for 17 crop species. *New Phytologist*, 194(3):760–774, March 2012. ISSN 1469-8137. doi: 10.1111/j.1469-8137.2012.04086.x. URL http://dx.doi.org/10.1111/j.1469-8137.2012.04086.x.

B. Parent, M. Leclere, S. Lacube, M.A. Semenov, C. Welcker, P. Martre, and F. Tardieu. Maize yields over europe may increase in spite of climate change, with an appropriate use of the genetic variability of flowering time. *Proceedings of the National Academy of Sciences*, 115(42):10642–10647, 2018. doi: 10.1073/pnas.1720716115. URL https://www.pnas.org/doi/abs/10.1073/pnas.1720716115.

P.S. Parker, J.S. Shonkwiler, and J. Aurbacher. Cause and consequence in maize planting dates in germany. *Journal of Agronomy and Crop Science*, 203(3):227–240, 2016. doi: https://doi.org/10.1111/jac.12182. URL https://onlinelibrary.wiley.com/doi/abs/10.1111/jac.12182.

M. Peichl, S. Thober, V. Meyer, and L. Samaniego. The effect of soil moisture anomalies on maize yield in germany. *Natural Hazards and Earth System Sciences*, 18(3):889–906, 3 2018. ISSN 1684-9981. doi: 10.5194/nhess-18-889-2018.

R. Peter, T.W. Eschholz, P. Stamp, and M. Liedgens. Early growth of flint maize landraces under cool conditions. *Crop Science*, 49(1):169–178, 1 2009. ISSN 1435-0653. doi: 10.2135/cropsci2007.10.0538.

F.T. Portmann, S. Siebert, and P. Döll. Mirca2000—global monthly irrigated and rainfed crop areas around the year 2000: A new high-resolution data set for agricultural and hydrological modeling. *Global Biogeochemical Cycles*, 24(1), 2010. doi: https://doi.org/10.1029/2008GB003435. URL https://agupubs.onlinelibrary.wiley.com/doi/abs/10.1029/2008GB003435.

J.A. Powell and J.A. Logan. Insect seasonality: circle map analysis of temperature-driven life cycles. *Theoretical Population Biology*, 67(3):161–179, May 2005. ISSN 0040-5809. doi: 10.1016/j.tpb.2004.10.001. URL http://dx.doi.org/10.1016/j.tpb.2004.10.001.

K.M. Ramachandran and C.P. Tsokos. *Mathematical Statistics with Applications*. Elsevier Science, 2009. ISBN 9780080951706. URL https://books.google.com.mx/books?id=YFyhXk-ONWwC.

P. Ranum, J.P. Peña-Rosas, and M.N. Garcia-Casal. Global maize production, utilization, and consumption. *Annals of the New York Academy of Sciences*, 1312(1):105–112, 2014. doi: https://doi.org/10.1111/nyas.12396. URL https://nyaspubs.onlinelibrary.wiley.com/doi/abs/10.1111/nyas.12396.

K.D. Rausch and R.L. Belyea. The future of coproducts from corn processing. *Applied Biochemistry and Biotechnology*, 128(1):047–086, 2006. ISSN 0273-2289. doi: 10.1385/abab:128:1:047. URL http://dx.doi.org/10.1385/ABAB:128:1:047.

C. Razafimaharo, S. Krähenmann, S. Höpp, M. Rauthe, and T. Deutschländer. New high-resolution gridded dataset of daily mean, minimum, and maximum temperature and relative humidity for central europe (hyras). *Theoretical and Applied Climatology*, 142(3-4):1531–1553, 9 2020. ISSN 1434-4483. doi: 10.1007/s00704-020-03388-w.

J. Régnière and J.A. Powell. *Animal Life Cycle Models (Poikilotherms)*, pages 295–316. Springer Netherlands, Dordrecht, 2013. ISBN 978-94-007-6925-0. doi: 10.1007/978-94-007-6925-0_16. URL https://doi.org/10.1007/978-94-007-6925-0_16.

P. Revilla, M.L. Alves, V. Andelković, C. Balconi, I. Dinis, P. Mendes-Moreira, R. Redaelli, J.I. Ruiz de Galarreta, M.C. Vaz Patto, S. Žilić, and R.A. Malvar. Traditional foods from maize (zea mays l.) in europe. *Frontiers in Nutrition*, 8, 2022. ISSN 2296-861X. doi: 10.3389/fnut.2021.683399.

J.L. Rocha-Arroyo, S. Salazar-García, A.E. Bárcenas-Ortega, I.J.L. González-Durán, and L.E. Cossio-Vargas. Fenología del aguacate "Hass"' en Michoacán. *Revista mexicana de ciencias agrícolas*, 2(3):303–316, 2011.

W.J. Sacks and C.J. Kucharik. Crop management and phenology trends in the u.s. corn belt: Impacts on yields, evapotranspiration and energy balance. *Agricultural and Forest Meteorology*, 151(7):882–894, July 2011. ISSN 0168-1923. doi: 10.1016/j.agrformet.2011.02.010.

W.J. Sacks, D. Deryng, J.A. Foley, and N. Ramankutty. Crop planting dates: an analysis of global patterns. *Global Ecology and Biogeography*, 19(5):607–620, August 2010. ISSN 1466-8238. doi: 10.1111/j.1466-8238.2010.00551.x. URL http://dx.doi.org/10.1111/j.1466-8238.2010.00551.x.

C.A. Schloeder, N.E. Zimmerman, and M.J. Jacobs. Comparison of methods for interpolating soil properties using limited data. *Soil Science Society of America Journal*, 65(2):470–479, 2001. doi: https://doi.org/10.2136/sssaj2001.652470x.

K.R. Shivanna. Climate change and its impact on biodiversity and human welfare. *Proceedings of the Indian National Science Academy*, 88(2):160–171, May 2022. ISSN 2454-9983. doi: 10.1007/s43538-022-00073-6. URL http://dx.doi.org/10.1007/s43538-022-00073-6.

A.A. Sokan-Adeaga, S.A. Salami, D.O. Bolade, M. Aledeh, M.A. Sokan-Adeaga, O.E. Amubieya, S.A. Kehinde, M. Farzadkia, G.M. Ashraf, and E. Hoseinzadeh. Utilization of local corn (zea mays) wastes for bioethanol production by separate hydrolysis and fermentation. *Journal of Hazardous Materials Advances*, 15:100447, 2024. ISSN 2772-4166. doi: https://doi.org/10.1016/j.hazadv.2024.100447. URL https://www.sciencedirect.com/science/article/pii/S2772416624000482.

P. Su, A. Zhang, J. Wang, and W. Xu. Plausible maize planting distribution under future global change scenarios. *Field Crops Research*, 302:109079, 2023. ISSN 0378-4290. doi: https://doi.org/10.1016/j.fcr.2023.109079. URL https://www.sciencedirect.com/science/article/pii/S0378429023002721.

B. Sánchez, A. Rasmussen, and J.R. Porter. Temperatures and the growth and development of maize and rice: a review. *Global Change Biology*, 20(2):408–417, 2014. doi: https://doi.org/10.1111/gcb.12389. URL https://onlinelibrary.wiley.com/doi/abs/10.1111/gcb.12389.

S.A. Tanumihardjo, L. McCulley, R. Roh, S. Lopez-Ridaura, N. Palacios-Rojas, and N.S. Gunaratna. Maize agro-food systems to ensure food and nutrition security in reference to the sustainable development goals. *Global Food Security*, 25:100327, 2020. ISSN 2211-9124. doi: https://doi.org/10.1016/j.gfs.2019.100327. URL https://www.sciencedirect.com/science/article/pii/S2211912419300112.

S.D. Vâtcă, V.A. Stoian, T.C. Man, C. Horvath, R. Vidican, Ș. Gâdea, A. Vâtcă, A. Rotaru, R. Vârban, M. Cristina, and V. Stoian. Agrometeorological requirements of maize crop phenology for sustainable cropping—a historical review for romania. *Sustainability*, 13(14):7719, 7 2021. ISSN 2071-1050. doi: 10.3390/su13147719.

K. Waha, L.G.J. van Bussel, C. Müller, and A. Bondeau. Climate-driven simulation of global crop sowing dates. *Global Ecology and Biogeography*, 21(2):247–259, 5 2011. ISSN 1466-8238. doi: 10.1111/j.1466-8238.2011.00678.x.

C.-H. Wang. Farming methods effects on the soil fertility and crop production under a rice-vegetables cropping sequences. *Journal of Plant Nutrition*, 37(9):1498–1513, 2014. doi: 10.1080/01904167.2014.881876. URL https://doi.org/10.1080/01904167.2014.881876.

I.J. Warrington and E.T. Kanemasu. Corn growth response to temperature and photoperiod i. seedling emergence, tassel initiation, and anthesis. *Agronomy Journal*, 75(5):749–754, 9 1983. ISSN 1435-0645. doi: 10.2134/agronj1983.00021962007500050008x.

Y. Zhang, J. Liu, L. Guan, D. Fan, F. Xia, A. Wang, Y. Bao, and Y. Xu. By-products of zea mays l.: A promising source of medicinal properties with phytochemistry and pharmacological activities: A comprehensive review. *Chemistry & Biodiversity*, 20(3):e202200940, 2023. doi: https://doi.org/10.1002/cbdv.202200940. URL https://onlinelibrary.wiley.com/doi/abs/10.1002/cbdv.202200940.