

Modelación probabilística de periodos óptimos de siembra del maíz en condiciones de cambio climático. Caso de estudio en Alemania.

Introducción

Las flores, frutas, vegetales y hongos representan un pilar fundamental en la cadena alimentaria [19]. La industria agrícola, responsable de su producción continua, enfrenta desafíos crecientes debido a la incertidumbre respecto a las condiciones de cultivo, las cuales se han visto afectadas, en gran parte, por el cambio climático [111].

Respecto a las estaciones del año, el cambio climático ha implicado un desfase su duración, alterando sus fechas de inicio y término. Las cuatro estaciones del año se definen a partir de criterios biológicos y físicos [162]. De esta manera, se ha determinado que, en el hemisferio norte, la duración del verano se ha prolongado de manera estadísticamente significativa; mientras que la duración del resto de estaciones se han reducido y se especula que esta tendencia se exacerbe en los próximos años [173], tanto por factores naturales como por factores ligados a la actividad humana [115].

Estas alteraciones repercuten en diversos aspectos, entre ellos el ciclo de producción agrícola, debido a variaciones inusuales e inesperadas en temperatura, precipitación y patrones de migración de polinizadores, entre otros factores. Los cuales, en conjunto, han modificado las zonas, temporadas y rendimiento de los cultivos [10, 30, 111].

Esto es especialmente relevante, ya que la estabilidad de los procesos productivos depende de cierta consistencia en las condiciones ambientales. Sin embargo, las circunstancias a las que nos enfrentamos actualmente, derivadas principalmente por el cambio climático, han incrementado la inestabilidad en la seguridad alimentaria y el desabasto a la par de reducir la producción y exportación, impactando directamente la economía de las naciones [44].

Cada cultivo prospera dentro de umbrales agro-ambientales específicos, que en muchos casos, han sido ya ampliamente descritos con anterioridad en la literatura científica; e.g., el aguacate [102, 140] o el agave [55]. El maíz (*Zea mays*), un cultivo de origen mexicano [109], representa un caso particular al ser considerado como uno de los cultivos más importantes a nivel mundial para el abastecimiento alimenticio directo e indirecto y sus usos industriales [136].

Desde su domesticación, ocurrida hace más de 9000 años [116, 182], el maíz ha sido empleado para consumo tanto de dieta primaria como de dieta secundaria; i.e., incorporado en conjunto con otros alimentos o para forrajeo [136]. Más aún, el maíz tiene un papel crucial en diversas actividades del sector productivo y de manufactura [129]; e.g., cervezas, jarabes, harinas, medicamentos y biocombustibles [132, 149, 187].

De esta manera, la importancia del maíz trasciende al sector alimentario y es por tanto que ha tomado relevancia a nivel mundial. De acuerdo con Erenstein *et al.* (2021) [41] y Erenstein *et al.* (2022) [42], anualmente se destinan aproximadamente 200 millones de hectáreas para la plantación de maíz las cuales se encuentran distribuidas principalmente en América (36.10 %) y Asia (34.08 %) seguidas por África (20.86 %), Europa (8.91 %) y, finalmente, Oceanía (0.05 %) [42].

Lo antes mencionado nos indica que las plantaciones de maíz se distribuyen de manera asimétrica alrededor del mundo [129]; en contraste, como producto alimenticio está presente en la dieta mundial [42]. El consumo de este cultivo aporta, en promedio, el 5.3 %, el 4.6 % y 1.6 % de la ingesta calórica, proteica y grasa, respectivamente, per capita diaria [42].

De acuerdo con Erenstein *et al.* (2021) [41], para finales de 2019, la Organización de las Naciones Unidas para la Alimentación y la Agricultura (FAO, por sus siglas en inglés) reportó una producción de 1137 millones de toneladas de maíz. El maíz puede clasificarse por su tamaño, dulzor, composición del endospermo o color [129]; no obstante, comparten su respuesta a las condiciones de cultivo [154, 114].

Desde la siembra hasta la cosecha, la fenología del maíz; i.e., las etapas de desarrollo, puede describirse de manera robusta en función de la temperatura [88]. En este sentido, se ha demostrado que la relación entre temperatura y tasa de desarrollo es consistente entre las distintas variedades [114].

Un calendario agrícola provee de información crítica respecto a las etapas del cultivo tales como la siembra o la cosecha [53]. Además del alza en la frecuencia de eventos climáticos extremos [99], el incremento de la temperatura promedio del planeta [146] y los desfases en la duración de las estaciones del año [172], el cambio climático ha alterado la distribución espacial de las zonas de cultivo [153] y los calendarios agrícolas [53].

Lo anterior impone a la agricultura un reto para garantizar la calidad y la cantidad de productos para satisfacer las necesidades alimentarias en el futuro [99]. Por otro lado, respecto al maíz, se ha observado que las fechas de siembra juegan un rol determinante en la cosecha resultante [9, 11, 89, 92, 117, 143], motivo por el cual este trabajo se centra en proponer una recalendarización de la ventana de fechas de siembra que garanticen ciclos de desarrollo sano y reduzcan la exposición al estrés.

Asimismo, en consecuencia del cambio climático, las regiones con mayor altitud y aquellas al norte de la región noroeste de Europa, en particular Alemania, tendrán un incremento en las zonas con potencial de producción agrícola del maíz [98]. No obstante, dicha transición implica retos en tanto a la renovación de la planeación, la gestión, el desarrollo y la correcta implementación de las técnicas agrícolas relativas al manejo y cuidado del cultivo [113, 37].

A pesar de ello, la identificación de ventanas óptimas de siembra, bajo la transición que su-

pone el cambio climático, continúa siendo limitada, no por desinterés sino por la tendencia a considerarlas estáticas [117], la complejidad inherente a la incertidumbre climática [171] y por falta de especificidad en la información disponible correspondiente a las fechas de plantación [124, 142]. En este sentido, este estudio pretende robustecer la planificación de fechas de siembra del maíz, a partir de la implementación de herramientas analíticas y computacionales para la toma de dicha decisión, dadas las demandas de actualización que implica el futuro panorama agrícola de Alemania.

Finalmente, el maíz constituye un cultivo estratégico no solo por su relevancia productiva y económica, sino también por su estabilidad nutricional bajo escenarios de elevadas concentraciones atmosféricas de CO₂ [104] y su papel en la seguridad alimentaria global [155]. Estas características, en conjunto con la expansión proyectada de su área potencial de cultivo en regiones como Alemania, refuerzan la necesidad de optimizar la planificación agronómica en dichas zonas. En consecuencia, el presente estudio se orienta a la determinación de ventanas óptimas de siembra mediante el análisis de datos históricos con el objetivo de anticipar y mitigar riesgos asociados al cambio climático.

Revisión del estado del arte

Los cultivos anuales; i.e., aquellos que completan su ciclo de vida en, a lo más, un año [147], son altamente sensibles al clima [59]. En particular, se ven afectados por las tendencias a largo plazo de la temperatura y precipitación promedio, la variabilidad climática interanual, las perturbaciones durante el desarrollo de etapas fenológicas específicas y los eventos meteorológicos extremos [46].

En escenarios climáticos poco favorables para la industria agrícola, se ha observado la tendencia de abandonar las zonas de cultivo dado que los ingresos esperados no compensarían los costos asociados a la recolección [31]. Este fenómeno es más frecuente en países en desarrollo [22]; no obstante, las decisiones agrícolas pueden ajustarse ante la ocurrencia de estos eventos [31] al aludir, por ejemplo, a observaciones del comportamiento de la fauna y flora, experiencias previas y/o el conocimiento ancestral [103].

Las estrategias para reducir el estrés inducido por los riesgos climáticos en la agricultura incluyen a la diversificación de cultivos, reducir la labranza, emplear variedades más resistentes, transicionar a sistemas integrados mixtos de agricultura y ganadería, introducir infraestructura para irrigación, cambiar los medios de almacenamiento de los productos y recalendarizar fechas [184, 31, 22].

Para cada cultivo, el calendario agrícola asociado a él detalla la secuencia cronológica en la que suceden las diversas etapas fenológicas asociadas a su ciclo de crecimiento [118]. En el ciclo de crecimiento las semillas son cruciales ya que, simultáneamente, estas son la fuente y el producto de las planta [63]; consecuentemente, las fechas de siembra tienen un papel

relevante en los calendarios agrícolas.

En plantas, la fenología describe los requerimientos ambientales para su desarrollo a la par de detallar la respuesta de la planta, en sus diversas etapas de vida, a los estresores ambientales [38]. De esta manera, la fenología monitorea, entiende y predice el acontecimiento de estos eventos biológicos que son desencadenados por cambios en el clima y la meteorología [72, 84, 21, 133, 138].

Por tanto, la fenología es una descripción integral tanto de las respuestas de los organismos como de las respuestas funcionales de los ecosistemas, ambos, ante el cambio climático [139, 138]. Se han observado cambios locales en la fenología [28]; por ejemplo, la duración de las temporadas de cultivo se ha prolongado presentando una tendencia hacia ser iniciadas en épocas más tempranas [87].

En este contexto, la documentación de calendarios agrícolas a escala global ha sido fundamental para estudiar, cuantificar y modelar las variaciones en los periodos de interés productivo [66]. Con base en la metodología empleada para generarlos, los calendarios agrícolas pueden clasificarse en tres categorías: basados en información local, basados en modelos agrícolas o basados en observaciones de la Tierra [53].

Los calendarios agrícolas generados a partir de información local provienen datos recopilados por agencias internacionales, visitas de campo, informes de expertos o de interpolaciones espaciales de censos [53]. No obstante, su resolución carece de especificidad regional por lo que no captura las variaciones particulares en el inicio y fin de las temporadas de cultivo [175].

Respecto a los calendarios agrícolas basados en modelos, estos se construyen con el objetivo de caracterizar las relaciones entre las variables climáticas y las etapas fenológicas de los cultivos [53]. La versatilidad tanto en la particularización de zonas geográficas y cultivos como en sus usos es amplia [101, 177]; no obstante, son susceptibles tanto al sobreajuste o la sobresimplificación como a incertidumbres estructurales derivadas de la selección de variables, la parametrización y la calidad de los datos de entrada [108].

Los modelos agrícola contruidos a través de observaciones de la Tierra emplean la metodología denominada Fenología de la Superficie Terrestre (LSP, por sus siglas en inglés) [53]. Bajo este paradigma se detectan cambios en la vegetación a través de observaciones remotas provenientes de satélites [75]. Identifica la primera y la última señal de cobertura espacial de la vegetación identificándolas con el inicio y el fin de la temporada de cultivo, respectivamente; no obstante, usualmente, reportan fechas de inicio retrasadas y fechas de término anticipadas [53].

En este contexto, el presente trabajo se desarrolla para robustecer la categoría de calendarios agrícolas basados en modelos agrícolas. Lo anterior, aportando un modelo probabilístico que satisfaga los estándares propuestos por Whitcraft et al. (2015) [175] considerando una

cobertura espacial amplia, integrando la variabilidad espacial en las prácticas de cultivo y las condiciones climáticas y definiendo explícitamente el periodo de referencia; esto, para asegurar su relevancia y aplicabilidad.

Las interacciones entre las temperaturas y el lapso en que un organismo es expuesto a la luz solar diariamente [28]; es decir, el fotoperiodo, caracterizan eventos claves del ciclo de desarrollo en las plantas [156]; motivo por el cual suelen considerarse en diversos modelos agrícolas. Los efectos de estas interacciones son más notables en las plantas cuya fenología sucede, parcial o totalmente, durante la primavera [156]; por ejemplo, el maíz en Alemania [88, 117].

Por una parte, el fotoperiodo es una señal abiótica con variabilidad predecible [82] cuyos efectos en plantas pueden compensar el enfriamiento insuficiente del invierno y fungir como una barrera para limitar la expansión geográfica [156]. Por otra parte, las temperaturas intervienen en el desarrollo y la producción de las plantas [8], pero sus fluctuaciones tienden a ser más volátiles por lo que la predicción climática aún es un reto [78, 93].

A pesar de la complejidad inherente a lo antes mencionado, en la literatura se reportan múltiples calendarios agrícolas utilizados como herramientas en la estructuración de cronogramas de producción. De esta manera, discutiremos aquellos derivados de modelos agrícolas, con particular énfasis en los desarrollados específicamente para el cultivo del maíz.

De acuerdo con Stehfest *et al.* (2007) [152], los trabajos de Sprengel, C. (1828) [150], de Liebig, J. (1840) [85] y de Mitscherlich, E. (1909) [100] fueron pioneros en investigar acerca de los factores que limitan el desarrollo en los cultivos y cuestionarse sobre el manejo agrícola lo optimiza.

Por una parte, en el trabajo de Sprengel, C. (1828) [150] se describió el papel de los minerales para la vida de las plantas y cómo los adquieren del suelo [71]. Posteriormente, el libro de Liebig, J. (1840) [85] se propone que la disponibilidad individual de los minerales supone una restricción para la producción de la planta, lo cual cimentó las bases para entender la nutrición de plantas [148]. No obstante, esta contribución pudo ser integrada cuantitativamente en la modelación agrícola tras su formulación matemática que fue presentada en el trabajo de Waggoner *et al.* (1979) [170].

Finalmente, en el trabajo de Mitscherlich, E. (1909) [100] se introduce la metodología de curvas de dosis-respuesta para representar la relación entre un parámetro biológico y un factor ambiental, cuantificando la fuerza, señal y forma del efecto que tiene tal factor sobre dicho parámetro [123]. El impacto de los trabajos antes mencionados ha trascendido de manera tal que modelos agrícolas aún se ven influenciados por ellos [152].

La metodología desarrollada por Mitscherlich, E. (1909) [100] fue propuesta un contexto biológico general; no obstante, en particular, se ha empleado para estudiar y predecir la relación

entre la fenología y el ambiente; e.g., [18, 127, 167]. Esto se logra a través de considerar los grados día de crecimiento (GDD, por sus siglas en inglés) en las ecuaciones correspondientes [127]; e.g., [18, 52, 160, 167].

La metodología de Mitscherlich, E. (1909) [100] se ha diversificado y generalizado [77]. No obstante, el papel de los GDD permanece vigente y ampliamente utilizado en la predicción fenológica de cultivos [2, 79, 112, 122, 127, 176], consolidándose como un referente metodológico estándar en el área [5].

La progresión de las etapas fenológicas responde al clima y a no la cronología *per se* [119]. En este sentido, los GDD son unidades de calor acumulado que miden la relación entre las condiciones térmicas disponibles en el entorno y los requerimientos térmicos necesarios para que el cultivo manifieste a sus diversas etapas de desarrollo [6].

El concepto de GDD fue formulado originalmente por René-Antoine Ferchault de Réaumur en 1730 [6, 58]. Se ha profundizado en sus propiedades matemáticas [94, 183] y desarrollado diversas variantes metodológicas teóricas [40, 188], cuya implementación en distintos cultivos ha sido exitosa, corroborando su utilidad en la predicción del desarrollo y la planificación agrícola, motivo por el cual ha sido adoptado por la FAO [112].

Respecto al maíz, tanto a nivel global como a escala local, los modelos basados en GDD se han desarrollado con los objetivos de predecir la secuencia fenológica completa del cultivo; e.g., [105, 57] o restringir la predicción a etapas específicas como la siembra, madurez fisiológica o la cosecha; e.g., [117, 65, 171, 120]. Además de estudiar las diferencias en los eventos fenológicos entre variedades de maíces o híbridos; e.g., [9, 92, 6], evaluar cambios en la dinámica fenológica ante estresores como las sequías o las heladas; e.g., [74, 80, 189] o determinar zonas con potencial productivo; e.g., [16, 83, 164].

Asimismo, estos enfoques han sido integrados en plataformas de simulación agrícola de mayor complejidad; e.g., [7, 181]. En años recientes, la capacidad predictiva de estos modelos se ha fortalecido mediante la incorporación de técnicas de ciencia de datos que, manteniendo a los GDD como variable explicativa central, permiten representar indirectamente la incertidumbre fenológica, preservando al mismo tiempo los objetivos agronómicos asociados a los enfoques de modelación basados en tiempo térmico previamente descritos [68].

Los modelos agrícolas basados en los GDD han sido implementados en campo, mostrando su efectividad [17, 48, 163]. No obstante, las extensiones de este enfoque destinadas a incorporar factores ambientales más allá de la temperatura siguen siendo escasas; e.g., [159]. En consecuencia, el marco metodológico tiende a sobresimplificar el problema de interés [51]. Más aún, debido a las diversas formulaciones propuestas, la interpretación de los resultados obtenidos puede resultar ambigua [94].

Asimismo, por su construcción matemática, este enfoque supone una relación lineal entre el

desarrollo fenológico y la temperatura, lo cual no refleja plenamente la complejidad de los procesos biológicos [76]. Además, los modelos basados en este enfoque suelen ser específicos de la zona de cultivo y de sus condiciones climáticas, por lo que su extrapolación a otros contextos resulta limitada [51].

Como se mencionó previamente, los modelos basados en GDD predominan en la predicción fenológica y en la construcción de calendarios agrícolas. No obstante, la literatura ha reportado diversas alternativas metodológicas [179]. En lo subsecuente, se presentan algunos trabajos que prescinden del uso de GDD y que incorporan explícitamente la incertidumbre inherente al desarrollo de los cultivos mediante enfoques probabilísticos.

La literatura referente a modelos estocásticos es aún limitada. No obstante, tanto a escala mundial como a nivel local, estos enfoques preservan los objetivos de estudiar la sucesión fenológica del cultivo en su totalidad; e.g., [53], o focalizar su análisis en alguna etapa específica del desarrollo; e.g., [35, 95, 96, 145].

De igual manera, estos modelos se interesan por caracterizar la fenología de variedades o híbridos; e.g., [45], estudiar cambios en la fenología causados por estresores; e.g., [20, 107] o determinar zonas con potencial productivo; e.g., [161]. A los objetivos anteriores, los modelos probabilísticos incorporan además la calibración explícita de parámetros; e.g., [20, 161, 168, 169].

De los trabajos anteriores, destacamos el de Cintas *et al.* (2021) [26] y el de Franch *et al.* (2022) [53], cuyas metodologías se basan en el trabajo de Cremers *et al.* (2018) [29] para dotar a los calendarios agrícolas de una estructura cíclica, en lugar de tratarlos como un sistema lineal de 365 días con principio y fin. Esta sutil modificación, junto con sus propiedades matemáticas subyacentes, reflejan con mayor fidelidad la naturaleza cíclica de los procesos biológicos [25, 56, 61, 90, 125, 134].

Para concluir, en el estado actual del arte la mayoría de los trabajos propuestos continúan centrados en describir la sucesión completa de etapas fenológicas o en modelar el desarrollo del cultivo a partir de los GDD. Por su parte, las alternativas probabilísticas suelen emplearse principalmente en la calibración de parámetros dentro de estos modelos.

En este contexto, la determinación de ventanas de fechas óptimas para la siembra desde una perspectiva probabilística que no utilice los GDD como variable explicativa ha recibido menor atención en la literatura. De esta manera, el presente trabajo propone un modelo probabilístico autónomo que considera factores agroambientales significativamente correlacionados con las fechas de siembra, con el objetivo de identificar intervalos temporales que reduzcan la exposición ante los estresores que afectan al cultivo.

Finalmente, en términos generales, los calendarios agrícolas derivados de modelos suelen validarse mediante su comparación con calendarios agrícolas construidos a partir de información local; por ejemplo, [124, 142]. Este procedimiento permite evaluar la consistencia de las esti-

maciones del modelo respecto a las condiciones agroclimáticas y productivas propias de cada región. Bajo dicho estándar, el modelo propuesto en este trabajo será evaluado mediante su contraste con calendarios agrícolas construidos a partir de información oficial de la región.

Objetivos

El proyecto aquí propuesto se ubica dentro de la línea de generación y aplicación del conocimiento de analítica de grandes cúmulos de información y pretende abordar la pregunta de investigación referente a cómo pueden utilizarse modelos probabilísticos basados en variables agroclimáticas para estimar ventanas óptimas de fechas de siembra de maíz en Alemania bajo condiciones de cambio climático, sin recurrir a la metodología clásica basada en GDD. Esto, bajo la hipótesis de que el cambio climático ha inducido cambios estructurales significativos en los procesos agrícolas de producción implicando un riesgo para la seguridad alimentaria.

De esta manera, consideraremos datos agroclimáticos históricos para pronosticar las fechas más apropiadas para realizar la siembra de maíz en Alemania. Así, emplearemos herramientas estadísticas, como las pruebas de hipótesis, las correlaciones y los análisis de regresión, a la par, de conjuntar la teoría de los procesos estocásticos y la teoría de gráficas a través de la incorporación de caminatas aleatorias sobre gráficas para estimar la viabilidad de siembra a través de los días. Para ello, se considerarán los objetivos que presentamos a continuación.

Objetivos generales.

1. Desarrollar un modelo probabilístico robusto, independiente de los GDD, que integre variables agroclimáticas significativas para predecir ventanas óptimas de fechas de siembra de maíz en Alemania, con el fin de favorecer ciclos de desarrollo saludables y disminuir la exposición a estresores ambientales, validando sus resultados mediante información oficial y sintetizándolos en un calendario agrícola claro y accesible.
2. Contribuir a la toma de decisiones dentro de la gestión de procesos agroproductivos del maíz en Alemania, una región con potencial agrícola en crecimiento debido a que se enfrenta a contexto de transición climática derivado del cambio climático.

Objetivos particulares.

1. Recopilar y sistematizar bases de datos históricas de fechas de siembra y variables agroclimáticas relevantes para la producción de maíz en Alemania.
2. Homogeneizar y depurar las bases de datos climáticas y agrícolas para garantizar su consistencia y comparabilidad.
3. Analizar la variabilidad temporal de las fechas de siembra del maíz y su relación con las condiciones agroclimáticas.

4. Identificar las variables agroambientales estadísticamente significativas asociadas a las decisiones de siembra.
5. Evaluar la estabilidad temporal de dichas variables agroclimáticas, considerando los cambios observados en el clima y su posible relación con el cambio climático.
6. Formular y estimar un modelo probabilístico que describa la distribución de las fechas de siembra a partir de las variables agroclimáticas seleccionadas.
7. Estimar ventanas probabilísticas de fechas óptimas de siembra, junto con intervalos de confianza asociados.
8. Validar los resultados del modelo mediante su comparación con calendarios agrícolas reportados por fuentes oficiales e identificar sus alcances y limitaciones para aplicaciones en otras regiones o cultivos.

Metodología

Físicamente, el proceso de siembra de una semilla dada puede llevarse a cabo cualquier día del año, especialmente cuando se tienen las condiciones climáticas adecuadas [126]. De igual manera, la fecha de siembra constituye una práctica de manejo agrícola fundamental, ya que determina las condiciones ambientales que experimentará el cultivo a lo largo de su desarrollo [144].

Históricamente, muchas de las prácticas agrícolas se consolidaron mediante procesos empíricos de observación y ajuste progresivo en los cuales, a través de ensayo y error, se identificaban los periodos más favorables; por ejemplo, para la siembra [106]. En el contexto actual, este tipo de decisiones debe replantearse dado que las condiciones en las que fueron tomadas se han alterado por la incertidumbre y la variabilidad asociadas al cambio climático.

En este sentido, se propone una metodología probabilística que formaliza este proceso empírico de exploración del calendario agrícola, permitiendo estudiar analíticamente la variabilidad temporal de las fechas de siembra y estimar periodos potencialmente favorables para el establecimiento del cultivo bajo condiciones climáticas variables.

Más aún, se estructura la progresión del tiempo como un proceso cíclico, emulando la periodicidad inherente a la naturaleza [25, 56, 61, 90, 125, 134], ver Fig. 2. De esta manera, supongamos que una semilla de maíz será sembrada en campo abierto si tal semilla no es viable, entonces se concluye el proceso de siembra como fallido desde el inicio. En otro caso, si dicha semilla es viable y se siembra el día D_i , para alguna $i \in \{1, 2, 3, \dots, 365\}$ el proceso puede concluir con la emergencia o con el fracaso al día D_j , para alguna $j \geq i$, tal que $j \bmod 365 \in \{1, 2, 3, \dots, 365\}$.

Por convención, definamos

$$D_{366} := D_1, \quad (1)$$

$$D_{367} := D_2, \quad (2)$$

$$\begin{aligned} & \vdots \\ D_j &:= D_{j \bmod 365}, \end{aligned} \quad (3)$$

para toda $j \in \mathbb{N}$ tal que $j > 365$.

Con lo anterior, es posible dotar de una estructura cíclica a la progresión del año dado que al finalizar un año inmediatamente comienza el siguiente de manera que la observación del proceso de siembra puede observarse de manera continua en todo punto del año.

Sea $n^* \in \mathbb{N}$ el número de días necesarios para que una semilla viable de maíz logre la emergencia desde su siembra. Como se busca determinar los periodos en donde las condiciones agroambientales favorezcan un sano desarrollo de la semilla, reduciendo la exposición al estrés del entorno entonces se desea hallar al conjunto de días D_i tales que una semilla sembrada en dicha fecha emerja al día D_{i+n^*} con una probabilidad *suficientemente grande*.

Sea $X = \{X_t\}_{t \in \mathbb{N}}$ un proceso estocástico a tiempo discreto con espacio de estados $S = \{D_1, D_2, \dots, D_{365}, F\}$, donde la variable aleatoria X_t representa el estado del proceso al t -ésimo día transcurrido desde la siembra. El estado F indica el fracaso del proceso de siembra atribuido a condiciones agroambientales adversas que detienen de manera irreversible el desarrollo de la semilla previo a la emergencia de la plántula.

Por otra parte, para cada $i \in \{1, 2, \dots, 365\}$, el estado D_i denota el i -ésimo día del año calendario. Cuando el proceso X se encuentra en alguno de los estados D_i , se interpreta que, en dicho día, la semilla continúa su desarrollo de manera adecuada, es decir, el proceso aún no ha sido absorbido por el estado F .

De esta manera, dado dos estados $i, j \in S$, $i \neq j$ si $P_{i,j}$ denota la probabilidad de partir del estado i para transicionar al estado j , en un paso, entonces

$$P_{i,j} := P(X_{t+1} = j \mid X_t = i) = \begin{cases} \lambda_k, & \text{si } i = D_k \text{ y } j = D_{k+1}, k \in \{1, 2, \dots, 365\}. \\ 1 - \lambda_k, & \text{si } i = D_k, k \in \{1, 2, \dots, 365\}, \text{ y } j = F. \\ 1, & \text{si } i = F \text{ y } j = F. \\ 0, & \text{en otro caso.} \end{cases} \quad (4)$$

Donde, para cada $k \in \{1, 2, \dots, 365\}$,

$$\lambda_k = 1 - \frac{d(C_{H,k}, C^*)}{\max_{l \in \{1, \dots, 365\}} \{d(C_{H,l}, C^*)\}}, \quad (5)$$

con $d(\cdot, \cdot)$ una distancia por definir; por ejemplo, la distancia Euclidiana, la distancia Manhattan o la distancia Mahalanobis.

Además, $C_{H,k}$ denota el centroide de las condiciones agroambientales históricas registradas el k -ésimo día del año incluyendo variables como la precipitación, temperatura del suelo, radiación solar, equivalencia de nieve en agua y otros fenómenos meteorológicos disponibles como el índice de Oscilación del Atlántico Norte (NAO, por sus siglas en inglés) en bases de datos climáticas disponibles a través del Deutscher Wetterdienst (DWD) [34] y la Unidad de Investigación Climática, (CRU, por sus siglas en inglés) [70], ver Tabla 1.

Asimismo, C^* denota el centroide de la región de condiciones agroambientales que, según la literatura, favorecen un desarrollo óptimo del cultivo. Específicamente, si $d \in \mathbb{N}$ es el número de variables agroambientales consideradas y, de acuerdo con la literatura, el intervalo $I_v = (a_v, b_v)$ representa el rango de valores en el cual el cultivo de maíz responde favorablemente, para cada variable $v \in \{1, \dots, d\}$ entonces se define a

$$C^* = \left(\frac{a_1 + b_1}{2}, \frac{a_2 + b_2}{2}, \dots, \frac{a_v + b_v}{2} \right), \quad (6)$$

el centroide de la región dada por

$$I_1 \times I_2 \times \dots \times I_d,$$

el producto cartesiano de los intervalos I_v , que representa la región de condiciones agroambientales óptimas.

De esta manera, para toda $k \in \{1, 2, \dots, 365\}$, se garantiza que $\lambda_k \in [0, 1]$ y, simultáneamente, tanto $C_{H,k}$ como C^* se interpretan como elementos en $\mathbb{R}^d$, donde cada componente corresponde a una variable agroambiental específica ver Fig. 1. Además, notemos que $d \leq 9$, dado que la dimensión d estará dada por el número de variables que presenten evidencia estadística suficiente de relación con las fechas de siembra. Reduciendo, en consecuencia, la incorporación de ruido proveniente de variables no informativas.

Para ilustrar lo discutido en la Ecuación (4), se tiene la matriz estocástica $A \in \mathcal{M}_{366 \times 366}(\mathbb{R})$, ver Ecuación (7). Asimismo se construyó un diagrama de transición en donde se muestra tanto la estructura cíclica como proceso estocástico que subyacen en la modelación del problema, ver Fig. 2.

Variable	Descripción	Fuente
Temperatura ambiente promedio (°C).	Promedio diario de la temperatura del aire medida a 2 m de altura en condiciones estandarizadas para suprimir los efectos de la humedad, la radiación solar y el viento.	Deutscher Wetterdienst [34].
Temperatura ambiente máxima y mínima (°C).	Registro diario de la temperatura ambiente máxima y mínima, respectivamente.	
Temperatura ambiente mínima sobre el suelo (°C).	Registro de la temperatura ambiente mínima medida a 5 cm sobre el suelo.	
Temperatura del suelo (°C).	Promedio diario de la temperatura del suelo medida a 2, 5, 10, 20 y 50 cm de profundidad. Nota: Se sugiere considerar mediciones a 10 cm [166].	
Precipitación (mm).	Precipitación diaria registrada en superficie.	
Humedad relativa (%).	Contenido de humedad real en el aire diario en comparación con el contenido de humedad del aire saturado a la misma temperatura.	
Duración del fotoperiodo (h).	Cantidad diaria de horas de luz.	
Índice de Oscilación del Atlántico Norte (adimensional).	Diferencia normalizada de la presión a nivel del mar entre el centro de altas presiones subtropicales (Azores) y el centro de bajas presiones subpolares (Islandia). Nota: Se sugiere considerar la componente asociada a Islandia [137].	Climatic Research Unit [70].

Tabla 1: Variables agroambientales que definen el registro histórico. A partir de las observaciones de cada variable se obtiene el centroide $C_{H,k}$, para cada $k \in \{1, 2, \dots, 365\}$.




Figura 1: Distancia entre las condiciones agroclimáticas para el desarrollo óptimo del maíz y las condiciones agroclimáticas históricamente reportadas para el k -ésimo día del año. Los círculos en color negro representan los datos agroclimáticos reportados anualmente para el k -ésimo día del año mientras que el polígono sombreado en color gris representa la región de parámetros agroclimáticos, ideales para el desarrollo del maíz. Los círculos de color azul y rojo indican los centroides de los datos históricos ($C_{H,k}$) y la región óptima (C^*), respectivamente. Por último, $d(\cdot, \cdot)$ denota una distancia por definir; por ejemplo, la distancia Euclidiana, la distancia Manhattan o la distancia Mahalanobis

$$A = \begin{matrix} & D_1 & D_2 & D_3 & D_4 & \cdots & D_{364} & D_{365} & F \\ \begin{matrix} D_1 \\ D_2 \\ \vdots \\ D_{364} \\ D_{365} \\ F \end{matrix} & \begin{bmatrix} 0 & \lambda_1 & 0 & 0 & \cdots & 0 & 0 & 1 - \lambda_1 \\ 0 & 0 & \lambda_2 & 0 & \cdots & 0 & 0 & 1 - \lambda_2 \\ & & & & \ddots & & & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 0 & \lambda_{364} & 1 - \lambda_{364} \\ \lambda_{365} & 0 & 0 & 0 & \cdots & 0 & 0 & 1 - \lambda_{365} \\ 0 & 0 & 0 & 0 & \cdots & 0 & 0 & 1 \end{bmatrix} \end{matrix}. \quad (7)$$

Sea

$$\tau_F := \inf_{t \in \mathbb{N}} \{X_t = F\} \quad (8)$$

el primer día en el que proceso de siembra falla. Así, propondremos al i -ésimo del año como candidato para la siembra de maíz en Alemania si

$$P_i(\tau_F > n^*) := P(\tau_F > n^* \mid X_0 = D_i) \geq \zeta^*, \quad (9)$$




Figura 2: Diagrama de transición diaria de la factibilidad de siembra. El estado F indica el fracaso del proceso de siembra, mientras que los estados D_i , $i \in \{1, 2, \dots, 365\}$, denotan el i -ésimo día del año calendario. Cuando el proceso X se encuentra en un estado D_i , se interpreta que, en dicho día, la semilla continúa su desarrollo de manera adecuada, es decir, que el proceso no ha sido absorbido por el estado F como consecuencia de las condiciones agroambientales del entorno. Para cada i , λ_i denota la probabilidad de transición de D_i a D_{i+1} , y $1 - \lambda_i$ la probabilidad de transición de D_i a F .

para algún $\zeta^* \in [0, 1]$. Es decir, bajo el esquema de trabajo anterior, se sugiere al i -ésimo día siempre que la emergencia de la semilla ocurra antes del fracaso del proceso.

Notemos que, al definir τ_F como el ínfimo de un conjunto, surge la cuestión de si dicho objeto está bien definido. Para responder a ella se introduce el siguiente teorema.

Teorema 1. Sea $\mathbb{R}^* := \mathbb{R} \cup \{-\infty, \infty\}$ el conjunto de los números reales extendidos. El instante $\tau_F(\omega) = \inf_{t \in \mathbb{N}} \{X_t(\omega) = F\}$ está bien definido para toda $\omega \in \Omega$ y cumple que $\tau_F(\omega) \in \mathbb{R}^*$.

Demostración. Sea $\omega^* \in \Omega$ arbitraria y fija; además, sea $A := \{t \in \mathbb{N} : X_t(\omega^*) = F\}$. Si $A = \emptyset$ entonces $\inf A = \infty$ y dado que, por definición, $\tau_F(\omega^*) = \infty$ se tiene que $\tau_F(\omega^*) \in \mathbb{R}^*$.

Por otra parte, supongamos que $A \neq \emptyset$. Como $A \subset \mathbb{N}$ y $\mathbb{N}$ es conjunto acotado inferiormente, en particular, A también lo es; a saber, el 0 satisface ser una cota inferior para ambos, A y $\mathbb{N}$. De esta manera, como A es un conjunto no vacío y acotado inferiormente se cumple que

el $\inf A$ existe y $\inf A \in \mathbb{R} \subset \mathbb{R}^*$.

En consecuencia, en ambos casos se tiene que $\tau_F(\omega^*) = \inf A$ está bien definido y $\tau_F(\omega^*) \in \mathbb{R}^*$. Más aún, como ω^* fue arbitraria, lo anterior se cumple para toda $\omega^* \in \Omega$. $\square$

Además, para simplificar la expresión mostrada en la Ecuación (9), se enuncia el siguiente lema.

Lema 1. *Dada $n^* \in \mathbb{N}$ fija, sean $E_1 := \{\omega \in \Omega \mid \tau_F(\omega) > n^*\}$ y $E_2 := \{\omega \in \Omega \mid X_0(\omega) \neq F, X_1(\omega) \neq F, X_2(\omega) \neq F, \dots, X_{n^*}(\omega) \neq F\}$ entonces los eventos E_1 y E_2 son equivalentes.*

Demostración. Sea $\omega^* \in E_1$. Como $\tau_F(\omega^*) = \inf_{t \in \mathbb{N}} \{X_t(\omega^*) = F\} > n^*$ entonces para todo instante $t < \tau_F(\omega^*)$ se cumple que $X_t \neq F$, por la definición de ínfimo. De esta manera, en particular, para toda $t \leq n^*$ se satisface que $X_t \neq F$. Por tanto $\omega^* \in E_2$, verificando que $E_1 \subseteq E_2$.

Sea $\omega^* \in E_2$. Como $X_t(\omega^*) \neq F$, para toda $t \leq n^*$, entonces $\{t \in \mathbb{N} : X_t(\omega^*) = F\} \subseteq \{t \in \mathbb{N} : t > n^*\}$ implicando que $\tau_F(\omega^*) = \inf_{t \in \mathbb{N}} \{X_t(\omega^*) = F\} \geq \inf_{t \in \mathbb{N}} \{t > n^*\} > n^*$ por propiedades del ínfimo sobre la contención de conjuntos y que $\inf_{t \in \mathbb{N}} \{t > n^*\} = n^* + 1$. Así, por transitividad, se tiene que $\inf_{t \in \mathbb{N}} \{X_t(\omega^*) = F\} > n^*$, implicando que $\omega^* \in E_1$, lo que verifica que $E_2 \subseteq E_1$.

De los argumentos previos se tiene que $E_1 = E_2$, lo deseado. $\square$

Aludiendo al lema anterior, la Ecuación (9) se reescribe como

$$\begin{aligned} P_i(\tau_F > n^*) &= P(\tau_F > n^* \mid X_0 = D_i) \\ &= P(X_0 \neq F, X_1 \neq F, X_2 \neq F, \dots, X_{n^*} \neq F \mid X_0 = D_i) \\ &= P(X_0 = D_i, X_1 = D_{i+1}, X_2 = D_{i+2}, \dots, X_{n^*} = D_{i+n^*} \mid X_0 = D_i) \\ &= P(X_1 = D_{i+1}, X_2 = D_{i+2}, \dots, X_{n^*} = D_{i+n^*} \mid X_0 = D_i) \end{aligned} \quad (10)$$

puesto que, por la probabilidad condicional, cuando el proceso de siembra se encuentra en el estado D_i solo puede transicionar a D_{i+1} o F ; por tanto, al evitar el estado F se determina por completo la estructura de la trayectoria transicionando de D_i a D_{i+n^*} pasando por los estados D_j , con $i < j < i + n^*$, intermedios.

Luego, al aplicar el teorema de la regla de la cadena para probabilidad condicional [141, Capítulo 3], podemos reescribir a la Ecuación (9) de la manera siguiente

$$\begin{aligned} P_i(\tau_F > n^*) &= P(X_1 = D_{i+1}, X_2 = D_{i+2}, \dots, X_{n^*} = D_{i+n^*} \mid X_0 = D_i) \\ &= P\left(\bigcap_{t=1}^{n^*} X_t = D_{i+t} \mid X_0 = D_i\right) \\ &= \prod_{t=1}^{n^*} P\left(X_t = D_{i+t} \mid \bigcap_{s=0}^{t-1} X_s = D_{i+s}\right). \end{aligned} \quad (11)$$

Con lo antes presentado, se puede proceder al cálculo de la probabilidad de interés, $P_i(\tau_F > n^*)$, de dos maneras distintas. Una de ellas, asumiendo que X es una cadena de Markov, por simplicidad, mientras que la forma alterna se basa en considerar al diagrama presentado en la Fig. 4 como una gráfica dirigida cuyos pesos son probabilidades y sobre ella se ejecutan caminatas aleatorias.

Por un lado, de suponer que X es una cadena de Markov, la Ecuación (11) admite la siguiente representación.

$$\begin{aligned} P_i(\tau_F > n^*) &= \prod_{t=1}^{n^*} P\left(X_t = D_{i+t} \mid \bigcap_{s=0}^{t-1} X_s = D_{i+s}\right) \\ &= P(X_{n^*} = D_{i+n^*} \mid X_{n^*-1} = D_{i+n^*-1}) \dots P(X_2 = D_{i+2} \mid X_1 = D_{i+1}) P(X_1 = D_{i+1} \mid X_0 = D_i), \end{aligned} \quad (12)$$

por la propiedad de Markov.

Más aún, de considerar que las probabilidades de transición en un paso, mostradas en la Ecuación (4), la Ecuación anterior se simplifica de manera que

$$\begin{aligned} P_i(\tau_F > n^*) &= \\ &P(X_{n^*} = D_{i+n^*} \mid X_{n^*-1} = D_{i+n^*-1}) \dots P(X_2 = D_{i+2} \mid X_1 = D_{i+1}) P(X_1 = D_{i+1} \mid X_0 = D_i) \\ &= \prod_{t=0}^{n^*-1} \lambda_{(i+t) \bmod 365}. \end{aligned} \quad (13)$$

Para extender el análisis del proceso X , como cadena de Markov absorbente, se introducen las siguientes definiciones.

Definición 1 (Estado absorbente). *Sea X una cadena de Markov con espacio de estados S . Un estado $s \in S$ es denominado absorbente si*

$$P_{s,s} = 1. \quad (14)$$

En otro caso, es llamado estado transitorio.

Definición 2 (Cadena de Markov absorbente). *Sea X una cadena de Markov con espacio de estados S . Se dice que X es una cadena de Markov absorbente si posee al menos un estado absorbente y si partiendo de cualquier estado $s \in S$ es posible llegar a algún estado absorbente, no necesariamente en un único paso.*

Aludiendo a las definiciones previas, puede demostrarse que que la cadena de Markov X propuesta para modelar el proceso de siembra es una cadena de Markov absorbente, ver Fig. 2. De esta manera, es posible preguntarse por cuál es el número de días que se espera transcurran hasta que el proceso de siembra fracase si dio inicio el i -ésimo día del año, con

$i \in \{1, 2, \dots, 365\}$.

Matemáticamente, lo anterior se traduce a responder, dado que la cadena de Markov X comenzó en el estado D_i , $i \in \{1, 2, \dots, 365\}$, cuál es el número de pasos esperado antes de que X sea absorbida por el estado F . Lo cual se aborda empleando las herramientas discutidas en el libro de Grinstead *et al.* (2003) [60, Capítulo 11] y se mencionan a continuación.

Definición 3 (Forma canónica). *Sea X una cadena de Markov a tiempo discreto con un espacio de estados S tal que $|S| = s + r$, $s, r \in \mathbb{N}$, tales que s denota el número de estados absorbentes mientras que t denota el número de estados transitorios. Además, sea $A \in \mathcal{M}_{s \times s}(\mathbb{R})$ la matriz de transición de X . Se dice que A está en forma canónica si admite la siguiente representación*

$$A = \begin{array}{cc} & \begin{array}{cc} \text{Transitorios} & \text{Absorbentes} \end{array} \\ \begin{array}{c} \text{Transitorios} \\ \text{Absorbentes} \end{array} & \begin{bmatrix} \mathbf{Q} & \mathbf{R} \\ \mathbf{0} & \mathbf{I} \end{bmatrix}, \end{array} \quad (15)$$

donde $\mathbf{Q} \in \mathcal{M}_{t \times t}(\mathbb{R})$ es la submatriz que considera al proceso mientras permanece en estados transitorios, $\mathbf{R} \in \mathcal{M}_{t \times r}(\mathbb{R})$ es la submatriz que considera la transición del proceso de estados transitorios a estados absorbentes, $\mathbf{0} \in \mathcal{M}_{r \times t}(\mathbb{R})$ es la matriz cero dado que considera la transición de estados absorbentes a estados transitorios y, finalmente, $\mathbf{I} \in \mathcal{M}_{r \times r}(\mathbb{R})$ es la matriz identidad dado que considera la transición de estados absorbentes a sí mismos.

Al considerar la forma canónica de una matriz de transición asociada a una cadena de Markov absorbente se puede introducir el concepto de matriz fundamental. Así pueden calcularse distintas probabilidad en función de dicha matriz por lo que a continuación se presenta su definición.

Definición 4 (Matriz fundamental). *Sea X una cadena de Markov absorbente con A su matriz de transición. Si $\mathbf{Q}$ es la submatriz que proviene en de la forma canónica de A , la matriz fundamental de X , $\mathbf{N} \in \mathcal{M}_{t \times t}(\mathbb{R})$, se denota y define por*

$$\mathbf{N} = (\mathbf{I}_t - \mathbf{Q})^{-1}, \quad (16)$$

donde $t \in \mathbb{N}$ indica el número de estados transitorios e $\mathbf{I}_t \in \mathcal{M}_{t \times t}(\mathbb{R})$ denota la matriz identidad.

Al considerar las definiciones previas, el número de pasos esperado para que una cadena de Markov absorbente sea absorbida, habiendo partido de un estado transitorio arbitrario, se obtiene a través del siguiente teorema.

Teorema 2 (Tiempo esperado para la absorción). *Sea X una cadena de Markov absorbente con espacio de estados S , $t \in \mathbb{N}$ el número de estados transitorios y $\mathbf{N}$ su matriz fundamental.*

Si μ_i denota el número de pasos esperado antes de que X sea absorbida, dado que comenzó en el estado transitorio s_i , $s_i \in S$, y $\mu \in \mathbb{R}^t$ es tal que $\mu = (\mu_1, \mu_2, \dots, \mu_t)^T$ entonces

$$\mu = \mathbf{N}\mathbf{1}, \quad (17)$$

donde $\mathbf{1} \in \mathbb{R}^t$ está dado por $\mathbf{1} = (1, 1, \dots, 1)^T$.

El resultado anterior puede robustecerse por aludir a las herramientas discutidas en el libro de Kemeny *et al.* (1976) [73, Capítulo 3]. En particular, se puede calcular la varianza del número de pasos para que una cadena de Markov absorbente sea absorbida, habiendo partido de un estado transitorio arbitrario, un resultado que presenta a continuación.

Teorema 3 (Varianza del tiempo para la absorción). *Sea X una cadena de Markov absorbente con espacio de estados S , $t \in \mathbb{N}$ el número de estados transitorios y $\mathbf{N}$ su matriz fundamental. Si σ_i^2 denota la varianza del número de pasos antes de que X sea absorbida, dado que comenzó en el estado transitorio s_i , $s_i \in S$, y $\sigma^2 \in \mathbb{R}^t$ es tal que $\sigma^2 = (\sigma_1^2, \sigma_2^2, \dots, \sigma_t^2)^T$ entonces*

$$\sigma^2 = (2\mathbf{N} - I_t)\mu - \mu_{sq}, \quad (18)$$

donde $\mu = (\mu_1, \mu_2, \dots, \mu_t)^T$ el vector del número esperado de pasos antes de la absorción y $\mu_{sq} \in \mathbb{R}^t$ se define por $\mu_{sq} = (\mu_1^2, \mu_2^2, \dots, \mu_t^2)^T$.

Con los resultados y definiciones previas, gráficamente, la matriz de transición mostrada en la Ecuación (4), que corresponde a la cadena de Markov de nuestro interés, se segmenta en los siguientes bloques, a fin de obtener su forma canónica.

$$A = \begin{array}{c} \begin{array}{c} D_1 \\ D_2 \\ \vdots \\ D_{364} \\ D_{365} \\ F \end{array} \begin{bmatrix} D_1 & D_2 & D_3 & D_4 & \cdots & D_{364} & D_{365} & F \\ 0 & \lambda_1 & 0 & 0 & \cdots & 0 & 0 & 1 - \lambda_1 \\ 0 & 0 & \lambda_2 & 0 & \cdots & 0 & 0 & 1 - \lambda_2 \\ & & & & \ddots & & & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 0 & \lambda_{364} & 1 - \lambda_{364} \\ \lambda_{365} & 0 & 0 & 0 & \cdots & 0 & 0 & 1 - \lambda_{365} \\ 0 & 0 & 0 & 0 & \cdots & 0 & 0 & 1 \end{bmatrix} \end{array} \quad (19)$$

De manera que, para el proceso que modela la siembra, $\mathbf{Q} \in \mathcal{M}_{365 \times 365}(\mathbb{R})$ se define por

$$\mathbf{Q} = \begin{array}{c} \begin{array}{c} D_1 \\ D_2 \\ \vdots \\ D_{364} \\ D_{365} \end{array} \begin{bmatrix} D_1 & D_2 & D_3 & D_4 & \cdots & D_{364} & D_{365} \\ 0 & \lambda_1 & 0 & 0 & \cdots & 0 & 0 \\ 0 & 0 & \lambda_2 & 0 & \cdots & 0 & 0 \\ & & & & \ddots & & \\ 0 & 0 & 0 & 0 & \cdots & 0 & \lambda_{364} \\ \lambda_{365} & 0 & 0 & 0 & \cdots & 0 & 0 \end{bmatrix} \end{array}, \quad (20)$$

dado que X posee un único estado absorbente, F .

Al emplear el Teorema 2 y el Teorema 3 de manera conjunta, se obtiene un criterio adicional. Para cada $i \in \{1, 2, \dots, 365\}$, sea T_i la variable aleatoria que cuenta el número de pasos para que la cadena X sea absorbida por F , dado que comenzó en el estado D_i , entonces por la desigualdad de Chebyshev [64] se tiene que, para toda $\kappa \geq 0$,

$$P(|T_i - \mu_i| \geq \kappa \sigma_i) \leq \frac{1}{\kappa^2}, \quad (21)$$

donde μ_i indica la i -ésima entrada del vector μ , calculado a través del Teorema 2, y $\sigma_i = \sqrt{\sigma_i^2}$ es la raíz cuadrada de la i -ésima entrada del vector σ^2 , obtenido a través del Teorema 3, ambos teoremas aplicados en la cadena de Markov X que modela la siembra.

En consecuencia,

$$P(|T_i - \mu_i| < \kappa \sigma_i) \geq 1 - \frac{1}{\kappa^2}. \quad (22)$$

Implicando que al menos el $\left(1 - \frac{1}{\kappa^2}\right) 100\%$ de las realizaciones de T_i caen en el intervalo

$$(\mu_i - \kappa \sigma_i, \mu_i + \kappa \sigma_i). \quad (23)$$

Con ello se obtiene una acota para el número de días para que la cadena X sea absorbida por el estado F dado que comenzó en el estado D_i .

De esta manera, para cada $i \in \{1, 2, \dots, 365\}$, se sugiere que la siembra se realice el i -ésimo día del año si

$$n^* < \mu_i - \kappa \sigma_i, \quad (24)$$

un criterio conservador al provenir de la desigualdad de Chebyshev [67].

Más aún, a través de las herramientas discutidas previamente es posible determinar la probabilidad de que el proceso visite en algún momento el estado s_j , habiendo partido del estado s_i , donde ambos estados son transitorios. Para tal efecto, se presenta el siguiente teorema.

Teorema 4 (Visita eventual). *Sea X una cadena de Markov absorbente con espacio de estados S y con matriz fundamental $\mathbf{N}$. Dados dos estados transitorios $s_i, s_j \in S$, la probabilidad de que X comience por el estado s_i y, que luego del estado inicial, eventualmente visite el estado s_j corresponde a la entrada $h_{i,j}$ de la matriz $\mathbf{H} \in \mathcal{M}_{t \times t}(\mathbb{R})$ dada por*

$$\mathbf{H} = (\mathbf{N} - I_t)(N_{dg})^{-1}, \quad (25)$$

donde $I_t \in \mathcal{M}_{t \times t}(\mathbb{R})$ denota la matriz identidad y $N_{dg} \in \mathcal{M}_{t \times t}(\mathbb{R})$ es la matriz diagonal con la misma diagonal que la matriz $\mathbf{N}$.

Con el teorema anterior se obtiene una alternativa directa al análisis correspondiente a la Ecuación (13), ya que, como consecuencia del siguiente teorema, se sabe que dicha expresión tiende a cero cuando n^* tiende a infinito.

Teorema 5 (Tendencia a la absorción). *Sea X una cadena de Markov finita con $s > 0$ estados absorbentes, $s \in \mathbb{N}$. Entonces la probabilidad de que X esté en un estado absorbente tras n pasos tiende a uno cuando n tiende a infinito, sin importar el estado en el que inició X .*

De esta manera, de acuerdo con Kemeny *et al.* (1976) [73], se tiene que

$$\lim_{n \rightarrow \infty} \mathbf{Q}^n = \mathbf{0}, \quad (26)$$

donde $\mathbf{0} \in \mathcal{M}_{t \times t}(\mathbb{R})$ denota la matriz cero y $t \in \mathbb{N}$ indica el número de estados transitorios. Así, el producto de n factores, tales que cada factor corresponde a algún λ_i , $i \in \{1, 2, \dots, 365\}$ tiende a cero, como se mencionaba anteriormente. Esto, dado que tal producto puede entenderse como una de las entradas de la n -ésima potencia de la matriz $\mathbf{Q}$ descrita en la Ecuación (20).

De manera que, si n^* denota el número de días que transcurren desde el inicio de la siembra hasta la emergencia del maíz en Alemania y la transición entre estados representa el avance diario del cultivo, entonces, desde el punto de vista fenológico, la etapa de siembra a la emergencia se completa aproximadamente en n^* días.

En consecuencia, con las herramientas discutidas en el Teorema 4, se establece el siguiente criterio de decisión. Para cada $i \in \{1, 2, \dots, 365\}$, se sugiere realizar la siembra en el i -ésimo día del año si

$$h_{i, (i+n^*) \bmod 365} \geq \zeta^*, \quad (27)$$

para algún $\zeta^* \in [0, 1]$. Es decir, si la probabilidad de que el cultivo eventualmente complete la etapa fenológica es suficientemente alta.

En muchos contextos, por otra parte, la propiedad de Markov es restrictiva por lo que puede no ser completamente apropiada [13]. Es por ello que, simultáneamente, presentamos una alternativa metodológica basada en caminatas aleatorias sobre una gráfica dirigida.

Sin hipótesis adicionales, obtener analíticamente el cálculo de la probabilidad mostrado en la Ecuación (9) puede resultar altamente complicado. En particular, el diagrama de transición mostrado en la Fig. 2 puede verse como una modificación del trabajo de Altman *et al.* (1993) [4] y dado que obtener expresiones análogas queda fuera del objetivo del presente trabajo, optando por un enfoque de estimación empírico.

De esta manera, al considerar al proceso mostrado en la Fig. 2 no como un diagrama de transición sino como un gráfica dirigida cuyos pesos son probabilidades, podemos emplear

una metodología similar a la discutida en el trabajo de de Anda-Jauregui *et al.* (2021) [33]. Así, al permitir que caminatas aleatorias recorran la gráfica es posible estimar el valor de $P_i(\tau_F > n^*)$ a través de estudiar sus trayectorias y longitudes.

Con este enfoque, las caminatas aleatorias se inicializan en cada uno de los vértices. En particular, para cada $i \in \{1, 2, \dots, 365\}$, se inicializa una caminata aleatoria que parte del vértice D_i y cuya trayectoria llega, por lo menos, al vértice D_{i+n^*} , o bien, llega al vértice F sin haber visitado el vértices D_{i+n^*} . Por repetir el proceso anterior $r^* \in \mathbb{N}$ veces para cada vértice, se propone a

$$\frac{|W(D_i, D_{(i+n^*) \bmod 365})|}{r^*}, \quad (28)$$

como estimador de $P_i(\tau_F > n^*)$, donde $W(D_i, D_{(i+n^*) \bmod 365})$ denota el conjunto de caminatas aleatorias que comienzan en el vértice D_i y, por lo menos, visitan el vértice $D_{(i+n^*) \bmod 365}$ y $|\cdot|$ indica el operador de cardinalidad en conjuntos.

Más aún, derivado del gran número de repeticiones es posible generar intervalos del $(1 - \alpha)100\%$ de confianza para cada uno de los vértices D_i empleando los métodos de bootstrap y jackknife [128, Capítulo 13].

Finalmente, tras la revisión bibliográfica, los parámetros a emplear están dados en la Tabla 2

Con el objetivo de cubrir una región de interés agrícola, el análisis se centrará en los estados federados de Baviera, Brandemburgo y Sajonia, los cuales, de manera conjunta, albergan 5.17 M ha de superficie destinada para la agricultura [47]. Al centrarnos en esta área, se logra una cobertura de aproximadamente el 54.42 % de las 9.5 M ha de superficie empleada anualmente para los principales cultivos que se producen en Alemania [39].

Para cada uno de los estados mencionados se replicará, de manera independiente, el procedimiento metodológico antes descrito para generar los correspondientes calendarios agrícolas regionalizados para la siembra de maíz en Alemania. Para ello, se considerarán exclusivamente aquellas estaciones climáticas contenidas dentro de sus fronteras geográficas, ver Fig. 3.

La elección de Baviera, Brandemburgo y Sajonia se ve motivada por el trabajo de Flores *et al.* (2025) [47] en el que se menciona que esta región agrícola está caracterizada por una elevada heterogeneidad topográfica, climática y edáfica. En consecuencia, la región presenta variaciones en humedad, altitud, temperatura y características del suelo, factores que influyen directamente sobre las prácticas agrícolas y los calendarios de siembra. De esta manera, se tiene un escenario tanto para evaluar la metodología como para explorar su potencial extrapolación espacial longitudinalmente [131].

Se dispone de información proveniente de 493 estaciones climáticas distribuidas a lo largo del territorio alemán, las cuales reportan simultáneamente las primeras ocho variables mostradas en la Tabla 1. Para Brandemburgo se tiene un total de 34 estaciones climáticas disponibles,

Parámetro	Descripción	Valor	Fuente
n^*	Número de días requeridos para que una semilla viable alcance la emergencia desde la siembra.	16.6 ± 3.1	Chmielewski <i>et al.</i> (2004) [23].
ζ^*	Umbral mínimo de probabilidad para considerar viable una fecha de siembra.	0.8	FAO (2011) [49, p. 57].
r^*	Número de repeticiones de caminatas aleatorias para estimación empírica.	500	de Anda-Jauregui <i>et al.</i> (2021) [33].
C^*	Centroide de la región de condiciones agroambientales óptimas para el desarrollo del cultivo.	N/A	FAO (2026) [50], Waha <i>et al.</i> (2011) [171].
$C_{H,k}$	Centroide de las condiciones agroambientales históricas observadas en el día k del año.	N/A	Deutscher Wetterdienst (2026) [34], Jones <i>et al.</i> (1997) [70].
$d(\cdot, \cdot)$	Métrica de distancia en el espacio de variables agroambientales.	Por definir	N/A
α	Nivel de significancia para la construcción de intervalos de confianza.	0.05	N/A
κ	Parámetro en la desigualdad de Chebyshev.	4.47	da Silva <i>et al.</i> (2019) [32].

Tabla 2: Parámetros empleados en la metodología probabilística para la estimación de fechas óptimas de siembra.

mientras que Sajonia dispone de 31 estaciones y, finalmente, Baviera cuenta con un total de 92 estaciones, permitiendo una amplia cobertura espacial de las condiciones climáticas regionales.

Las estaciones a emplear serán todas aquellas que reporten los datos históricos desde 1994 hasta 2024, considerando un periodo de 30 años, una duración estándar al estudiar efectos del cambio climático [62]. De igual forma, se considerarán aquellas estaciones sin datos faltantes, o bien, que pueda llevarse a cabo la imputación de datos pese a los valores faltantes.

Para cada variable considerada y para cada día del año, se calcula el promedio de los valores reportados por todas las estaciones climáticas durante el periodo de estudio que estén




Figura 3: Distribución de las estaciones climáticas respecto a los estados federados de Alemania. Los polígonos delimitados por un contorno en color negro corresponden a los estados federados reportados por Bundesamt für Kartographie und Geodäsie [15]. En color verde se muestran, de manera descendente, Brandemburgo, Sajonia y Baviera. Los puntos en color amarillo indican la ubicación de las 493 estaciones climáticas, las cuales reportan las primeras ocho variables listadas en la Tabla 1.

contenidas en el estado correspondiente. De esta manera, se obtienen mediciones históricas representativas de las condiciones medias locales, ver Fig. 1, las cuales son utilizadas para determinar las probabilidades de transición del modelo a través de la Ecuación (5).

De acuerdo con Flores *et al.* (2025) [47], Brandeburgo y el norte de Sajonia se caracterizan por presentar elevaciones inferiores a 150 m.s.n.m., localizándose geográficamente al norte de

los 51° N y al este de los 8.5° E. En contraste, el sur de Sajonia y Baviera presentan una topografía más irregular, con elevaciones que pueden superar los 1200 m.s.n.m., y se localizan al sur de los 51° N y al este de los 8.5° E.

De esta manera, al emplear los criterios topográficos y geográficos reportados por Parker *et al.* (2017) [117, Tabla 1], es posible asociar las condiciones agroclimáticas mencionadas anteriormente para las regiones de estudio con información referente a fechas promedio de siembra de maíz, ver Tabla 3.

Región	Características	Fecha de siembra
Brandemburgo Norte de Sajonia	Altitud menor que 250 m.s.n.m.	115.6 ± 7.12
	Latitud mayor o igual que 51° N.	116.2 ± 7.08
	Longitud mayor o igual que 8.5° E.	116.2 ± 7.3
Sur de Sajonia Baviera	Altitud mayor o igual que 250 m.s.n.m.	117.4 ± 8.29
	Latitud menor que 51° N.	116.7 ± 8.23
	Longitud mayor o igual que 8.5° E.	116.2 ± 7.3

Tabla 3: Fechas promedio de siembra de maíz y sus correspondientes desviaciones estándar reportadas por Parker *et al.* (2017) [117], asociadas a las características geográficas y topográficas descritas por Flores *et al.* (2025) [47] para Brandemburgo, Sajonia y Baviera.

Con lo anterior, para cada estado se obtiene un conjunto específico de probabilidades de transición, lo que permite la identificación de periodos óptimos de siembra adaptados a las condiciones locales mediante los criterios de decisión previamente establecidos y contrastarlos con la información disponible en la Tabla 3. No obstante, es importante mencionar que la diferencia en la cantidad de información disponible entre estados, puede influir en las estimaciones obtenidas.

Cronograma de actividades

Para asegurar el desarrollo y la culminación exitosa del proyecto, se propone el siguiente cronograma, el cual se ha desglosado semestralmente. Lo anterior, para tomarlo como referencia a fin de garantizar un avance progresivo al apegarnos lo más posible a él y cubrir tanto los aspectos referentes al proyecto de investigación como los aspectos administrativos.

Semestre	Actividades
Agosto – Diciembre 2025	• Profundizar la revisión bibliográfica sobre calendarios agrícolas, variabilidad temporal y métodos probabilísticos aplicados a sistemas agrícolas. • Definir y depurar el conjunto de datos con el que se trabajará a lo largo del proyecto. • Explorar enfoques estadísticos y probabilísticos para el análisis de series temporales asociadas a eventos agrícolas. • Elaborar una primera versión del protocolo de investigación.
Enero – Julio 2026	• Proponer y diseñar la metodología estadística y probabilística para el análisis de las fechas de siembra. • Implementar un análisis exploratorio con datos preliminares. • Presentar la versión final del protocolo de investigación ante el comité sinodal. • Comenzar con la escritura de la tesis.
Agosto – Diciembre 2026	• Desarrollar modelos probabilísticos preliminares para describir la evolución temporal de las fechas de siembra. • Analizar las propiedades estadísticas de las series temporales empleadas en el estudio. • Realizar simulaciones y análisis computacionales para explorar el comportamiento del modelo propuesto. • Comenzar con la escritura del primer artículo de investigación. • Presentar avances en un congreso nacional; por ejemplo, el Congreso Nacional de la Sociedad Matemática Mexicana, Congreso Nacional de Agricultura Sostenible u otros.

Semestre	Actividades
Enero – Julio 2027	• Profundizar el desarrollo y análisis de la metodología probabilística propuesta. • Evaluar los resultados obtenidos mediante análisis estadístico y simulación. • Identificar el congreso internacional más adecuado para la difusión de los resultados. • Preparar una presentación oral o póster para dicho evento. • Fortalecer el proyecto mediante la búsqueda de colaboraciones potenciales nacionales e internacionales.
Agosto – Diciembre 2027	• Realizar actividades de retribución social para cumplir con los requisitos de la SECIHTI. • Consolidar los primeros capítulos de la tesis. • Integrar los resultados metodológicos preliminares al desarrollo del artículo de investigación. • Identificar revistas científicas indexadas en el JCR adecuadas para la publicación de los resultados del proyecto.
Enero – Julio 2028	• Refinar la metodología desarrollada considerando los resultados obtenidos y los alcances del proyecto. • Consolidar el análisis estadístico y probabilístico de los datos estudiados. • Preparar la versión final del primer artículo de investigación. • Enviar el artículo a una revista científica indexada en el JCR.
Agosto – Diciembre 2028	• Atender los comentarios de los revisores del artículo enviado y realizar las correcciones solicitadas. • Integrar los resultados finales del proyecto en los capítulos centrales de la tesis. • Revisar y afinar los avances de la tesis, evaluando el cumplimiento de los objetivos planteados.

Semestre	Actividades
Enero – Julio 2029	• Obtener la aceptación del artículo enviado a una revista indexada en el JCR. • Culminar la escritura de la tesis con el visto bueno por parte de la directora de tesis. • Enviar la tesis al comité sinodal para su revisión, corrección y posterior aprobación. • Solicitar la autorización de impresión de la tesis por parte de la biblioteca. • Presentar el examen de defensa de tesis para la obtención del grado académico.

Resultados preliminares

Según la ubicación geográfica y el cultivo a producir, los calendarios agrícolas consideran tanto las condiciones ambientales como los requerimientos agroclimáticos necesarios para el desarrollo del cultivo de interés, ambos, para caracterizar los eventos fenológicos en función del entorno regional [186]. De esta manera, es posible sincronizar los manejos y procesos agrícolas con la fenología del cultivo [54].

Para la Unión Europea, el Joint Research Centre (JRC) ha desarrollado la plataforma web AGRI4CAST (<https://agri4cast.jrc.ec.europa.eu/dataportal>). Esta es una herramienta de dominio público que condensa datos agrometeorológicos para propósitos de investigación y el desarrollo de políticas públicas [12].

A través de su unidad de seguridad alimentaria, el JRC ha reportado los calendarios agrícolas de 28 países para el maíz; en particular para Alemania, ver Tabla 5. De acuerdo con el JRC [69], dichos calendarios se encuentran a una resolución por países y por regiones socio-económicas grandes clasificados dentro de la nomenclatura de unidades territoriales para estadísticas (NUTS, por siglas en inglés) como NUTS 0 y NUTS 1, respectivamente [43].

Quincenas mensuales del año																			
E-I	E-II	F-I	F-II	M-I	M-II	Ab-I	Ab-II	M-I	M-II	Jun-I	Jun-II	Jul-I	Jul-II	Ag-I	Ag-II	S-I	S-II	O-I	O-II
-	-	-	-	-	1	1	2	2	2	2	2	2	2	2	2	2	3	3	3

Tabla 5: Calendario agrícola para el cultivo del maíz en Alemania. Extracto y traducción de los calendarios agrícolas del maíz para los países miembros de la Unión Europea en resolución NUTS 0 y NUTS 1 [69]. Las celdas en color verde y etiquetadas con el número uno indican los periodos de plantación a etapas vegetativas tempranas, las celdas en color amarillo y etiquetadas con el número dos indican las etapas vegetativas a reproductivas del cultivo y, finalmente, las celdas en color rojo y etiquetadas con el número tres señalan los periodos de maduración a cosecha; mientras que las celdas en color blanco y etiquetadas por un guion señalan el periodo fuera de la temporada agrícola.

Para el caso de Alemania, este calendario se muestra con resolución NUTS 0 únicamente; asimismo, considera fechas fijas y presenta información actualizada hasta 2015 [69]. Por tanto, posee tanto las ventajas como las limitaciones discutidas en la revisión del estado del arte para los calendarios agrícolas basados en información local.

Resaltando que, por una parte, es un calendario que reporta información oficial que proviene de un organismo internacional. Y, por otra parte, a consecuencia de su resolución, carece de especificidad geográfica lo que, potencialmente, enmascara las variaciones particulares de cada región.

El proyecto Fenología Paneuropea 725 (PEP725, por sus siglas en inglés) alberga bases de datos fenológicas para promover el desarrollo científico y educativo [157, 158]. De esta manera, la base de datos que concierne al cultivo de maíz en Alemania reporta datos históricos desde 1951 hasta 2015 [110].

Al analizar la base de datos de fechas de siembra que se reportan a través del proyecto PEP725 y contrastarlos con el calendario agrícola descrito por el JRC se observa una clara discrepancia, ver Fig. 4. Las fechas de siembra teóricas anteceden al periodo de fechas que se emplean en el campo para llevar a cabo la siembra del maíz.

Más aún, a lo largo de los 64 años reportados, solo se han registrado siembras en 3654 días distintos de los 23360 disponibles acumulados. Por otra parte, únicamente en 847 veces se han llevado siembras dentro del periodo teórico, implicando que el 76.82 % de las fechas se encuentra fuera del periodo reportado oficialmente. Específicamente, en el campo, la siembra del maíz tiende a ser posterior al final de la temporada de siembra que se comunica en el calendario agrícola teórico.

En la Fig. 4, el análisis presentado es binario en el sentido de que si en una fecha dada no se ha registrado alguna siembra, esta se mantiene en color blanco; mientras que, si se ha registrado una o más siembras, dicha fecha se muestra en color negro. Al hacer distinción sobre el número de siembras realizadas en las diversas fechas obtenemos una perspectiva más amplia, ver Fig. 5.

Al estimar las distribuciones de las fechas de siembra reportadas anualmente, a través del método Kernel Density Estimation (KDE) implementado a través de JoyPy, puede apreciarse que, en general, son insesgadas. Por tanto, se verifica que el periodo de fechas de siembra teóricas culmina previo al periodo en el cual se realiza la siembra realmente.

Ante cambios en el clima, la conjunción entre el conocimiento local y los modelos agrícolas puede ser un auxiliar en el apropiado ajuste de los manejos agrícolas [165, 180]. Por otra parte, el efecto del cambio climático sobre la sincronía entre los eventos fenológicos con los procesos agrícolas es diverso [27, 36, 91, 92, 151, 190] induciendo, únicamente, tres escenarios




Figura 4: Comparativa entre las fechas de siembra históricas y las fechas de siembra del calendario agrícola teórico. Las líneas punteadas en color rojo denotan el día número 74 y 105 del año que corresponden al inicio y fin del periodo de siembra, respectivamente, que comprende desde la segunda mitad de marzo hasta la primera mitad de abril [69]. Los puntos en color negro indican que las fechas en las que se llevó a cabo, al menos, una siembra de maíz dentro de Alemania en el periodo de 1951 a 2015 [110].

posibles: adelantar, mantener o retrasar dicha sincronía.

La migración hacia fechas previas a las usuales puede resultar beneficioso al evitar condiciones estresantes asociadas a temporadas más cálidas [27]. Asimismo, en algunas regiones, la plantación temprana de maíz tuvo un efecto en el incremento de la cosecha [92, 151]. No obstante, en este escenario, es posible que las plantas demoren más tiempo para emerger a la par de reducir la densidad poblacional del cultivo [91].

En comparación, optar por fechas posteriores expone a condiciones más cálidas a los cultivo, especialmente en zonas en donde el comienzo de la temporada de heladas se ha retrasado [27].




Figura 5: Comparativa entre el periodo de fechas de siembra del calendario agrícola teórico y las distribuciones anuales de las fechas de siembra históricas. Las líneas punteadas en color rojo denotan el día número 74 y 105 del año que corresponden al inicio y fin del periodo de siembra, respectivamente, que comprende desde la segunda mitad de marzo hasta la primera mitad de abril [69]. Mientras que en escala de colores se visualizan las estimaciones por KDE de las distribuciones de fechas de siembra por año.

De igual manera, puede favorecer que la maduración del maíz ocurra en menor tiempo, se obtengan granos con mayor humedad y plantas más altas [36, 91, 188]. Sin embargo, bajo este manejo agrícola, se ha reportado una baja en la producción de algunas variantes o híbridos del maíz [92, 151, 190].

En contraste, en las plantas como el maíz se han descrito métodos, tanto intrínsecos [1] como extrínsecos [174], capaces de compensar las condiciones del entorno y, así, mantener su

producción. De esta manera, cambiar las fechas para su plantación no tiene un efecto real sobre la cosecha obtenida, implicando que también es viable preservar las fechas usuales de plantación [92].

Al considerar lo antes discutido, es posible entender la complejidad subyacente en la determinación de periodos de siembra, lo cuales se ven influenciados tanto por objetivos agrícolas deseados como por las condiciones regionales [92]. De modo que comprender la interacción entre las alteraciones fenológicas y los ajustes procedimentales en la agricultura es crucial ante la incertidumbre que induce el cambio climático [27, 36, 117, 190].

Asimismo, lo anterior confirma, en lo general, la hipótesis bajo la cual desarrollamos este trabajo: el cambio climático ha producido cambios estructurales significativos en los procesos agrícolas de manera tal que los periodos óptimos para la plantación cultivos anuales; e.g., el maíz, cambian acorde el área, principalmente, por las variaciones climáticas [9, 14, 27, 91].

De igual forma, lo anterior justifica el estudio de las fechas de siembra históricas del maíz en Alemania, una región en transición climática, para generar un modelo matemático cuyo objetivo sea determinar las fechas que optimicen este proceso, favoreciendo un desarrollo sano y reduciendo la exposición al estrés del entorno.

En este sentido, a nivel particular de Alemania, se realizó un análisis comparativo del comportamiento registrado históricamente en tanto a los periodos de siembra, para corroborar la hipótesis que subyace en el desarrollo de este trabajo. En la Fig. 6, puede apreciarse un cambio entre la distribución de fechas de siembra registradas en el año 1951 y la correspondiente al año 2015.

En general, se observa que el periodo de siembra se ha reducido en los últimos años, concentrándose, en promedio, al rededor del día número 113.2247 ± 7.0994 del año. En contraste al año 1951, cuando el periodo tenía una mayor amplitud y se concentraba, en promedio, al rededor del día 124.2026 ± 13.8963 .

En particular, de acuerdo con la prueba Kolmogorov-Smirnov, ambas distribuciones presentan un comportamiento estocástico distinto ($p < 0.01$). En este sentido, de acuerdo con la prueba Shapiro-Wilk, las fechas de siembra empleadas durante 1951 siguen una distribución normal ($p > 0.05$); mientras que no hay evidencia suficiente para aceptar la hipótesis de normalidad en aquellas empleadas durante 2015 ($p < 0.01$).

Partiendo de lo anterior, se emplearon pruebas no paramétricas para hallar diferencias entorno a la dispersión y la tendencia central. De acuerdo con la prueba de Mood, hay una diferencia estadísticamente significativa entre las medianas de las fechas de siembra de 1951 y de 2015 ($p < 0.001$). De igual forma, la prueba para homocedasticidad de Levene con corrección de Brown Forsythe concluye que las distribuciones difieren respecto a la varianza




Figura 6: Comparación entre la distribución de fechas de siembra reportadas en los años 1951 y 2015, respectivamente. En color amarillo se aprecia la estimación por KDE de la distribución de fechas de siembra registradas para 1951. Similarmente, en color morado, se muestra la estimación por KDE de la distribución de fechas de siembra registradas para 2015.

($p < 0.01$).

Adicionalmente, según la prueba U de Mann-Whitney, en su versión lateral derecha; es decir, aquella que analiza si la distribución de las fechas de siembra de 1951 es estocásticamente más grande que la correspondiente al año 2015, indica que, en efecto, se presenta tal diferencia ($p < 0.01$). Por esta manera, puede concluirse que, en general, la temporada de siembra en 1951 ocurría en temporadas más tardías, con mayor amplitud en su duración y una mayor dispersión en comparación de lo observado en 2015.

Más aún, lo anterior sugiere que las ventanas de siembra presentan la tendencia de trasladarse

hacia el inicio del año. Además, es importante mencionar, que los resultados antes mencionados se preservaron aún tras considerar los datos libres de *outliers*, en este caso, empleando un método clásico [86], removiendo aquellos datos fuera del intervalo $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$, con Q_i , $i = 1, 3$, el i -ésimo cuartil y IQR la distancia intercuartílica, robusteciendo las conclusiones obtenidas.

Para extender el análisis previo, en la Fig. 7 se realizó una prueba Kruskal-Wallis para determinar si, de manera general, existen diferencias en la distribución de las fechas de siembra en función de los años. Tras concluir que, en efecto, hay diferencias ($p < 0.01$; $H = 9656.7260$), se procedió a realizar un análisis a pares a través de la prueba de Dunn con corrección de Benjamini-Hochberg para reducir la detección de falsos descubrimientos, ver Fig. 7.

En la Fig. 7 se observa que las comparaciones entre la distribución de fechas de siembra correspondientes al año 1951 y las de otros años presentan resultados heterogéneos en términos de significancia estadística. En particular, las últimas comparaciones en donde no se encontró evidencia suficiente para rechazar la hipótesis de igualdad entre las distribuciones de 1951 corresponden a los datos reportados para los años 1985, 1987 y 2001. En contraste, sí se identificaron diferencias estadísticamente significativas entre la distribución de 1951 y los datos provenientes de años más recientes.

Por otra parte, al considerar la distribución de fechas de siembra del año 2015 como referencia fija, se observa una tendencia general hacia la presencia de diferencias estadísticamente significativas en las comparaciones a pares, en la mayoría de los casos con niveles de significancia de $p < 0.01$. La única excepción corresponde al año 2009, cuya distribución no difiere estadísticamente de la observada en 2015.

Anteriormente se mencionó que, en Alemania, la temporada de siembra de maíz presenta la tendencia de trasladarse hacia épocas más cercanas al inicio del año. Para profundizar de manera crítica en dicho comportamiento se procedió analíticamente implementando técnicas estadísticas, ver Fig. 8.

Al comparar el promedio de las fechas de siembra empleadas tanto durante 1951 como a lo largo de 2015, hay una diferencia de 11.5612 días. Es decir, tras un periodo de 64 años, la fecha de siembra promedio se ha adelantado 11 días, aproximadamente. Lo anterior sugiere que el tiempo tiene un efecto intrínseco en el proceso de siembra.

Derivado de la falta de la hipótesis en la normalidad de los datos reportados, se empleó la correlación de Spearmann para cuantificar la correspondencia entre el paso de los años con las fechas de siembra. Bajo este esquema, se obtuvo un coeficiente de correlación, estadísticamente significativo ($p < 0.01$), de $\rho = -0.2756$. Por tanto, a medida que transcurren los años, la siembra ocurre en épocas más tempranas.

Con el objetivo de cuantificar la tendencia temporal observada, se empleó el método de




Figura 7: Matriz de significancia construida a partir de las comparaciones a pares entre las distribuciones de fechas de siembra de maíz históricas en Alemania. Los p -valores se obtuvieron a partir de la prueba post-hoc de Dunn, con corrección de Benjamini–Hochberg para múltiples comparaciones, a consecuencia de una prueba de Kruskal–Wallis. Las celdas en color blanco representa la no significancia estadística, $p \geq 0.05$, y la intensidad del color rojo denota la significancia estadística, las tonalidades más claras indican un nivel de significancia $p < 0.05$, las tonalidades medias indican $p < 0.01$ y, finalmente, las tonalidades más oscuras indican $p < 0.001$.

mínimos cuadrados para determinar la recta de mejor ajuste. Con ello, se identificó que si y y d_s denotan los años y las fechas de siembra, respectivamente, entonces el ajuste lineal está dado por

$$d_s = -0.1805y + 478.6709. \quad (29)$$

El ajuste representa la tendencia promedio de las fechas de siembra dado que considera todas las observaciones disponibles. En particular, este resultado indica que, aproximadamente, la fecha de siembra se adelanta 1.8 días por década, ver Fig. 8.




Figura 8: Tendencia en las fechas de siembra de maíz en Alemania. En círculos de color negro se muestran las fechas registradas empleadas en el periodo de 1951 a 2015 para efectuar la siembra. Las líneas punteadas horizontales en color verde y azul representan la fecha de siembra promedio observada en los años 1951 y 2015, respectivamente. La línea sólida en color rojo muestra el ajuste lineal de la tendencia en las fechas de siembra obtenido a través del método de mínimos cuadrados.

Al proceder con la remoción de *outliers* clásica [86], que preserva solo a los datos dentro del intervalo $[Q_1 - 1.5 \text{ IQR}, Q_3 + 1.5 \text{ IQR}]$, con Q_i , $i = 1, 3$, el i -ésimo cuartil y IQR la distancia intercuartílica, los resultados previamente discutidos se mantienen. No obstante, la diferencia entre las fechas promedio de 1951 respecto a 2015 se reduce a 9.4024 días; asimismo, del ajuste lineal proveniente del método de mínimos cuadrado, se tiene que la tendencia promedio es que las fechas de siembra se adelanten en, aproximadamente, 1.57 días por década, ver Tabla 6.

Previamente, se mencionó que, en lo general, hay evidencia en la literatura que corrobora la hipótesis bajo la cual se desarrolla este trabajo. En este sentido, en conjunto, los análisis presentados, los cuales estudian la problemática de interés directamente, apoyan la hipótesis subyacente. Es decir, en lo particular, hay cambios estructurales significativos dentro de los procesos agrícolas.

Datos	Ajustes lineales	
	Con outliers	Sin outliers
Fechas de siembra	$d_s = -0.1805y + 478.6709$	$d_s = -0.1578y + 433.4605$
Promedios anuales (1951–2015)	$d_s = -0.1732y + 464.0563$	$d_s = -0.1479y + 413.4202$
Promedios anuales (1951–1988)	$d_s = -0.1078y + 335.3932$	$d_s = -0.0710y + 262.2608$
Promedios anuales (1989–2015)	$d_s = -0.2774y + 672.4599$	$d_s = -0.2637y + 645.0710$

Tabla 6: Aproximaciones lineales para el ajuste de los datos de siembra. La columna de la izquierda muestra las rectas de mejor ajuste, determinadas a través del método de mínimos cuadrados, considerando la totalidad de los datos para cada uno de los casos listados. Similarmente para la columna de la derecha, salvo que considera los datos listados libres de outliers. La notación d_s indica la fecha de siembra mientras que y denota los años.

Más aún, se identificó un cambio estructural en la tendencia de las fechas de siembra promedio, mismo que sucedió a finales de la década de 1980, ver Fig. 9. De acuerdo con la literatura, las alteraciones estructurales halladas pueden vincularse a modificaciones en los regímenes climáticos, las cuales se derivan del cambio climático [23, 97, 135, 178]. Además, es importante mencionar la influencia de los eventos antropogénicos ocurridos tanto en Alemania [121] como en Europa [3].

En general, la prueba Mann-Kendall evalúa si el valor de los datos tiende a aumentar o disminuir de forma consistente en función de la variable predictora [185], sin asumir que tal este cambio sea lineal. En este caso, las fechas de siembra promedio tienen una tendencia monótona decreciente estadísticamente significativa ($p < 0.01$).

Tras confirmar lo antes mencionado, se procedió a detectar la existencia de algún instante en el que sucediese un cambio abrupto en el comportamiento a través de la prueba de Pettitt [81]. Con esta herramienta se determinó que el año 1988 constituye un punto de quiebre significativo ($p < 0.01$), lo cual sugiere que las fechas de siembra difieren drásticamente de un periodo a otro.

Para analizar la veracidad de la afirmación anterior, empleamos la prueba de Chow, la cual determina si dos modelos lineales, asociados a un mismo fenómeno en dos periodos distintos, difieren significativamente [24, 130]. De esta manera, empleando el método de mínimos cuadrados, se obtuvieron las rectas de mejor ajuste con las fechas de siembra promediadas anualmente pertenecientes al periodo de 1951 a 1988 y, similarmente, para aquellas comprendidas de 1989 a 2015, ver Tabla 6. Adicionalmente, como referencia, se obtuvo la recta de mejor ajuste empleando las fechas promedio desde 1951 a 1988, ver Fig. 9.




Figura 9: Tendencia interanual en las fechas promedio de siembra de maíz en Alemania. Los puntos en color negro representan los promedios anuales de las fechas de siembra. La línea vertical en color rojo punteada indica el año 1988, identificado como punto de cambio estructural mediante la prueba de Pettitt. La línea sólida en color gris corresponde al ajuste por mínimos cuadrados calculado a partir de toda la serie de promedios anuales. Las líneas punteadas azul y amarilla muestran los ajustes lineales obtenidos por mínimos cuadrados para los periodos 1951–1988 y 1989–2015, respectivamente. Como referencia, la línea punteada en color gris corresponde al ajuste mostrado en la Fig. 8.

De la prueba de Chow se concluye que no hay evidencia suficiente para argumentar que los datos se ajustan mejor, con modelos lineales, si se dividen en dos periodos distintos ($p > 0.05$). Por otra parte, al remover los *outliers* en cada año documentado, los resultados son consistentes salvo que, de acuerdo con la respectiva prueba de Pettitt, el punto de cambio estructural se traslada al año 1987 ($p < 0.01$) y, de acuerdo con la respectiva prueba de Chow, el ajuste de los datos mejora significativamente si se emplean modelos lineales distintos para cada uno de los dos periodos ($p < 0.05$), ver Tabla 6.

De esta manera, el cambio estructural hallado se preserva y corrobora, en lo particular, la hipótesis acerca de cambios estructurales en los procesos agrícolas a causa del cambio climático. No obstante, la caracterización de las fechas de siembra promediadas anualmente en los periodos de 1951–1988 y 1989–2015 requiere de metodologías más sofisticadas que los ajustes lineales y queda fuera de los objetivos del presente trabajo.

Referencias

- [1] H.A.S. Agrama. Sequential path analysis of grain yield and its components in maize. *Plant Breeding*, 115(5):343–346, 1996.
- [2] M. Ahmed, A. Sameen, and A.M.S. Kheir. Warming trends and shortened growing seasons: integrating four decades of observations and model simulations to develop wheat adaptation strategies in semi-arid pakistan. *Scientific Reports*, 16(1), February 2026.
- [3] R.M. Alexakhin, N.I. Sanzharova, S.V. Fesenko, S.I. Spiridonov, and A.V. Panov. Chernobyl radionuclide distribution, migration, and environmental and agricultural impacts. *Health Physics*, 93(5):418–426, November 2007.
- [4] E. Altman and U. Yechiali. Cyclic bernoulli polling. *ZOR Zeitschrift für Operations Research Methods and Models of Operations Research*, 38(1):55–76, February 1993.
- [5] M. Amare and B. Balana. Climate change, income sources, crop mix, and input use decisions: Evidence from nigeria. *Ecological Economics*, 211:107892, 2023.
- [6] A. Anandhi. Growing degree days – ecosystem indicator for changing diurnal temperatures and their impact on corn growth stages in kansas. *Ecological Indicators*, 61:149–158, February 2016.
- [7] J.R. Angel, M. Widhalm, D. Todey, R. Massey, and L. Biehl. The u2u corn growing degree day tool: Tracking corn growth across the us corn belt. *Climate Risk Management*, 15:73–81, 2017.
- [8] R.N. Bahuguna and K.S.V. Jagadish. Temperature regulation of plant phenological development. *Environmental and Experimental Botany*, 111:83–90, 2015.
- [9] M. E. Baum, S. V. Archontoulis, and M. A. Licht. Planting date, hybrid maturity, and weather effects on maize yield and crop stage. *Agronomy Journal*, 111(1):303–313, 2019.
- [10] G. Bayable, G. Amare, G. Alemu, and T. Gashaw. Spatiotemporal variability and trends of rainfall and its association with pacific ocean sea surface temperature in west harerge zone, eastern ethiopia. *Environmental Systems Research*, 10:1–21, 2021.
- [11] R. Bernal-Morales, J.P. Juárez-Sánchez, B. Ramírez-Valverde, I. Ocampo-Fletes, and M.A. Velasco-Hernández. Impact of climate change on maize (zea mays l.) planting dates in the eastern region of puebla, mexico. *Agrociencia*, page 1–16, August 2025.
- [12] I. Biavetti, S. Karetsos, A. Ceglar, A. Toreti, and P. Panagos. European meteorological data: contribution to research, development, and policy support. In Diofantos G. Hadjimitsis, Kyriacos Themistocleous, Silas Michaelides, and Giorgos Papadavid, editors, *Second International Conference on Remote Sensing and Geoinformation of the Environment (RSCy2014)*, volume 9229, page 922907. SPIE, August 2014.

- [13] M.A. Boyd and S. Lau. An introduction to markov modeling: Concepts and uses. In *Annual Reliability and Maintainability Symposium*, 1998.
- [14] H. Arnold Bruns and H. K. Abbas. Planting date effects on bt and non-bt corn in the mid-south usa. *Agronomy Journal*, 98(1):100–106, 2006.
- [15] Bundesamt für Kartographie und Geodäsie. Nuts-gebiete 1:250 000 (nuts250) – open data download, jul 2025. Accesado vía https://daten.gdz.bkg.bund.de/produkte/vg/nuts250_1231/aktuell/nuts250_12-31.utm32s.gpkg.zip en abril 16, 2026.
- [16] E.E. Butler and P. Huybers. Variations in the sensitivity of us maize yield to extreme temperatures by region and growth phase. *Environmental Research Letters*, 10(3):034009, March 2015.
- [17] R. Callejas-Rodríguez, R. Reyes-Sánchez, I. Plácido-Tomieli, and H. Flores-Gallardo. Métodos de evaluación de tiempo térmico para determinar fecha de plantación de papa para la agroindustria. *Revista Fitotecnia Mexicana*, 46(2):127, June 2023.
- [18] W. Campillay-Llanos, S. Ortega-Farias, and L. Ahumada-Orellana. Development and validation of phenological models for eight varieties of sweet cherry (*prunus avium* l.) growing under mediterranean climate condition. *Scientia Horticulturae*, 326:112711, 2024.
- [19] L. Cassani and A. Gomez-Zavaglia. Sustainable food systems in fruits and vegetables food supply chains. *Frontiers in Nutrition*, 9, February 2022.
- [20] A. Ceglar, Z. Črepinšek, L. Kajfež-Bogataj, and T. Pogačar. The simulation of phenological development in dynamic crop model: The bayesian comparison of different methods. *Agricultural and Forest Meteorology*, 151(1):101–115, January 2011.
- [21] L.P. Cerdeira Morellato, B. Alberton, S.T. Alvarado, B. Borges, E. Buisson, M.G.G. Camargo, L.F. Cancian, D.W. Carstensen, D.F.E. Escobar, P.T.P. Leite, I. Mendoza, N.M.W.B. Rocha, N.C. Soares, T.S. Freire Silva, V.G. Staggemeier, A.S. Streher, B.C. Vargas, and C.A. Peres. Linking plant phenology to conservation biology. *Biological Conservation*, 195:60–72, 2016.
- [22] N. Chekenya. Climate-induced crop failure and crop abandonment: What do we know and not know? *African Journal of Agricultural and Resource Economics*, 18(2):142–151, June 2023.
- [23] F.M. Chmielewski, A. Müller, and E. Bruns. Climate changes and trends in phenology of fruit trees and field crops in germany, 1961–2000. *Agricultural and Forest Meteorology*, 121(1):69–78, 2004.
- [24] Gregory C. Chow. Tests of equality between sets of coefficients in two linear regressions. *Econometrica*, 28(3):591–605, 1960.

- [25] I. Chuine and J. Régnière. Process-based models of phenology for plants and animals. *Annual Review of Ecology, Evolution, and Systematics*, 48(Volume 48, 2017):159–182, 2017.
- [26] J. Cintas R., B. Franch, I. Becker-Reshef, S. Skakun, J.A. Sobrino, K. van Tricht, J. Degerickx, and S. Gilliams. Generating winter wheat global crop calendars in the framework of worldcereal. In *2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS*, page 6583–6586. IEEE, July 2021.
- [27] E.I. Clark, M.A. Moore, C.K. Khoury, B.S. Hulke, N.C. Kane, and S.C. Elmendorf. Climate drives variation in optimal phenology: 46 years of multi-environment trials in sunflower. *New Phytologist*, 249(3):1527–1541, 2026.
- [28] E.E. Cleland, I. Chuine, A. Menzel, H.A. Mooney, and M.D. Schwartz. Shifting plant phenology in response to global change. *Trends in Ecology & Evolution*, 22(7):357–365, 2007.
- [29] J. Cremers and I. Klugkist. One direction? a tutorial for circular data analysis using r with examples in cognitive psychology. *Frontiers in Psychology*, 9, 2018.
- [30] E. Cuevas, J. Blancas, J. Caballero, I. A Hinojosa-Díaz, and A. Martínez-Ballesté. Agricultural management and local knowledge: key factors for the conservation of socio-ecosystems in the face of the pollinator world crisis. *Botanical Sciences*, 99(2):305–320, 2021.
- [31] X Cui. Beyond yield response: Weather shocks and crop abandonment. *Journal of the Association of Environmental and Resource Economists*, 7(5):901–932, 2020.
- [32] C.M. da Silva, F.C. Araújo Ribeiro, J.W. Vieira, and C.A. da Silva Filho. Bootstrap interval with application in environmental monitoring. *International Journal of Environmental Studies*, 77(2):335–348, June 2019.
- [33] G. de Anda-Jauregui and E. Hernandez-Lemus. Identification of potential adverse drug reactions using random walk on network models. In *2021 Mexican International Conference on Computer Science (ENC)*, page 1–6. IEEE, August 2021.
- [34] Deutscher Wetterdienst. Climate data center (cdc): Daily climate observations, 2026. Accesado vía https://opendata.dwd.de/climate_envir/CDC/observations_germany/climate/daily/onment en marzo 10, 2026.
- [35] J.M. Diez, I. Ibáñez, A.J. Miller-Rushing, S.J. Mazer, T.M. Crimmins, M.A. Crimmins, C.D. Bertelsen, and D.W. Inouye. Forecasting phenology: from species variability to community patterns. *Ecology Letters*, 15(6):545–553, March 2012.
- [36] K. Djaman, S. Allen, D.S. Djaman, K. Koudahe, S. Irmak, N. Puppala, M.K. Darapuni, and S.V. Angadi. Planting date and plant density effects on maize growth, yield and water use efficiency. *Environmental Challenges*, 6:100417, 2022.

- [37] C. Donmez, M. Schmidt, A. Cilek, M. Grosse, C. Paul, W. Hierold, and K. Helming. Climate change impacts on long-term field experiments in germany. *Agricultural Systems*, 205:103578, 2023.
- [38] K. Donohue, L.T. Burghardt, D. Runcie, K.J. Bradford, and J. Schmitt. Applying developmental threshold models to evolutionary ecology. *Trends in Ecology & Evolution*, 30(2):66–77, 2015.
- [39] C. Duden, C. Nacke, and F. Offermann. German yield and area data for 11 crops from 1979 to 2021 at a harmonized spatial resolution of 397 districts. *Scientific Data*, 11(1), January 2024.
- [40] M.N. Elnesr, A.A. Alazba, and A.A. Alsadon. An arithmetic method to determine the most suitable planting dates for vegetables. *Computers and Electronics in Agriculture*, 90:131–143, 2013.
- [41] O. Erenstein, J. Chamberlin, and K. Sonder. Estimating the global number and distribution of maize and wheat farms. *Global Food Security*, 30:100558, 2021.
- [42] O. Erenstein, M. Jaleta, K. Sonder, K. Mottaleb, and B.M. Prasanna. Global maize production, consumption and trade: trends and r& d implications. *Food Security*, 14(5):1295–1319, May 2022.
- [43] Eurostat, European Commission. Territorial units for statistics (nuts) – gisco geodata, 2026. Accesado vía <https://ec.europa.eu/eurostat/web/gisco/geodata/statistical-units/territorial-units-statistics> en marzo 6, 2026.
- [44] M.S. Farooq, M. Uzair, A. Raza, M. Habib, Y. Xu, M. Yousuf, S.H. Yang, and M. Ramzan Khan. Uncovering the research gaps to alleviate the negative impacts of climate change on food security: a review. *Frontiers in plant science*, 13:927535, 2022.
- [45] S. Felema, L.C. Garcia, J.A. Gomes, R.Z. Filho, É.P. Zeny, and A.F. Luchetti. Optimal timing of fungicide applications on maize, soybean, and beans based on calendar and agrometeorological data. *New Zealand Journal of Agricultural Research*, 67(4):513–525, 2024.
- [46] C.B. Field, V. Barros, T.F. Stocker, D. Qin, D.J. Dokken, K.L. Ebi, M.D. Mastrandrea, K.J. Mach, G.-K. Plattner, S.K. Allen, M. Tignor, and P.M. Midgley, editors. *Managing the Risks of Extreme Events and Disasters to Advance Climate Change Adaptation*. Cambridge University Press, Cambridge, United Kingdom, 2012.
- [47] L. Flores, C. Nendel, B. Bookhagen, J.A. Oviedo Reyes, T. Smith, and G. Ghazaryan. The potential of sentinel-1 time series for large-scale assessment of maize and wheat phenology across germany. *GIScience & Remote Sensing*, 62(1), 2025.

- [48] H. Flores-Gallardo, W. Ojeda-Bustamante, H. Flores-Magdaleno, E. Mejía-Sáenz, and E. Sifuentes-Ibarra. Grados día y la programación integral del riego en el cultivo de papa. *Terra Latinoamericana*, 30(1):59–67, 2012.
- [49] Food and Agriculture Organization of the United Nations. *Seeds in emergencies: A technical handbook*. FAO Plant Production and Protection Papers. Food and Agriculture Organization of the United Nations (FAO), Rome, Italy, March 2011.
- [50] Food and Agriculture Organization of the United Nations. Maize – crop information, 2026. Accesado vía <https://www.fao.org/land-water/databases-and-software/crop-information/maize/en/> en marzo 10, 2026.
- [51] H. Fotouo Makouate and M. Zude-Sasse. Advances in growing degree days models for flowering to harvest: Optimizing crop management with methods of precision horticulture—a review. *Horticulturae*, 11(12), 2025.
- [52] J. France and J.H.M. Thornley. *Mathematical models in agriculture*. Butterworths, London, 1984. p. 335.
- [53] B. Franch, J. Cintas, I. Becker-Reshef, M.J. Sanchez-Torres, J. Roger, S. Skakun, J.A. Sobrino, K. Van Tricht, J. Degerickx, S. Gilliams, B. Koetz, Z. Szantoi, and A. Whitcraft. Global crop calendars of maize and wheat in the framework of the worldcereal project. *GIScience & Remote Sensing*, 59(1):885–913, 2022.
- [54] O. Garcia-Tejera, R. Marcos-Matamoros, B. Basile, A. Mataffo, P. Scognamiglio, H. Prieto, L. Mancha, I. Cabral, J. Queiroz, J. Valente, F. Alves, N. González-Reviriego, S. Hernández-Barrera, M. Mata, and J. Girona. A method for using monthly average temperatures in phenology models for grapevine (*vitis vinifera* l.). *OENO One*, 56(4):173–182, November 2022.
- [55] A. García-Mendoza. Distribution of agave (agavaceae) in mexico. 74:177–187, 2002.
- [56] R. Gatto and S.R. Jammalamadaka. Directional statistics: Introduction, March 2015.
- [57] M. Ghamghami, N. Ghahreman, P. Irannejad, and K. Ghorbani. Comparison of data mining and gdd-based models in discrimination of maize phenology. *International Journal of Plant Production*, 13(1):11–22, November 2018.
- [58] M. Giolo, R. Sallenave, C. Pornaro, C. Velasco-Cruz, S. Macolino, and B. Leinauer. Base temperatures affect accuracy of growing degree day model to predict emergence of bermudagrasses. *Agronomy Journal*, 113(3):2960–2966, April 2021.
- [59] A. Gordes, editor. *Climate-Smart Agriculture Sourcebook*. Food and Agriculture Organization of the United Nations (FAO), Rome, Italy, 2nd edition, 2017. Accessed 26 February 2026.

- [60] C.M. Grinstead and J.L. Snell. *Introduction to Probability*. American Mathematical Society, Providence, RI, 2nd edition, 2003.
- [61] W.S.C. Gurney, P.H. Crowley, and R.M. Nisbet. Locking life-cycles onto seasons: Circle-map models of population dynamics and local adaptation. *Journal of Mathematical Biology*, 30(3):251–279, January 1992.
- [62] B. Hennemuth, S. Bender, K. Bülow, N. Dreier, E. Keup-Thiel, O. Krüger, C. Muellersbach, C. Radermacher, and R. Schoetter. Statistical methods for the analysis of simulated and observed climate data: applied in projects and institutions dealing with climate change impact and adaptation. Climate Service Center Germany, 2013.
- [63] A.K. Hickling and S.A. Gelman. How does your garden grow? early conceptualization of seeds and their place in the plant growth cycle. *Child Development*, 66(3):856–876, 1995.
- [64] O.C. Ibe. *Basic Concepts in Probability*, page 1–27. Elsevier, 2013.
- [65] T. Iizumi, W. Kim, and M. Nishimori. Modeling the global sowing and harvesting windows of major crops around the year 2000. *Journal of Advances in Modeling Earth Systems*, 11(1):99–112, 2019.
- [66] J. Jägermeyr and K. Frieler. Spatial variations in crop growing seasons pivotal to reproduce global fluctuations in maize and wheat yields. *Science Advances*, 4(11), November 2018.
- [67] N. Jain and P. Ramu. L-moments and chebyshev inequality driven convex model for uncertainty quantification. *Structural and Multidisciplinary Optimization*, 65(7), June 2022.
- [68] Z. Ji, Y. Pan, X. Zhu, and E.S. Adem. Combining multi-source data, phenology information, and machine learning approaches to estimate crop yield in the united states. *Field Crops Research*, 336:110219, February 2026.
- [69] Joint Research Centre of the European Commission. Agri4cast data portal, 2026. Accesado el 19 de febrero, 2026.
- [70] P.D. Jones, T. Jonsson, and D. Wheeler. Extension to the north atlantic oscillation using early instrumental pressure observations from gibraltar and south-west iceland. *International Journal of Climatology*, 17(13):1433–1450, November 1997. Actualizado a febrero 18, 2026.
- [71] A. Jungk. Carl sprengel—the founder of agricultural chemistry: A re-appraisal commemorating the 150th anniversary of his death. *Journal of Plant Nutrition and Soil Science*, 172(5):633–636, 2009.

- [72] Markus Keller. Chapter 2: Phenology and growth cycle. In M. Keller, editor, *The Science of Grapevines (Third Edition)*, pages 61–103. Academic Press, third edition edition, 2020.
- [73] John G Kemeny and J Laurie Snell. *Finite Markov chains*. Undergraduate Texts in Mathematics. Springer, New York, NY, 1 edition, July 1976.
- [74] M. Kim, J. Kim, M.-H. Jo, K. Sung, and K.-J. Han. Assessment of planting soil temperature and growing degree day impacts on silage corn (zea mays l.) biomass. *Journal of Animal Science and Technology*, 66(5):949–961, September 2024.
- [75] J. Kimball. *Vegetation Phenology*, page 886–890. Springer New York, 2014.
- [76] Hans-Peter Kläring and Angela Schmidt. Diurnal temperature variations significantly affect cucumber fruit growth. *HortScience*, 52(1):60–64, January 2016.
- [77] P.R. Koya and A.T. Goshu. Generalized mathematical model for biological growths. *Open Journal of Modelling and Simulation*, 01(04):42–53, 2013.
- [78] V. Krishnamurthy. Predictability of weather and climate. *Earth and Space Science*, 6(7):1043–1056, 2019.
- [79] C. Kubota. Chapter 10: Growth, development, transpiration and translocation as affected by abiotic environmental factors. In Toyoki Kozai, Genhua Niu, and Michiko Takagaki, editors, *Plant Factory*, pages 151–164. Academic Press, San Diego, 2016.
- [80] M.S. Kukal and S. Irmak. U.s. agro-climate in 20th century: Growing degree days, first and last frost, growing season length, and impacts on crop yields. *Scientific Reports*, 8(1), May 2018.
- [81] Z.W. Kundzewicz and A.J. Robson. Change detection in hydrological records—a review of the methodology / revue méthodologique de la détection de changements dans les chroniques hydrologiques. *Hydrological Sciences Journal*, 49(1):7–19, February 2004.
- [82] M.-W. Li and J.M. Gendron. Exploring the metabolic daylength measurement system: implications for photoperiodic growth. *New Phytologist*, 245(2):503–509, 2025.
- [83] X. Li, L. Yu, Z. Du, and X. Liu. Crop statistic to annual map: Tracking spatiotemporal dynamics of crop-specific areas through machine learning and statistics disaggregating. *Scientific Data*, 12(1), July 2025.
- [84] L. Liang. Phenology. In *Reference Module in Earth Systems and Environmental Sciences*. Elsevier, 2019.
- [85] J. Liebig. *Die organische Chemie in ihrer Anwendung auf Agricultur und Physiologie*. Friedrich Vieweg und Sohn Publ. Co., Braunschweig, Germany, 1840.

- [86] H. Lin, R. Zhang, and T. Tong. When tukey meets chauvenet: a new boxplot criterion for outlier detection. *Journal of Computational and Graphical Statistics*, pages 1–14, 2025.
- [87] H.W. Linderholm. Growing season changes in the last century. *Agricultural and Forest Meteorology*, 137(1):1–14, 2006.
- [88] Y.-Y. Liu, Y.-C. Su, P.-W. Sun, H.-Y. Dai, and B.-J. Kuo. Stability of maize phenology predictions by using calendar days, thermal functions, and photothermal functions. *Agriculture*, 15(19), 2025.
- [89] N.V. Long, Y. Assefa, R. Schwalbert, and I.A. Ciampitti. Maize yield and planting date relationship: A synthesis-analysis for us high-yielding contest-winner and field research data. *Frontiers in Plant Science*, 8, December 2017.
- [90] K.V. Mardia and P.E. Jupp. *Directional Statistics*. Wiley, January 1999.
- [91] A. Maresma, A. Ballesta, F. Santiveri, and J. Lloveras. Sowing date affects maize development and yield in irrigated mediterranean environments. *Agriculture*, 9(3):67, March 2019.
- [92] S. Mason, T. Galusha, and Z. Kmail. Planting date influence on yield of drought-tolerant maize with different maturity classifications. *Agronomy Journal*, 110(1):293–299, 2018.
- [93] S. Materia, L. García Palma, C. van Straaten, S. O, A. Mamalakis, L. Cavicchia, D. Coumou, P. de Luca, M. Kretschmer, and M. Donat. Artificial intelligence for climate prediction of extremes: State of the art, challenges, and future perspectives. *Wiley Interdisciplinary Reviews: Climate Change*, 15(6):e914, 2024.
- [94] G.S. McMaster and W.W. Wilhelm. Growing degree-days: one equation, two interpretations. *Agricultural and Forest Meteorology*, 87(4):291–300, 1997.
- [95] E.D. Meenken, C.M. Triggs, H.E. Brown, S. Sinton, J.R. Bryant, A.D.L. Noble, M. Espig, M. Sharifi, and D.M. Wheeler. Bayesian hybrid analytics for uncertainty analysis and real-time crop management. *Agronomy Journal*, 113(3):2491–2505, 2021.
- [96] E.K. Melaas, M.A. Friedl, and A.D. Richardson. Multiscale modeling of spring phenology across deciduous forests in the eastern united states. *Global Change Biology*, 22(2):792–805, January 2016.
- [97] A. Menzel, Y. Yuan, M. Matiu, T. Sparks, H. Scheifinger, R. Gehrig, and N. Estrella. Climate change fingerprints in recent european plant phenology. *Global Change Biology*, 26(4):2599–2612, February 2020.
- [98] T. Miedaner and P. Juroszek. Global warming and increasing maize cultivation demand comprehensive efforts in disease and insect resistance breeding in north-western europe. *Plant Pathology*, 70(5):1032–1046, 2021.

- [99] I.J. Mirón, C. Linares, and J. Díaz. The influence of climate change on food production and food safety. *Environmental Research*, 216:114674, 2023.
- [100] E.A. Mitscherlich. Das gesetz des minimums und das gesetz des abnehmenden bodenertrages. *Landwirtschaftliche Jahrbücher*, 38:537–552, 1909.
- [101] Y. Mo, J. Zhang, H. Jiang, and Y.H. Fu. A comparative study of 17 phenological models to predict the start of the growing season. *Frontiers in Forests and Global Change*, 5, 2023.
- [102] A.F Moraes García, L. Micheletti Broglio, M. Santoro Brossi, N. Teixeira dos Santos, T. Avilés Cantuarias, and S. da Silva Rodrigues. Horticultural performance of 'hass' avocado grafted onto seedling and clonal rootstocks under tropical wet-dry climate conditions. *Scientia Horticulturae*, 302:111155, August 2022.
- [103] E.W. Mugi-Ngenga, M.N. Kiboi, M.W. Mucheru-Muna, J.N. Mugwe, F.S. Mairura, D.N. Mugendi, and F.K. Ngetich. Indigenous and conventional climate-knowledge for enhanced farmers' adaptation to climate variability in the semi-arid agro-ecologies of kenya. *Environmental Challenges*, 5:100355, 2021.
- [104] Samuel S. Myers, Antonella Zanobetti, Itai Kloog, Peter Huybers, Andrew D. B. Leakey, Arnold J. Bloom, Eli Carlisle, Lee H. Dietterich, Glenn Fitzgerald, Toshihiro Hasegawa, N. Michele Holbrook, Randall L. Nelson, Michael J. Ottman, Victor Raboy, Hidemitsu Sakai, Karla A. Sartor, Joel Schwartz, Saman Seneweera, Michael Tausz, and Yasuhiro Usui. Increasing co2 threatens human nutrition. *Nature*, 510(7503):139–142, May 2014.
- [105] S.S. Narwal, S. Poonia, and D.S. Singh, G.and Malik. Influence of sowing dates on the growing degree days and phenology of winter maize (zea mays l.). *Agricultural and Forest Meteorology*, 38(1):47–57, 1986.
- [106] National Research Council. *Lessons from the Past Provide Direction for the Future*, pages 1–22. National Academies Press, Washington, DC, 1996.
- [107] G.E.O. Ogutu, W.H.P. Franssen, I. Supit, P. Omondi, and R.W.A. Hutjes. Probabilistic maize yield prediction over east africa using dynamic ensemble seasonal climate forecasts. *Agricultural and Forest Meteorology*, 250–251:243–261, March 2018.
- [108] J.E. Olesen, T.R. Carter, C.H. Díaz-Ambrona, S. Fronzek, T. Heidmann, T. Hickler, T. Holt, M.I. Minguez, P. Morales, J.P. Palutikof, M. Quemada, M. Ruiz-Ramos, G.H. Rubæk, F. Sau, B. Smith, and M.T. Sykes. Uncertainties in projected impacts of climate change on european agriculture and terrestrial ecosystems based on scenarios from regional climate models. *Climatic Change*, 81(S1):123–143, March 2007.
- [109] Q. Orozco-Ramírez, H. Perales, and R.J. Hijmans. Geographical distribution and diversity of maize (zea mays l. subsp. mays) races in mexico. *Genetic Resources and Crop Evolution*, 64(5):855–865, April 2016.

- [110] Pan European Phenology Network. Pep725 data selection portal, 2025. Accesado vía http://www.pep725.eu/data_download/data_selection.php en marzo 6, 2026.
- [111] R. Parajuli, G. Thoma, and M.D. Matlock. Environmental sustainability of fruit and vegetable production supply chains in the face of climate change: A review. *Science of The Total Environment*, 650:2863–2879, 2019.
- [112] P. Paredes, R. López-Urrea, Á. Martínez-Romero, M. Petry, M.R. Cameira, F. Montoya, M. Salman, and L.S. Pereira. Estimating the lengths of crop growth stages to define the crop coefficient curves using growing degree days (gdd): Application of the revised fao56 guidelines. *Agricultural Water Management*, 319:109758, 2025.
- [113] B. Parent, M. Leclerc, S. Lacube, M.A. Semenov, C. Welcker, P. Martre, and F. Tardieu. Maize yields over europe may increase in spite of climate change, with an appropriate use of the genetic variability of flowering time. *Proceedings of the National Academy of Sciences*, 115(42):10642–10647, 2018.
- [114] B. Parent and F. Tardieu. Temperature responses of developmental processes have not been affected by breeding in different ecological areas for 17 crop species. *New Phytologist*, 194(3):760–774, March 2012.
- [115] B. Park, Y. Kim, S. Min, and E. Lim. Anthropogenic and natural contributions to the lengthening of the summer season in the northern hemisphere. *Journal of Climate*, 31(17):6803 – 6819, 2018.
- [116] J.S. Park, S. Hong, J. Go, M.-G. Seok, H. Lee, and G. Yi. Tracing the global spread of maize (*zea mays* l.) through plastome analysis of landraces. *BMC Plant Biology*, 26(1), November 2025.
- [117] P.S. Parker, J.S. Shonkwiler, and J. Aurbacher. Cause and consequence in maize planting dates in germany. *Journal of Agronomy and Crop Science*, 203(3):227–240, 2016.
- [118] J.H. Patel and M.P. Oza. Deriving crop calendar using ndvi time-series. *The International Archives of the Photogrammetry, Remote Sensing and Spatial Information Sciences*, XL-8:869–873, 2014.
- [119] D.A. Perala. Predicting red pine shoot growth using growing degree days. *Forest Science*, 31(4):913–925, December 1985.
- [120] A.A. Pinto, C. Zerbato, and G. de Souza Rolim. A machine learning models approach and remote sensing to forecast yield in corn with based cumulative growth degree days. *Theoretical and Applied Climatology*, 155(8):7285–7294, June 2024.
- [121] T. Plieninger and H. Schaich. Socialist and postsocialist land-use legacies determine farm woodland composition and structure: lessons from eastern germany. *European Journal of Forest Research*, 133(4):597–610, February 2014.

- [122] G.M. Poggi, M. Vignudelli, F. Di Cesare, and F. Ventura. Alternative modelling approaches significantly differ in simulating summer crops phenology in mediterranean europe. *International Journal of Biometeorology*, 70(1), January 2026.
- [123] H. Poorter, K.J. Niklas, P.B. Reich, J. Oleksyn, P. Poot, and L. Mommer. Biomass allocation to leaves, stems and roots: meta-analyses of interspecific variation and environmental control. *New Phytologist*, 193(1):30–50, 2012.
- [124] F.T. Portmann, S. Siebert, and P. Döll. Mirca2000—global monthly irrigated and rainfed crop areas around the year 2000: A new high-resolution data set for agricultural and hydrological modeling. *Global Biogeochemical Cycles*, 24(1), 2010.
- [125] J.A. Powell and J.A. Logan. Insect seasonality: circle map analysis of temperature-driven life cycles. *Theoretical Population Biology*, 67(3):161–179, May 2005.
- [126] S. Qiao, S.P. Harrison, I.C. Prentice, and H. Wang. Optimality-based modelling of wheat sowing dates globally. *Agricultural Systems*, 206:103608, March 2023.
- [127] R. Rafique, T. Ahmad, M.A. Khan, M. Ahmed, and G. Hoogenboom. Developing a simple and efficient modeling solution for predicting key phenological stages of table grapes in a non-traditional viticulture zone in south asia. *International Journal of Biometeorology*, 68(8):1587–1601, May 2024.
- [128] K.M. Ramachandran and C.P. Tsokos. *Mathematical Statistics with Applications*. Elsevier Science, 2009.
- [129] P. Ranum, J.P. Peña-Rosas, and M.N. Garcia-Casal. Global maize production, utilization, and consumption. *Annals of the New York Academy of Sciences*, 1312(1):105–112, 2014.
- [130] D.E. Rapach and M.E. Wohar. Structural breaks and predictive regression models of aggregate us stock returns. *Journal of Financial Econometrics*, 4(2):238–274, 2006.
- [131] J.I. Rattalino Edreira, K.G. Cassman, Z. Hochman, M.K. van Ittersum, L. van Bussel, L. Claessens, and P. Grassini. Beyond the plot: technology extrapolation domains for scaling out agronomic science. *Environmental Research Letters*, 13(5):054027, May 2018.
- [132] K.D. Rausch and R.L. Belyea. The future of coproducts from corn processing. *Applied Biochemistry and Biotechnology*, 128(1):047–086, 2006.
- [133] F. Recknagel. Cyberinfrastructure for sourcing and processing ecological data. *Ecological Informatics*, 75:102039, 2023.
- [134] J. Régnière and J.A. Powell. *Animal Life Cycle Models (Poikilotherms)*, pages 295–316. Springer Netherlands, Dordrecht, 2013.

- [135] P.C. Reid, R.E. Hari, G. Beaugrand, D.M. Livingstone, C. Marty, D. Straile, J. Barichivich, E. Goberville, R. Adrian, Y. Aono, R. Brown, J. Foster, P. Groisman, P. Hélaouët, H.-H. Hsu, R. Kirby, J. Knight, A. Kraberg, J. Li, T.-T. Lo, R.B. Myneni, R.P. North, J.A. Pounds, T. Sparks, R. Stübi, Y. Tian, K.H. Wiltshire, D. Xiao, and Z. Zhu. Global impacts of the 1980s regime shift. *Global Change Biology*, 22(2):682–703, November 2015.
- [136] P. Revilla, M.L. Alves, V. Andelković, C. Balconi, I. Dinis, P. Mendes-Moreira, R. Redaelli, J.I. Ruiz de Galarreta, M.C. Vaz Patto, S. Žilić, and R.A. Malvar. Traditional foods from maize (*zea mays* l.) in europe. *Frontiers in Nutrition*, 8, 2022.
- [137] S.M.F. Riaz, M.J. Iqbal, and S. Hameed. Impact of the north atlantic oscillation on winter climate of germany. *Tellus A: Dynamic Meteorology and Oceanography*, 69(1):1406263, January 2017.
- [138] A.D. Richardson. Phenocam: An evolving, open-source tool to study the temporal and spatial variability of ecosystem-scale phenology. *Agricultural and Forest Meteorology*, 342:109751, 2023.
- [139] A.D. Richardson, T.F. Keenan, M. Migliavacca, Y. Ryu, O. Sonnentag, and M. Toomey. Climate change, phenology, and phenological control of vegetation feedbacks to the climate system. *Agricultural and Forest Meteorology*, 169:156–173, 2013.
- [140] J.L. Rocha-Arroyo, S. Salazar-García, A.E. Bárcenas-Ortega, I.J.L. González-Durán, and L.E. Cossio-Vargas. Fenología del aguacate “Hass” en Michoacán. *Revista mexicana de ciencias agrícolas*, 2(3):303–316, 2011.
- [141] S.M. Ross. *A First Course in Probability*. Pearson, Harlow, United Kingdom, 8 edition, 2020.
- [142] W.J. Sacks, D. Deryng, J.A. Foley, and N. Ramankutty. Crop planting dates: an analysis of global patterns. *Global Ecology and Biogeography*, 19(5):607–620, August 2010.
- [143] W.J. Sacks and C.J. Kucharik. Crop management and phenology trends in the u.s. corn belt: Impacts on yields, evapotranspiration and energy balance. *Agricultural and Forest Meteorology*, 151(7):882–894, July 2011.
- [144] Y. Sadeh, X. Zhu, D. Dunkerley, J.P. Walker, Y. Chen, and K. Chenu. Versatile crop yield estimator. *Agronomy for Sustainable Development*, 44(4), July 2024.
- [145] Q. Shi, T. Pan, D. Lu, H. Li, and Z. Chai. Bpum: A bayesian probabilistic updating model applied to early crop identification. *Journal of Remote Sensing*, 5, January 2025.
- [146] K.R. Shivanna. Climate change and its impact on biodiversity and human welfare. *Proceedings of the Indian National Science Academy*, 88(2):160–171, May 2022.

- [147] M.G. Simpson. Chapter 9: Plant morphology. In M.G. Simpson, editor, *Plant Systematics (Second Edition)*, pages 451–513. Academic Press, San Diego, second edition edition, 2010.
- [148] T.R. Sinclair and W.I. Park. Inadequacy of the liebig limiting-factor paradigm for explaining varying crop yields. *Agronomy Journal*, 85(3):742–746, 1993.
- [149] A.A. Sokan-Adeaga, S.A. Salami, D.O. Bolade, M. Aledeh, M.A. Sokan-Adeaga, O.E. Amubieya, S.A. Kehinde, M. Farzadkia, G.M. Ashraf, and E. Hoseinzadeh. Utilization of local corn (zea mays) wastes for bioethanol production by separate hydrolysis and fermentation. *Journal of Hazardous Materials Advances*, 15:100447, 2024.
- [150] C. Sprengel. Von den substanzen der ackerkrume und des untergrundes. *Journal for Technische and Okonomische Chemie*, 2:397–421, 1828.
- [151] S.A. Staggenborg, D.L. Fjell, D.L. Devlin, W.B. Gordon, L.D. Maddux, and B.H. Marsh. Selecting optimum planting dates and plant populations for dryland corn in kansas. *Journal of Production Agriculture*, 12(1):85–90, 1999.
- [152] E. Stehfest, Heistermann, Joerg A. Priess, Dennis S. Ojima, and Joseph Alcamo. Simulation of global crop production with the ecosystem model daycent. *Ecological Modelling*, 209(2):203–219, 2007.
- [153] P. Su, A. Zhang, J. Wang, and W. Xu. Plausible maize planting distribution under future global change scenarios. *Field Crops Research*, 302:109079, 2023.
- [154] B. Sánchez, A. Rasmussen, and J.R. Porter. Temperatures and the growth and development of maize and rice: a review. *Global Change Biology*, 20(2):408–417, 2014.
- [155] S.A. Tanumihardjo, L. McCulley, R. Roh, S. Lopez-Ridaura, N. Palacios-Rojas, and N.S. Gunaratna. Maize agro-food systems to ensure food and nutrition security in reference to the sustainable development goals. *Global Food Security*, 25:100327, 2020.
- [156] M. Tarascio, L. Brancaleoni, A. Cazzavillan, M. Cutini, R. Gerdol, and T. Abeli. Photo-period–temperature interactions in a changing climate: A review of plant phenological responses. *Journal of Biogeography*, 53(1):e70113, 2026. e70113 7724405.
- [157] B. Templ, E. Koch, K. Bolmgren, M. Ungersböck, A. Paul, H. Scheifinger, T. Rutishauser, M. Busto, F.-M. Chmielewski, L. Hájková, S. Hodzić, F. Kaspar, B. Pietragalla, R. Romero-Fresneda, A. Tolvanen, V. Vučetič, K. Zimmermann, and A. Zust. Pan european phenological database (pep725): a single point of access for european data. *International Journal of Biometeorology*, 62(6):1109–1113, February 2018.
- [158] B. Templ, H. Scheifinger, I. Ostovary, M. Ungersböck, and H. Ressler. Pep725: 15 years of driving european and global phenology science. *New Phytologist*, 2026.

- [159] R. Thompson and R.M. Clark. Spatio-temporal modelling and assessment of within-species phenological variability using thermal time methods. *International Journal of Biometeorology*, 50(5):312–322, February 2006.
- [160] J.H. Thornley and I.R. Johnson. *Plant and crop modelling*. Oxford University Press, 1990.
- [161] H.E.Z. Tonnang, D. Makumbi, and P. Craufurd. Methodological approach for predicting and mapping the phenological adaptation of tropical maize (zea mays l.) using multi-environment trials. *Plant Methods*, 14(1), December 2018.
- [162] K.E. Trenberth. What are the seasons? *Bulletin of the American Meteorological Society*, 64(11):1276 – 1282, 1983.
- [163] R. Tsimba, G.O. Edmeades, J.P. Millner, and P.D. Kemp. The effect of planting date on maize: Phenology, thermal time durations and growth rates in a cool temperate climate. *Field Crops Research*, 150:145–155, August 2013.
- [164] L.G.J. van Bussel, E. Stehfest, S. Siebert, C. Müller, and F. Ewert. Simulation of the phenological development of wheat and maize at the global scale. *Global Ecology and Biogeography*, 24(9):1018–1029, July 2015.
- [165] P.A.J. van Oort and S.J. Zwart. Impacts of climate change on rice production in africa and causes of simulated yield changes. *Global Change Biology*, 24(3):1029–1045, December 2017.
- [166] S.D. Vâtcă, V.A. Stoian, T.C. Man, C. Horvath, R. Vidican, Ș. Gâdea, A. Vâtcă, A. Rotaru, R. Vârban, M. Cristina, and V. Stoian. Agrometeorological requirements of maize crop phenology for sustainable cropping—a historical review for romania. *Sustainability*, 13(14):7719, July 2021.
- [167] N. Verdugo-Vásquez, C. Pañitrur-De la Fuente, and S. Ortega-Farías. Model development to predict phenological scale of table grapes (cvs. thompson, crimson and superior seedless and red globe) using growing degree days. *OENO One*, 51(3), Sep. 2017.
- [168] M. Viswanathan, A. Scheidegger, T. Streck, S. Gayler, and T.K.D. Weber. Bayesian multi-level calibration of a process-based maize phenology model. *Ecological Modelling*, 474:110154, December 2022.
- [169] M. Viswanathan, T. K. D. Weber, S. Gayler, J. Mai, and T. Streck. A bayesian sequential updating approach to predict phenology of silage maize. *Biogeosciences*, 19(8):2187–2209, 2022.
- [170] P. E. Waggoner and W. A. Norvell. Fitting the law of the minimum to fertilizer applications and crop yields. *Agronomy Journal*, 71(2):352–354, 1979.

- [171] K. Waha, L.G.J. van Bussel, C. Müller, and A. Bondeau. Climate-driven simulation of global crop sowing dates. *Global Ecology and Biogeography*, 21(2):247–259, May 2011.
- [172] C.-H. Wang. Farming methods effects on the soil fertility and crop production under a rice-vegetables cropping sequences. *Journal of Plant Nutrition*, 37(9):1498–1513, 2014.
- [173] J. Wang, Y. Guan, L. Wu, X. Guan, W. Cai, J. Huang, W. Dong, and B. Zhang. Changing lengths of the four seasons by global warming. *Geophysical Research Letters*, 48(6):e2020GL091753, 2021. e2020GL091753 2020GL091753.
- [174] J. Wang, L. Zhao, B.-Z. Wang, F. Mo, N. Wang, S.-T. Liu, Y. Song, A.-T. Ren, F.-J. Mei, Y. Wang, Q. Lu, and Y.-C. Xiong. Plastic film mulching ensures maize climate resilience: A perspective of temperature suitability and optimal sowing period window. *Soil and Tillage Research*, 252:106611, October 2025.
- [175] A.K. Whitcraft, I. Becker-Reshef, and C.O. Justice. Agricultural growing season calendars derived from modis surface reflectance. *International Journal of Digital Earth*, 8(3):173–197, 2015.
- [176] J.A. Winkler, A.B. Cinderich, S.D. Ddumba, D. Doubler, J. Nikolic, Perdinan, A.M. Pollyea, D.R. Young, and C. Zavalloni. 2.04: Understanding the impacts of climate on perennial crops. In Roger A. Pielke, editor, *Climate Vulnerability*, pages 37–49. Academic Press, Oxford, 2013.
- [177] L. Wu, Y. Feng, L. and Zhang, J. Gao, and J. Wang. Comparison of five wheat models simulating phenology under different sowing dates and varieties. *Agronomy Journal*, 109(4):1280–1293, 2017.
- [178] X. Wu, R. Zurita-Milla, and M.-J. Kraak. A novel analysis of spring phenological patterns over europe based on co-clustering. *Journal of Geophysical Research: Biogeosciences*, 121(6):1434–1448, June 2016.
- [179] C. Yang, N. Lei, C. Menz, A. Ceglar, J.A. Torres-Matallana, S. Li, Y. Jiang, X. Tan, L. Tao, F. He, S. Li, B. Liu, F. Yang, H. Fraga, and J.A. Santos. Regional uncertainty analysis between crop phenology model structures and optimal parameters. *Agricultural and Forest Meteorology*, 355:110137, August 2024.
- [180] H. Yang, S. Ranjitkar, W. Xu, L. Han, J. Yang, L. Wu, and J. Xu. Crop-climate model in support of adjusting local ecological calendar in the taxkorgan, eastern pamir plateau. *Climatic Change*, 167(3–4), August 2021.
- [181] H.S Yang, A. Dobermann, J.L Lindquist, D.T. Walters, T.J. Arkebauer, and K.G Cassman. Hybrid-maize—a maize simulation model that combines two crop modeling approaches. *Field Crops Research*, 87(2–3):131–154, May 2004.

- [182] N. Yang, Y. Wang, X. Liu, M. Jin, M. Vallebuena-Estrada, E. Calfee, L. Chen, B.P. Dilkes, S. Gui, X. Fan, T.K. Harper, D.J. Kennett, W. Li, Y. Lu, J. Ding, Z. Chen, J. Luo, S. Mambakkam, M. Menon, S. Snodgrass, C. Veller, S. Wu, S. Wu, L. Zhuo, Y. Xiao, X. Yang, M.C. Stitzer, D. Runcie, J. Yan, and J. Ross-Ibarra. Two teosintes made modern maize. *Science*, 382(6674):eadg8940, 2023.
- [183] S. Yang, J. Logan, and D.L. Coffey. Mathematical formulae for calculating the base temperature for growing degree days. *Agricultural and Forest Meteorology*, 74(1):61–74, 1995.
- [184] M. Yaseen, S.E. Saqib, F. Zulfiqar, S. Ali, and S. Visetnoi. Farmers’ decisions under climate change: A field level empirical investigation of climate risk management strategies. *Sustainable Futures*, 10:101390, 2025.
- [185] S. Yue, P. Pilon, and G. Cavadias. Power of the mann–kendall and spearman’s rho tests for detecting monotonic trends in hydrological series. *Journal of Hydrology*, 259(1–4):254–271, March 2002.
- [186] Q.-J. Zhang, D.-L. Wu, Y.-C. Zhu, C. Liu, and D.-S. Yang. A long-term dataset of maize phenology observations from agrometeorological stations in northeast china (1981–2024). *Scientific Data*, 12(1), November 2025.
- [187] Y. Zhang, J. Liu, L. Guan, D. Fan, F. Xia, A. Wang, Y. Bao, and Y. Xu. By-products of zeamays l.: A promising source of medicinal properties with phytochemistry and pharmacological activities: A comprehensive review. *Chemistry & Biodiversity*, 20(3):e202200940, 2023.
- [188] G. Zhou and Q. Wang. A new nonlinear method for calculating growing degree days. *Scientific Reports*, 8(1), July 2018.
- [189] L. Zhou, X. Han, Q. Yang, H. Feng, and K.H.M. Siddique. Optimizing sowing date to mitigate loss of growing degree days and enhance crop water productivity of groundwater-irrigated spring maize. *Agricultural Water Management*, 305:109097, December 2024.
- [190] G. Zhu, Z. Liu, S. Qiao, Z. Zhang, Q. Huang, Z. Su, and X. Yang. How could observed sowing dates contribute to maize potential yield under climate change in northeast china based on apsim model. *European Journal of Agronomy*, 136:126511, May 2022.